MODELO BASADO EN DEEP LEARNING CON ANÁLISIS DE DATOS FUNCIONALES PARA LA CLASIFICACIÓN DE PACIENTES CON ENFERMEDAD DE PARKINSON USANDO SEÑALES DE ELECTROENCEFALOGRAMA



LADY JOHANA ESPAÑA GAMBOA
22500238

UNIVERSIDAD AUTÓNOMA DE OCCIDENTE
FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS
MAESTRÍA EN INTELIGENCIA ARTIFICIAL Y CIENCIA DE DATOS
SANTIAGO DE CALI
2026

MODELO BASADO EN DEEP LEARNING CON ANÁLISIS DE DATOS FUNCIONALES PARA LA CLASIFICACIÓN DE PACIENTES CON ENFERMEDAD DE PARKINSON USANDO SEÑALES DE ELECTROENCEFALOGRAMA



LADY JOHANA ESPAÑA GAMBOA

Proyecto de grado para optar al título de
Magíster en Inteligencia Artificial y Ciencia de Datos

Director
JOHANN ALEXIS OSPINA GALINDEZ
Magíster en Estadística
Codirectora
DORIS ELENA CAMPO DUARTE
Doctora en Ciencias Matemáticas

UNIVERSIDAD AUTÓNOMA DE OCCIDENTE
FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS
MAESTRÍA EN INTELIGENCIA ARTIFICIAL Y CIENCIA DE DATOS
SANTIAGO DE CALI
2026

Nota de aceptación

Johann Alexis Ospina Galíndez
Director

Doris Elena Campo Duarte
Codirectora

Jurado

Santiago de Cali, 29 de agosto de 2026

A mi madre por ser el motor de todos mis logros y a Valentina por estar siempre presente.

AGRADECIMIENTOS

En primer lugar, agradezco a Dios y a la vida por darme la oportunidad de aprender cada día y enfrentar nuevos retos. Me agradezco a mí misma por mi capacidad de superación, por mi esfuerzo, por la fortaleza para afrontar las dificultades y por mantener el compromiso necesario para llevar a buen término las metas que me propongo.

A mi madre, por su paciencia, comprensión y cariño durante este proceso, especialmente en los momentos en que los compromisos redujeron el tiempo que podía compartir con ella. A mi sobrina, por su compañía diaria y por estar presente durante tantas jornadas de trabajo; agradezco a Dios por tenerla en mi vida. A mi familia, por su apoyo incondicional.

A mis amigos, por su apoyo, comprensión y confianza. Les agradezco especialmente su disposición para escucharme, animarme en los momentos difíciles y acompañarme de distintas maneras mientras avanzaba en este proceso.

A mis profesores y a la Universidad, por contribuir a mi formación académica y profesional, por los conocimientos compartidos, por el acompañamiento y las oportunidades brindadas durante esta etapa.

ÍNDICE GENERAL

Agradecimientos 5

Índice de figuras 9

Índice de tablas 11

Lista de abreviaturas y siglas 12

Introducción 17

1. Planteamiento del problema 19
- 1.1. Descripción del problema . . . 19
- 1.2. Formulación del problema . . . 20
- 1.3. Objetivos . . . 20
  - 1.3.1. Objetivo general . . . 20
  - 1.3.2. Objetivos específicos . . . 20
- 1.4. Justificación . . . 20
- 1.5. Alcance y delimitaciones . . . 21

2. Marco referencial 23
- 2.1. Marco teórico . . . 23
  - 2.1.1. La enfermedad de Parkinson . . . 23
  - 2.1.2. Electroencefalografía . . . 24
  - 2.1.3. Análisis de datos funcionales . . . 25
  - 2.1.4. Redes neuronales y datos funcionales . . . 33
- 2.2. Antecedentes . . . 38
  - 2.2.1. Enfoques basados en aprendizaje automático clásico . . . 38
  - 2.2.2. Enfoques basados en aprendizaje profundo . . . 39
  - 2.2.3. Enfoques basados en análisis de datos funcionales . . . 41
  - 2.2.4. Antecedentes sobre la cohorte analizada . . . 42
  - 2.2.5. Oportunidad de investigación . . . 43

3. Metodología 46
- 3.1. Conjunto de datos y sujetos . . . 46
- 3.2. Preprocesamiento de las señales EEG . . . 47
  - 3.2.1. Re-referenciado . . . 48
  - 3.2.2. Filtrado . . . 48
  - 3.2.3. Remuestreo . . . 48
  - 3.2.4. Corrección de artefactos mediante ICA . . . 48
  - 3.2.5. Selección de canales . . . 49
  - 3.2.6. Segmentación en épocas . . . 49
  - 3.2.7. Rechazo de épocas . . . 50
- 3.3. Estimación espectral . . . 50

3.3.1. Estimación mediante el método de Welch . . . 50
3.3.2. Procesamiento espectral según la estrategia de representación . . . 51
3.4. Construcción de las representaciones funcionales . . . 53
3.4.1. Configuración de la base funcional . . . 54
3.4.2. Construcción funcional en el dominio de la frecuencia . . . 56
3.4.3. Construcción funcional sobre el orden normalizado de las épocas . . . 56
3.4.4. Incorporación de la geometría funcional mediante Cholesky . . . 57
3.4.5. Reducción dimensional mediante FPCA . . . 59
3.5. Modelos de clasificación . . . 60
3.5.1. Modelos de referencia . . . 60
3.5.2. Arquitecturas de aprendizaje profundo . . . 61
3.5.3. Diseño de la comparación . . . 64
3.5.4. Análisis complementario para aislar el aporte específico del ADF . . . 65
3.5.5. Interpretabilidad funcional mediante reconstrucción de funciones de peso . . . 66
3.6. Esquema de validación y métricas . . . 68
3.6.1. Validación cruzada agrupada por sujeto . . . 69
3.6.2. Prevención de fuga de información . . . 69
3.6.3. Agregación de predicciones a nivel de sujeto . . . 70
3.6.4. Métricas de evaluación . . . 70
3.7. Análisis estadístico . . . 71
3.8. Herramientas computacionales . . . 72
3.9. Síntesis del flujo metodológico . . . 73

4. Resultados **75**
4.1. Preprocesamiento y limpieza de la señal . . . 75
4.1.1. Filtrado y corrección de artefactos . . . 75
4.1.2. Rechazo de épocas y control de calidad . . . 78
4.2. Caracterización espectral de los datos . . . 80
4.2.1. Dominancia y distribución espacial del ritmo alfa . . . 80
4.2.2. Enlentecimiento del pico alfa . . . 81
4.3. Configuración y caracterización de la representación funcional . . . 83
4.3.1. Elección de la base funcional . . . 83
4.3.2. Enfoque A: selección de la base y representación funcional . . . 83
4.3.3. Enfoque B: selección de la base y representación funcional . . . 85
4.3.4. Validación de la transformación de Cholesky . . . 88
4.3.5. Reducción de dimensión mediante FPCA . . . 89
4.3.6. Representaciones funcionales y entradas al modelado . . . 91
4.4. Comparación de modelos y representaciones . . . 93
4.4.1. Desempeño de las representaciones por sujeto . . . 94
4.4.2. Estrategia A2: entrenamiento con representaciones por época . . . 95
4.4.3. Efecto de las transformaciones funcionales . . . 96
4.5. Curvas de validación . . . 98
4.5.1. Control del sobreajuste . . . 98
4.5.2. Curva de aprendizaje por número de sujetos . . . 99

4.6. Análisis complementarios del aporte del ADF 100
4.6.1. Aislamiento del aporte específico del ADF 100
4.6.2. Interpretabilidad funcional mediante funciones de peso 102

5. Conclusiones **104**
5.1. Principales hallazgos y contribución 104
5.1.1. Contribución de la representación funcional 104
5.1.2. Complejidad del modelo y tamaño de la muestra 106
5.1.3. Comparación con el estado del arte 107
5.1.4. Alcance de la contribución 108
5.2. Limitaciones 109
5.3. Trabajo futuro 110

Referencias **112**

A. Resultados completos por modelo **118**

B. Configuración de los modelos de clasificación **122**

C. Material complementario para reproducibilidad **125**

ÍNDICE DE FIGURAS

2.1. Esquema general de una red neuronal profunda tipo *feedforward*. Elaboración propia. . . . 34
2.2. Esquema general de una red convolucional unidimensional (CNN1D). Elaboración propia. . . . 35
2.3. Esquema del mecanismo de atención de múltiples cabezas en una arquitectura Transformer. Elaboración propia. . . . 36
2.4. Esquema conceptual de una red neuronal funcional. Elaboración propia. . . . 37

3.1. Esquemas de las arquitecturas de propósito general y funcionales evaluadas. Elaboración propia. . . . 62
3.2. Arquitectura EEGNet adaptada a las representaciones funcionales utilizadas en el estudio. Elaboración propia. . . . 63
3.3. Esquema general de la metodología propuesta. Elaboración propia. . . . 74

4.1. Comparación temporal antes y después del preprocesamiento en ejemplos de HC y PD_OFF. Elaboración propia con datos de OpenNeuro ds003490. 76
4.2. Comparación espectral antes y después del preprocesamiento en un sujeto HC, canal Pz. Elaboración propia con datos de OpenNeuro ds003490. . . . 77
4.3. Comparación espectral antes y después del preprocesamiento en un sujeto PD_OFF, canal Pz. Elaboración propia con datos de OpenNeuro ds003490. 77
4.4. Densidad espectral de potencia relativa por región en HC y PD_OFF. Elaboración propia con datos de OpenNeuro ds003490. . . . 81
4.5. Distribución de la frecuencia del pico alfa en personas sanas y pacientes. Elaboración propia con datos de OpenNeuro ds003490. . . . 82
4.6. Comparación entre B-spline y P-spline en el Enfoque A. Elaboración propia con datos de OpenNeuro ds003490. . . . 84
4.7. Selección del número de nudos por GCV en el Enfoque A. Elaboración propia con datos de OpenNeuro ds003490. . . . 85
4.8. Curvas funcionales del Enfoque A en HC y PD_OFF. Elaboración propia con datos de OpenNeuro ds003490. . . . 86
4.9. Selección del número de nudos por GCV en theta y alfa. Elaboración propia con datos de OpenNeuro ds003490. . . . 86
4.10. Trayectorias funcionales alfa del Enfoque B. Elaboración propia con datos de OpenNeuro ds003490. . . . 87
4.11. Trayectorias funcionales theta del Enfoque B. Elaboración propia con datos de OpenNeuro ds003490. . . . 88
4.12. Componentes FPCA retenidos por canal y banda en el Enfoque B. Elaboración propia con datos de OpenNeuro ds003490. . . . 91
4.13. Ejemplo de reconstrucción funcional del Enfoque A en el canal Pz. Elaboración propia con datos de OpenNeuro ds003490. . . . 92
4.14. Ejemplo de reconstrucción funcional del Enfoque B en el canal Pz en alfa. Elaboración propia con datos de OpenNeuro ds003490. . . . 92

4.15. Ejemplo de reconstrucción funcional del Enfoque B en el canal Pz en theta. Elaboración propia con datos de OpenNeuro ds003490. 93
4.16. Matrices de confusión de configuraciones seleccionadas de A1 y A2. Elaboración propia con datos de OpenNeuro ds003490. 98
4.17. Evolución del AUC de entrenamiento y validación en modelos profundos seleccionados de la estrategia A2. Elaboración propia con datos de OpenNeuro ds003490. 99
4.18. Curva de aprendizaje según el número de sujetos independientes utilizados para entrenamiento. Elaboración propia con datos de OpenNeuro ds003490. 100
4.19. Funciones de peso reconstruidas por canal entre 4 y 10 Hz. Elaboración propia con datos de OpenNeuro ds003490. 102

ÍNDICE DE TABLAS

2.1. Resumen de trabajos previos en clasificación de señales EEG mediante aprendizaje automático, aprendizaje profundo y análisis de datos funcionales. 44

3.1. Características demográficas de la cohorte original `ds003490`. 47

4.1. Componentes ICA excluidos durante la corrección de artefactos. 78
4.2. Conservación de épocas en las sesiones incluidas. 79
4.3. Tasas de marcado de los criterios de rechazo sobre las 50 sesiones candidatas. 79
4.4. Validación numérica de la transformación de Cholesky. 89
4.5. Componentes FPCA retenidos por canal en el Enfoque A. 90
4.6. Mejor desempeño observado por representación según exactitud balanceada. 94
4.7. Mejor desempeño observado de aprendizaje profundo por representación. 94
4.8. Comparación entre las estrategias A1 y A2 del Enfoque A. 96
4.9. Desempeño de las representaciones evaluadas en el análisis de ablación. 101

A.1. Resultados de la línea base sin ADF basada en características escalares. . 118
A.2. Enfoque A, estrategia A1: desempeño a nivel de sujeto sobre las tres representaciones funcionales. 119
A.3. Enfoque B: desempeño a nivel de sujeto. 120
A.4. Enfoque A, estrategia A2: desempeño a nivel de sujeto. 121

B.1. Configuración de entrenamiento utilizada en las arquitecturas de aprendizaje profundo. 122
B.2. Principales parámetros estructurales de los modelos de clasificación evaluados. 123
B.3. Número de parámetros entrenables de las arquitecturas de aprendizaje profundo según el enfoque y la representación funcional. 124

LISTA DE ABREVIATURAS Y SIGLAS

A1: Estrategia del Enfoque A con una representación funcional por sujeto.

A2: Estrategia del Enfoque A con representaciones funcionales por época y agregación posterior de las predicciones a nivel de sujeto.

ADF: Análisis de Datos Funcionales.

AdaFNN: Red neuronal funcional con bases adaptativas (*Adaptive Functional Neural Network*).

AUC: Área bajo la curva ROC (*Area Under the ROC Curve*).

BalAcc: Exactitud balanceada (*Balanced Accuracy*).

CNN1D: Red neuronal convolucional unidimensional (*One-Dimensional Convolutional Neural Network*).

DE: Desviación estándar.

DL: Aprendizaje profundo (*Deep Learning*).

ECM: Error cuadrático medio.

EEG: Electroencefalografía (*Electroencephalography*).

EEGNet: Arquitectura convolucional compacta diseñada para el procesamiento de señales EEG.

EOG: Electrooculografía (*Electrooculography*).

EP: Enfermedad de Parkinson.

FDA: Análisis de Datos Funcionales (*Functional Data Analysis*); sigla correspondiente a

la denominación en inglés.

FDNN: Red neuronal profunda con entradas funcionales (*Functional Deep Neural Network*).

FIR: Respuesta finita al impulso (*Finite Impulse Response*).

FNN: Red neuronal funcional (*Functional Neural Network*).

FPCA: Análisis de Componentes Principales Funcionales (*Functional Principal Component Analysis*).

GCV: Validación Cruzada Generalizada (*Generalized Cross-Validation*).

HC: Controles sanos (*Healthy Controls*).

ICA: Análisis de Componentes Independientes (*Independent Component Analysis*).

LogReg: Regresión logística (*Logistic Regression*).

ML: Aprendizaje automático (*Machine Learning*).

MLP: Perceptrón multicapa (*Multilayer Perceptron*).

MNE-Python: Biblioteca de Python para el procesamiento y análisis de datos neurofisiológicos.

PAF: Frecuencia del pico alfa (*Peak Alpha Frequency*).

PD: Enfermedad de Parkinson (*Parkinson's Disease*); sigla correspondiente a la denominación en inglés.

PD_OFF: Pacientes con enfermedad de Parkinson evaluados en estado OFF de medicación.

PET: Tomografía por emisión de positrones (*Positron Emission Tomography*).

PSD: Densidad espectral de potencia (*Power Spectral Density*).

PTP: Amplitud pico a pico (*Peak-to-Peak*).

Random Forest: Modelo de clasificación basado en un ensamble de árboles de decisión.

REM: Movimientos oculares rápidos (*Rapid Eye Movement*).

ROC: Curva de característica operativa del receptor (*Receiver Operating Characteristic*).

SPECT: Tomografía computarizada por emisión de fotón único (*Single-Photon Emission Computed Tomography*).

SSE: Suma de cuadrados del error (*Sum of Squared Errors*).

Transformer: Arquitectura neuronal basada en mecanismos de atención.

UNM: Universidad de Nuevo México (*University of New Mexico*).

VC: Validación cruzada.

RESUMEN

La enfermedad de Parkinson (EP) figura entre los trastornos neurodegenerativos de rápido crecimiento a nivel mundial y su diagnóstico continúa basándose principalmente en la valoración clínica, lo que motiva la búsqueda de herramientas complementarias de análisis. El electroencefalograma (EEG) ofrece una alternativa no invasiva y de alta resolución temporal para estudiar la actividad cortical, pero los enfoques tradicionales resumen esta señal en unas pocas características escalares y descartan la forma del espectro, donde se expresan biomarcadores asociados con la enfermedad.

El Análisis de Datos Funcionales (ADF) permite modelar la información espectral como una función continua y conservar su forma, por lo que este trabajo lo evalúa como representación de entrada para la clasificación entre pacientes con EP y personas sanas a partir de EEG de reposo, sobre una cohorte pública de 48 sujetos. Se construyeron dos representaciones funcionales, una definida sobre el eje de la frecuencia y otra sobre el orden normalizado de las épocas válidas. La representación en frecuencia se evaluó tanto mediante una observación promedio por sujeto como mediante una estrategia de entrenamiento por épocas con agregación posterior de las predicciones a nivel de sujeto. Las representaciones funcionales se evaluaron mediante dos modelos clásicos y siete arquitecturas de aprendizaje profundo, y sus resultados se contrastaron con una línea base basada en características espectrales escalares, bajo validación cruzada agrupada por sujeto.

La representación funcional en frecuencia alcanzó un valor máximo observado de exactitud balanceada de 0,818 mediante regresión logística con Cholesky, frente a 0,732 obtenido por Transformer en la línea base escalar. En el Enfoque B, basado en el orden normalizado de las épocas, el mayor valor observado fue 0,781 mediante Random Forest con Cholesky+FPCA. La estrategia de entrenamiento por épocas (A2) alcanzó un máximo observado de 0,824 mediante regresión logística con Cholesky+FPCA. El modelo propuesto, FDNN con Cholesky+FPCA bajo A2, obtuvo una exactitud balanceada de 0,781 y un AUC de 0,875, sin superar el desempeño observado del modelo lineal bajo las condiciones evaluadas. La FPCA redujo la dimensión media aproximadamente un 46,7 % en el Enfoque A y un 30 % en el Enfoque B. En una comparación controlada con regresión logística, el ADF no mostró una ventaja predictiva frente a una PSD discretizada con información espectral equivalente. Su aporte se situó principalmente en una representación estructurada y compacta de la información espectral y en la posibilidad de interpretarla sobre el dominio continuo de la frecuencia. Estas comparaciones son descriptivas y no constituyen evidencia de superioridad estadística entre configuraciones.

Palabras clave: enfermedad de Parkinson; electroencefalografía (EEG); análisis de datos funcionales; aprendizaje profundo; clasificación.

ABSTRACT

Parkinson's disease (PD) is among the fastest-growing neurodegenerative disorders worldwide, and its diagnosis continues to rely primarily on clinical assessment, motivating the search for complementary analytical tools. Electroencephalography (EEG) provides a non-invasive approach with high temporal resolution for studying cortical activity; however, traditional approaches often summarize the signal using a limited set of scalar features and may not explicitly preserve the shape of the spectrum, where disease-related neurophysiological alterations may be expressed.

Functional Data Analysis (FDA) enables spectral information to be modeled as a continuous function while preserving its structure. Accordingly, this study evaluated FDA-based representations as inputs for the experimental classification of patients with PD and healthy individuals using resting-state EEG from a public cohort of 48 subjects. Two functional representations were constructed: one defined over the frequency domain and another over the normalized order of valid epochs. The frequency-domain representation was evaluated both as a single averaged observation per subject and through an epoch-based training strategy with subsequent aggregation of predictions at the subject level. The functional representations were assessed using two classical models and seven deep learning architectures and were compared with a baseline based on scalar spectral features under subject-wise grouped cross-validation.

The frequency-domain functional representation achieved a maximum observed balanced accuracy of 0.818 using logistic regression with Cholesky transformation, compared with 0.732 obtained by Transformer for the scalar baseline. In Approach B, based on the normalized order of epochs, the highest observed value was 0.781 using Random Forest with Cholesky+FPCA. The epoch-based training strategy (A2) achieved a maximum observed balanced accuracy of 0.824 using logistic regression with Cholesky+FPCA. The proposed model, FDNN with Cholesky+FPCA under A2, achieved a balanced accuracy of 0.781 and an AUC of 0.875, without exceeding the observed performance of the linear model under the evaluated conditions. FPCA reduced the average dimensionality by approximately 46.7 % in Approach A and 30 % in Approach B. In a controlled comparison using logistic regression, FDA showed no predictive advantage over a discretized PSD containing equivalent spectral information. Its main contribution therefore lay in providing a structured and compact representation of spectral information and enabling interpretation over the continuous frequency domain. These comparisons are descriptive and do not constitute evidence of statistical superiority between configurations.

Keywords: Parkinson's disease; electroencephalography (EEG); functional data analysis; deep learning; classification.

INTRODUCCIÓN

La enfermedad de Parkinson (EP) se ha consolidado como una de las enfermedades neurodegenerativas de mayor impacto y crecimiento a nivel mundial. De acuerdo con la Organización Mundial de la Salud, la discapacidad y la mortalidad asociadas a esta enfermedad han aumentado a un ritmo más acelerado que las de otros trastornos neurológicos, y su prevalencia se ha duplicado durante los últimos 25 años [1]. Se trata de una condición degenerativa del sistema nervioso caracterizada principalmente por manifestaciones motoras como bradicinesia, temblor, rigidez y alteraciones de la marcha y el equilibrio. Su expresión clínica trasciende el compromiso motor, ya que involucra también síntomas neuropsiquiátricos, autonómicos, del sueño, sensoriales y cognitivos, que deterioran de forma progresiva la autonomía, el funcionamiento cotidiano y la calidad de vida de los pacientes [2], [3].

La identificación temprana y precisa de los patrones asociados a la enfermedad constituye uno de los principales retos de su abordaje clínico. El diagnóstico continúa sustentándose en la evaluación clínica, pero las manifestaciones motoras y no motoras se presentan de forma heterogénea, evolucionan a ritmos distintos entre pacientes y se solapan con otros trastornos neurológicos o formas de parkinsonismo [4]. Esa variabilidad dificulta la caracterización temprana de los cambios neurofisiológicos y motiva la búsqueda de herramientas complementarias que apoyen el análisis, la clasificación y el seguimiento de la enfermedad.

El electroencefalograma (EEG) ofrece en ese contexto una alternativa no invasiva, de bajo costo y alta resolución temporal para el estudio de la actividad cerebral [5]. Su capacidad para registrar la actividad eléctrica cortical lo convierte en una herramienta prometedora para explorar biomarcadores neurofisiológicos asociados a trastornos neurodegenerativos [6]. Su aplicación en la EP exige, sin embargo, abordajes metodológicos rigurosos, dada la naturaleza no estacionaria de la señal, su alta dimensionalidad, la presencia de artefactos y ruido, y la variabilidad intra e intersujeto [7].

Los enfoques convencionales de clasificación a partir del EEG resumen la señal en un conjunto de características escalares, como la potencia en bandas de frecuencia predefinidas o distintas medidas de entropía [5]. Ese procedimiento facilita el análisis, pero reduce el espectro completo a unos pocos valores y obliga a decidir de antemano qué medir, con lo que puede dejar fuera información relevante. La forma detallada del espectro de potencia, más allá de la potencia agregada en cada banda, contiene rasgos asociados a la organización funcional del EEG que resultan pertinentes para diferenciar entre personas sanas y pacientes con EP, y que las características escalares tradicionales no capturan de manera adecuada [6], [8].

Esta investigación aborda esa limitación integrando el Análisis de Datos Funcionales (ADF) con modelos de aprendizaje profundo (*Deep Learning*, DL). Frente a los enfoques tradicionales, que representan la señal EEG como un vector de características resumidas, el ADF modela el espectro de potencia como una función continua [9] y conserva así la forma completa del espectro y su suavidad, donde se expresan los biomarcadores de la enfermedad.

Las representaciones funcionales obtenidas se emplean como entrada de distintos modelos de clasificación, incluidas arquitecturas de aprendizaje profundo, capaces de aprender relaciones no lineales a partir de datos de alta dimensión [10]. El estudio se realiza sobre una cohorte pública de tamaño reducido, cuarenta y ocho sujetos tras el preprocesamiento. Esa escala condiciona el tipo de modelos que pueden entrenarse y la lectura de sus resultados, y se tiene presente a lo largo de todo el trabajo. El propósito no se centra en obtener el mejor desempeño de clasificación, sino en evaluar el aporte de la representación funcional del EEG y su viabilidad como entrada de modelos de clasificación mediante aprendizaje profundo, como parte de una exploración reproducible de los biomarcadores neurofisiológicos asociados a la enfermedad de Parkinson.

1. PLANTEAMIENTO DEL PROBLEMA

1.1 DESCRIPCIÓN DEL PROBLEMA

La enfermedad de Parkinson (EP) es un trastorno neurodegenerativo cuya prevalencia mundial ha mostrado un crecimiento acelerado en las últimas décadas [11]. Fisiológicamente se manifiesta como la pérdida progresiva de las neuronas dopaminérgicas de la sustancia negra, lo que deteriora el sistema motor y se expresa clínicamente en temblor, rigidez y bradicinesia [12].

Pese a conocerse su origen y su sintomatología, el diagnóstico de la EP sigue siendo un desafío. La ausencia de biomarcadores definitivos hace que el proceso dependa casi exclusivamente de la evaluación clínica de los síntomas, con la subjetividad que ello implica. A esto se suma la marcada heterogeneidad de la enfermedad, ya que los síntomas varían entre pacientes y su progresión resulta a menudo impredecible. La combinación de ambos factores conduce con frecuencia a diagnósticos tardíos o erróneos, que retrasan el inicio del tratamiento y afectan el pronóstico [13].

El electroencefalograma (EEG) se ha investigado como apoyo a ese diagnóstico, por su capacidad para registrar la actividad eléctrica cortical de manera no invasiva y a un costo menor que otras técnicas de neuroimagen. Su utilidad clínica encuentra, sin embargo, dos obstáculos. El primero es la baja relación señal-ruido y la contaminación por artefactos. El segundo es la práctica convencional de resumir la señal en unas pocas características escalares, como la potencia media por banda, que descarta buena parte de la forma del espectro, donde residen biomarcadores característicos de la enfermedad como el enlentecimiento de la actividad espectral, caracterizado por la reducción de la frecuencia dominante y el aumento de potencia en las bandas lentas [6], [8], [14].

Esta investigación aborda esa pérdida de información mediante el Análisis de Datos Funcionales (ADF), que modela el espectro del EEG como una función continua en lugar de reducirlo a unos pocos valores [9], [15]. El enfoque preserva la forma completa de la señal, donde se expresan los biomarcadores de la enfermedad. Sobre esa representación funcional se emplean modelos de aprendizaje profundo (*Deep Learning*, DL) para la clasificación entre pacientes con EP y personas sanas, dada su capacidad para identificar relaciones no lineales en datos de alta dimensión [10]. El problema que se plantea es determinar si una representación fiel a la forma de la señal aporta información que las características escalares clásicas no recogen.

1.2 FORMULACIÓN DEL PROBLEMA

A partir de lo anterior, la pregunta de investigación que orienta este trabajo es la siguiente:

¿En qué medida el Análisis de Datos Funcionales aporta información relevante para clasificar pacientes con enfermedad de Parkinson frente a personas sanas, a partir de señales EEG y empleando modelos de clasificación basados en Deep Learning?

1.3 OBJETIVOS

1.3.1 Objetivo general

Desarrollar un modelo de Deep Learning basado en Análisis de Datos Funcionales (ADF) para la clasificación de pacientes con la enfermedad de Parkinson usando señales de EEG.

1.3.2 Objetivos específicos

- Caracterizar las señales de EEG asociadas a la enfermedad de Parkinson para identificar patrones relevantes en su clasificación.

- Construir los datos funcionales a partir de las señales EEG para la integración en el modelo de Deep Learning.

- Desarrollar un modelo de Deep Learning integrando Análisis de Datos Funcionales para clasificar pacientes con EP a partir de señales EEG.

- Evaluar el desempeño del modelo propuesto en términos de su capacidad para clasificar correctamente entre pacientes con Enfermedad de Parkinson y personas sanas.

1.4 JUSTIFICACIÓN

La prevalencia de la enfermedad de Parkinson (EP) crece de forma sostenida [11] y su diagnóstico temprano sigue siendo un desafío, lo que motiva el desarrollo de herramientas de apoyo clínico. El electroencefalograma (EEG) ofrece una vía accesible y no invasiva para esa tarea, pero su potencial se ha visto limitado por la forma en que habitualmente se procesa la señal. Los enfoques tradicionales la resumen en unas pocas características

escalares, como la potencia media por banda de frecuencia, y descartan con ello buena parte de la forma del espectro, que es donde residen algunos de los biomarcadores más informativos de la EP, como el enlentecimiento de la actividad espectral y la redistribución de potencia hacia las bandas lentas [6], [8].

El aprendizaje profundo (*Deep Learning*, DL) se ha explorado ampliamente para superar esas limitaciones [5], [16], [17], [18]. Estos trabajos, sin embargo, suelen apoyarse en representaciones que no consideran la naturaleza continua del dato, ya sea extrayendo características espectrales estáticas o transformando la señal en imágenes de tiempo-frecuencia [19]. Aplicar modelos computacionales a señales inherentemente continuas tratando cada punto como una variable independiente introduce además problemas de alta dimensionalidad y colinealidad que dificultan el aprendizaje [15], [20].

El Análisis de Datos Funcionales (ADF) ofrece un marco adecuado para abordar esa limitación, ya que permite modelar las señales de EEG, o las características derivadas de ellas, como funciones continuas. Al representar la señal por su forma completa en lugar de por puntos o promedios aislados, el ADF preserva la morfología en la que se expresan los biomarcadores de la enfermedad y, mediante técnicas como el análisis de componentes principales funcionales, produce una descripción de dimensión reducida que mitiga los problemas de alta dimensionalidad y colinealidad [15].

Esta investigación aborda una vía escasamente explorada, el uso de representaciones funcionales de la señal EEG como entrada de modelos de clasificación, incluidos modelos de aprendizaje profundo, para distinguir entre pacientes con EP y personas sanas. Trabajos previos han demostrado el valor del ADF para el análisis estadístico de la señal [8], pero su empleo como representación de entrada para la clasificación automática cuenta con antecedentes limitados. La hipótesis que motiva el trabajo es que una representación fiel a la forma del espectro puede aportar información que las características escalares clásicas no recogen, de modo que su contribución se plantea en términos de la calidad, la interpretabilidad y la dimensión reducida de la representación.

1.5 ALCANCE Y DELIMITACIONES

Este trabajo se plantea como una exploración de biomarcadores neurofisiológicos y de la viabilidad de una representación funcional del EEG para distinguir entre pacientes con enfermedad de Parkinson y personas sanas. No constituye una herramienta de diagnóstico, ya que la clasificación obtenida es de carácter experimental y no sustituye la valoración clínica.

El estudio se realiza sobre una única cohorte pública, de tamaño reducido, registrada en reposo con ojos cerrados y con los pacientes retirados de la medicación (estado OFF),

por lo que quedan fuera de su alcance la generalización a otras poblaciones o protocolos y la comparación entre estados de medicación. Las variables clínicas utilizadas en este trabajo se limitaron al grupo de estudio y al estado de medicación, por lo que no se evaluó la relación entre las representaciones funcionales y la severidad clínica de la enfermedad.

El análisis se delimitó a la información espectral del EEG, evaluada mediante una línea base basada en características espectrales escalares y dos representaciones funcionales. Estas estrategias se orientaron a explorar patrones asociados al enlentecimiento espectral descrito en la enfermedad de Parkinson. En consecuencia, quedaron fuera del modelado otras propiedades de la señal, como la forma de onda en el dominio temporal y la conectividad entre regiones.

2. MARCO REFERENCIAL

2.1 MARCO TEÓRICO

Este capítulo reúne los fundamentos conceptuales necesarios para abordar la clasificación de la enfermedad de Parkinson a partir de señales EEG. Se parte de la descripción de la enfermedad y de su diagnóstico, se presenta el electroencefalograma como fuente de biomarcadores, se introduce el análisis de datos funcionales como marco para representar la señal, y finalmente se exponen las redes neuronales y su extensión al caso funcional, que articula la propuesta de este trabajo.

2.1.1 La enfermedad de Parkinson

La enfermedad de Parkinson (EP) es un trastorno neurodegenerativo crónico y progresivo, caracterizado por la pérdida gradual de las neuronas dopaminérgicas de la sustancia negra del mesencéfalo [12]. Estas neuronas forman parte de los ganglios basales, un conjunto de estructuras subcorticales que regulan el control motor; su degeneración interrumpe la comunicación en los circuitos que conectan los ganglios basales con la corteza y el tálamo, lo que da origen a las manifestaciones clínicas de la enfermedad [21].

Los síntomas de la EP se agrupan en dos grandes categorías. Los síntomas motores, que son los más reconocibles, incluyen el temblor en reposo, la lentitud de movimientos o bradicinesia y la rigidez muscular. Junto a ellos, y con frecuencia menos visibles, aparecen síntomas no motores como el deterioro cognitivo, las alteraciones del estado de ánimo, los trastornos del sueño y las disfunciones autonómicas, que afectan de forma importante la calidad de vida y pueden incluso preceder a los síntomas motores [2], [13]. Esta diversidad de manifestaciones, junto con su variabilidad entre pacientes, refleja la heterogeneidad de la enfermedad.

Un aspecto relevante de la EP es que su desarrollo comienza mucho antes del diagnóstico. Los síntomas motores que permiten el diagnóstico clínico aparecen cuando la pérdida de neuronas dopaminérgicas de la sustancia negra ya está avanzada, de modo que la neurodegeneración lleva años en curso. Durante esa fase prodrómica, previa a los síntomas motores, se manifiestan síntomas no motores como la hiposmia (pérdida del olfato), el trastorno de conducta del sueño REM, el estreñimiento y la depresión, que pueden preceder al diagnóstico por varios años [2], [3]. Esta larga fase preclínica es una de las razones por las que la detección temprana de la EP resulta compleja.

El diagnóstico de la EP constituye un reto, pues no existe una prueba que la confirme de manera definitiva, y el diagnóstico clínico basado en los signos motores tiene una

precisión limitada, en especial en las etapas tempranas [4], [13]. En la práctica, el diagnóstico es fundamentalmente clínico y se basa en la identificación de los signos motores cardinales. Como apoyo, se emplean distintas técnicas de neuroimagen. La resonancia magnética estructural permite descartar otras causas, como tumores o infartos. La tomografía computarizada por emisión de fotón único (SPECT) con trazadores que se unen al transportador de dopamina, entre ellos el ioflupano marcado con yodo-123, conocido comercialmente como DaTscan, cuantifica la integridad de las terminales dopaminérgicas del estriado [22], [23]. La tomografía por emisión de positrones (PET) con fluorodopa mide la capacidad de síntesis y almacenamiento de dopamina, si bien su uso es principalmente de investigación [22]. Estas técnicas requieren una infraestructura compleja y costosa, y dependen de la disponibilidad de radiotrazadores [23], mientras que el electroencefalograma destaca por su carácter no invasivo y su bajo costo comparado con la neuroimagen [5], lo que lo convierte en una vía accesible para explorar biomarcadores de la enfermedad a partir del registro de la actividad eléctrica cortical.

2.1.2 Electroencefalografía

El electroencefalograma (EEG) registra la actividad eléctrica de la corteza cerebral mediante electrodos dispuestos sobre el cuero cabelludo. La señal que captan estos electrodos es el resultado de la suma de millones de potenciales postsinápticos generados de forma sincronizada por poblaciones de neuronas corticales, y se mide como la diferencia de potencial entre cada electrodo y una referencia. La disposición de los electrodos suele seguir el sistema internacional 10-20, que los ubica en proporciones fijas respecto a puntos de referencia anatómicos del cráneo, lo que permite comparar registros entre sujetos y estudios [7].

La señal de EEG es de naturaleza no estacionaria, de alta dimensionalidad y baja relación señal-ruido, lo que condiciona su análisis. Puede estudiarse desde distintas perspectivas: en el dominio del tiempo, analizando la forma de onda; en el dominio espacial, considerando la distribución de la actividad entre electrodos; y en el dominio de la frecuencia o de tiempo-frecuencia, mediante herramientas como la transformada de Fourier o la transformada wavelet [7]. Algunos enfoques recientes incluso transforman la señal en imágenes, como espectrogramas, para aplicar sobre ellas técnicas de visión por computador [19].

La actividad del EEG se organiza en bandas de frecuencia asociadas a distintos ritmos cerebrales y estados funcionales: delta (por debajo de $4\,\mathrm{Hz}$), ligada al sueño profundo; theta ($4\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$); alfa ($8\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$), asociada a la relajación y dominante en reposo con ojos cerrados; beta ($13\,\mathrm{Hz}$ a $30\,\mathrm{Hz}$), relacionada con la alerta y la actividad cognitiva; y gamma (por encima de $30\,\mathrm{Hz}$) [7]. El análisis por bandas es central en el estudio del EEG, pues muchas alteraciones neurológicas se expresan como cambios en la distribución de la potencia entre ellas.

Para cuantificar esa distribución se utiliza la densidad espectral de potencia (PSD), que describe cómo se distribuye la potencia de la señal a lo largo de las frecuencias. Su estimación se basa en el análisis de la señal en el dominio de la frecuencia, habitualmente mediante la transformada de Fourier, bajo el principio de que una señal compleja puede descomponerse en componentes sinusoidales [7]. El análisis de la PSD permite caracterizar los ritmos cerebrales y estudiar alteraciones en su distribución espectral asociadas con distintas condiciones neurológicas, entre ellas la enfermedad de Parkinson [6], [8].

2.1.3 Análisis de datos funcionales

El análisis de datos funcionales (ADF) es un marco estadístico que toma como unidad de análisis la función completa, normalmente una curva definida sobre un dominio continuo, y no el vector de observaciones discretas con que se la muestrea [9]. Aunque el registro se obtenga en instantes discretos, el ADF parte de que el fenómeno subyacente es una función suave, lo que permite aprovechar su forma, su suavidad y sus derivadas como fuentes de información. Trabajar con estos objetos requiere un conjunto propio de definiciones y herramientas, que se exponen a continuación [24].

2.1.3.1 El dato funcional y su espacio

Sea $\mathcal{T} = [a, b] \subset \mathbb{R}$ un intervalo compacto. Una *variable funcional* es una variable aleatoria X que toma valores en un espacio de dimensión infinita cuyos elementos son funciones definidas sobre $\mathcal{T}$, y cada realización x de X se denomina *dato funcional* [24]. La diferencia con el caso multivariante clásico no es de tamaño sino de naturaleza, porque el objeto observado no es una lista de valores sino la función que los genera.

En la práctica esa función no se observa de forma continua, ya que el registro solo proporciona sus valores sobre una malla discreta de J puntos $t_1, \ldots, t_J \in \mathcal{T}$, y por lo general con ruido de medición [15]:

$$y_j = x(t_j) + \varepsilon_j, \qquad j = 1, \ldots, J, \tag{2.1}$$

donde x es la función suave subyacente y los ε_j son términos de error independientes de media cero. Recuperar x a partir de $\{y_j\}$ es el primer problema que el ADF debe resolver.

Para trabajar con estas funciones hace falta un espacio que permita medir distancias y proyectar. Entre los espacios funcionales más habituales están $\mathcal{C}(\mathcal{T})$, formado por las funciones continuas con valores reales sobre $\mathcal{T}$; $L^1(\mathcal{T})$, formado por aquellas cuyo valor absoluto es integrable; y $L^2(\mathcal{T})$, el de las funciones de cuadrado integrable, que es el espacio en el que habitualmente se formula el ADF y se define como

$$L^2(\mathcal{T}) = \left\{ f : \mathcal{T} \to \mathbb{R} \;\middle|\; \int_{\mathcal{T}} f^2(t)\, dt < \infty \right\}. \tag{2.2}$$

Este espacio está dotado del producto interno

$$\langle f, g \rangle = \int_{\mathcal{T}} f(t)\, g(t)\, dt, \tag{2.3}$$

que induce la norma $\|f\|_{L^2} = \sqrt{\langle f, f \rangle}$ y la distancia

$$d_{L^2}(f, g) = \|f - g\|_{L^2} = \left(\int_{\mathcal{T}} \big(f(t) - g(t)\big)^2 dt \right)^{1/2}. \tag{2.4}$$

Además, $L^2(\mathcal{T})$ es un espacio completo, lo que significa que toda sucesión de Cauchy converge a un elemento del propio espacio. Un espacio con producto interno que además es completo se denomina espacio de Hilbert, y ese es el caso de $L^2(\mathcal{T})$ [24].

El producto interno le da al espacio una geometría, con nociones de ángulo, ortogonalidad y proyección, y es lo que permite descomponer una función en componentes y medir cuánto se parece a otra. La completitud, por su parte, garantiza que las aproximaciones sucesivas de una función converjan a un elemento del propio espacio, y es también la condición que permite descomponer el operador de covarianza en el análisis de componentes principales funcionales.

La distancia de la Ecuación (2.4) está definida entre funciones, no entre los coeficientes con que se las representa. Ambas nociones coinciden únicamente cuando la base es ortonormal, ya que en ese caso la distancia euclidiana entre vectores de coeficientes reproduce la distancia L^2 entre las curvas correspondientes, mientras que con una base no ortonormal las dos geometrías difieren [9].

Una representación discretizada de una señal conserva el orden natural de los puntos del dominio en el que fue observada. Sin embargo, cuando estos valores se utilizan directamente como un vector de características en modelos multivariantes, la continuidad del fenómeno y la relación funcional entre puntos vecinos no quedan incorporadas explícitamente en la representación. Además, en señales densamente muestreadas, los valores correspondientes a posiciones próximas del dominio suelen presentar una elevada dependencia, lo que puede generar redundancia y colinealidad y aumentar la dimensionalidad del problema sin un incremento equivalente de la información efectiva, una situación especialmente relevante cuando el número de observaciones es pequeño frente a la dimensión [20].

El ADF aborda esta situación considerando la curva completa como la unidad de análisis y representándola como un elemento de $L^2(\mathcal{T})$. De esta forma, las observaciones discretas se interpretan como muestras de una función subyacente y pueden describirse mediante un número finito de coeficientes de base. Esta representación incorpora explícitamente la estructura del dominio y permite trabajar con propiedades funcionales como la continuidad, la suavidad y la geometría del espacio $L^2(\mathcal{T})$ [9], [15].

2.1.3.2 Representación en bases de funciones

Como la función x se observa de forma discreta según la Ecuación (2.1), el primer paso del ADF consiste en reconstruirla a partir de esas observaciones, y el procedimiento habitual la expresa como combinación lineal de un conjunto de funciones conocidas. Un sistema de funciones $\{\phi_k\}_{k\in\mathbb{N}}$ definidas sobre $\mathcal{T}$ es una base cuando toda función del espacio se puede aproximar con la precisión que se quiera mediante una combinación lineal finita de sus primeros K elementos, tomando K suficientemente grande [9], [24].

La representación de un dato funcional en una base de dimensión K toma entonces la forma

$$x(t) \approx \sum_{k=1}^{K} c_k \, \phi_k(t), \tag{2.5}$$

donde los coeficientes c_k ponderan la contribución de cada función base [9]. Lo que hace la Ecuación (2.5) es trasladar el problema de un espacio de dimensión infinita a uno de dimensión K, porque una vez fijada la base el dato funcional queda descrito por el vector $\mathbf{c} = (c_1, \ldots, c_K)^\top$. La familia de funciones base y su dimensión K condicionan por completo la representación resultante.

La elección de la familia depende de las características de la función que se quiere representar, y en el ADF se emplean habitualmente cuatro tipos. Las bases de Fourier son la opción natural para funciones periódicas, los B-splines para curvas no periódicas con variaciones suaves, las bases wavelet para funciones con transitorios o cambios abruptos, y las bases con restricción para casos en los que la función debe cumplir alguna condición, como la positividad [9], [24]. A continuación se describe cada una.

Base de Fourier. La expansión de Fourier de $x(t)$ tiene la forma $x(t) = c_0\phi_0(t) + \sum_r [c_{2r-1}\phi_{2r-1}(t) + c_{2r}\phi_{2r}(t)]$, con

$$\phi_0(t) = \frac{1}{\sqrt{P}}, \qquad \phi_{2r-1}(t) = \frac{\operatorname{sen}(r\omega t)}{\sqrt{P/2}}, \qquad \phi_{2r}(t) = \frac{\cos(r\omega t)}{\sqrt{P/2}}, \tag{2.6}$$

que forman una base ortonormal periódica de período $P = 2\pi/\omega$. Su ortonormalidad preserva la geometría de $L^2(\mathcal{T})$, y al estar compuesta por senos y cosenos permite derivar la expansión en cualquier orden con facilidad. Su limitación es estructural, porque la periodicidad la hace adecuada para señales que también lo son y para funciones estables de curvatura aproximadamente constante, pero poco apropiada cuando la curva presenta rasgos localizados o discontinuidades [9].

Base de B-splines. Un spline se construye dividiendo el intervalo $\mathcal{T} = [a, b]$ en L subintervalos separados por los nudos $a = \tau_0 < \tau_1 < \cdots < \tau_L = b$. En cada subintervalo el

spline es un polinomio de orden m, es decir, de grado $m-1$, y los polinomios contiguos coinciden en los nudos hasta la derivada de orden $m-2$, lo que garantiza uniones suaves. Con estas restricciones, el número de funciones base que resulta es

$$K = m + L - 1. \tag{2.7}$$

Si $B_k(t, \boldsymbol{\tau})$ denota el k-ésimo elemento de la base sobre la partición $\boldsymbol{\tau}$, la función spline se escribe

$$S(t) = \sum_{k=1}^{m+L-1} c_k \, B_k(t, \boldsymbol{\tau}). \tag{2.8}$$

Hay tres propiedades que hacen a los B-splines adecuados para curvas no periódicas: cada elemento de la base es una función spline de orden m sobre la partición $\boldsymbol{\tau}$, toda combinación lineal de funciones spline es de nuevo una función spline, y toda función spline de orden m sobre esa partición se puede expresar como combinación lineal de la base [9], [25]. A ello se suma el soporte local, ya que cada B_k es distinta de cero solo en un intervalo reducido, de manera que un coeficiente afecta únicamente a una región de la curva y no propaga oscilaciones espurias a lo largo del dominio, como sí ocurre con las bases globales. La contrapartida es que la base pierde la ortonormalidad, de modo que la distancia euclidiana entre coeficientes deja de coincidir con la distancia L^2 entre las curvas.

Bases wavelet. Las bases wavelet representan una función mediante traslaciones y dilataciones de una función generadora ψ, llamada wavelet madre, de la forma $\psi_{j,k}(t) = 2^{j/2}\,\psi(2^j t - k)$ con j, k enteros. Fijada una escala $j = J_0$, la expansión de f se descompone en una parte de aproximación y otra de detalle,

$$f(t) = \sum_k c_{J_0,k}\,\phi_{J_0,k}(t) + \sum_{j \geq J_0} \sum_k d_{j,k}\,\psi_{j,k}(t), \tag{2.9}$$

con coeficientes $c_{J_0,k} = \langle f, \phi_{J_0,k} \rangle$ y $d_{j,k} = \langle f, \psi_{j,k} \rangle$ [9]. Que describan la función a la vez en tiempo y en escala las hace especialmente indicadas cuando la señal presenta transitorios o discontinuidades, y explica su uso extendido en el procesamiento de señales biomédicas.

Bases con restricción. Cuando el fenómeno impone condiciones sobre la función estimada, la representación se puede formular de modo que las cumpla por construcción. Para una función estrictamente positiva se emplea

$$x(t) = e^{W(t)}, \tag{2.10}$$

donde W se expande en una base de Fourier o de B-splines sin restricciones [9]. Una construcción análoga sobre la derivada, $Dx(t) = e^{W(t)}$, produce por integración una función monótona creciente. Estas bases resultan pertinentes cuando la magnitud representada no admite valores negativos, como ocurre con densidades, concentraciones o medidas de potencia.

La elección de la familia de bases depende de las características del fenómeno representado. Las bases wavelet resultan especialmente útiles cuando se busca representar cambios localizados o transitorios, mientras que las restricciones de positividad son pertinentes cuando la función modelada debe permanecer no negativa en todo su dominio. En representaciones sometidas a transformaciones que llevan la variable a una escala real no restringida, esta última condición puede dejar de ser necesaria.

2.1.3.3 Estimación de los coeficientes y selección de la dimensión

Una vez fijadas la base y su dimensión K, los coeficientes se estiman ajustando la Ecuación (2.5) a las observaciones discretas. Sea $\mathbf{\Phi}$ la matriz de evaluación de dimensión $J \times K$, con elementos $\Phi_{jk} = \phi_k(t_j)$, y sea $\mathbf{y} = (y_1, \ldots, y_J)^\top$ el vector de valores observados. El criterio de mínimos cuadrados ordinarios minimiza

$$\mathrm{SSE}(\mathbf{c}) = \sum_{j=1}^{J} \left[y_j - \sum_{k=1}^{K} c_k \phi_k(t_j) \right]^2 = (\mathbf{y} - \mathbf{\Phi c})^\top (\mathbf{y} - \mathbf{\Phi c}), \tag{2.11}$$

y su solución es

$$\hat{\mathbf{c}} = \left(\mathbf{\Phi}^\top \mathbf{\Phi} \right)^{-1} \mathbf{\Phi}^\top \mathbf{y}. \tag{2.12}$$

Los valores ajustados quedan entonces como $\hat{\mathbf{y}} = \mathbf{\Phi}\hat{\mathbf{c}} = \mathbf{\Phi}(\mathbf{\Phi}^\top\mathbf{\Phi})^{-1}\mathbf{\Phi}^\top\mathbf{y} = \mathbf{S}\mathbf{y}$, donde $\mathbf{S}$ es la matriz de proyección del ajuste, análoga a la matriz sombrero de la regresión lineal múltiple [9].

La dimensión K gobierna el equilibrio entre ajuste y suavidad, y funciona como el parámetro de suavizado de la representación. Su efecto se expresa a través del sesgo y la varianza de la estimación,

$$\mathrm{Sesgo}[\hat{x}(t)] = \mathbb{E}[\hat{x}(t)] - x(t), \qquad \mathrm{Var}[\hat{x}(t)] = \mathbb{E}\left[(\hat{x}(t) - \mathbb{E}[\hat{x}(t)])^2 \right]. \tag{2.13}$$

que se combinan en el error cuadrático medio del estimador,

$$\mathrm{ECM}_{\mathrm{est}}[\hat{x}(t)] = \mathrm{Sesgo}^2[\hat{x}(t)] + \mathrm{Var}[\hat{x}(t)]. \tag{2.14}$$

Un valor de K demasiado bajo produce una curva excesivamente suave, con un sesgo elevado que puede pasar por alto rasgos relevantes de la función, mientras que uno demasiado alto reduce el sesgo a costa de ajustar el ruido de la estimación y aumentar la varianza. Lo que indica la Ecuación (2.14) es que conviene tolerar cierto sesgo cuando con ello se reduce apreciablemente la varianza [9].

Para elegir K de forma objetiva se recurre a la validación cruzada. En su versión de dejar uno fuera, cada observación se retira sucesivamente, se ajusta el modelo con las restantes y se predice el valor ausente, y como el ajuste es lineal el criterio se puede

expresar en forma cerrada,

$$\mathrm{VC}(K) = \frac{1}{J}\sum_{j=1}^{J}\left(\frac{y_j - \hat{y}_j}{1 - s_{jj}}\right)^2, \tag{2.15}$$

donde s_{jj} es el j-ésimo elemento diagonal de $\mathbf{S}$, de modo que no hace falta ajustar J modelos [9]. La validación cruzada generalizada (GCV, por sus siglas en inglés) sustituye cada s_{jj} por su valor promedio ν/J, con $\nu = \mathrm{traza}(\mathbf{S})$ los grados de libertad efectivos del ajuste [26]. Denotando por $\mathrm{ECM}_{\text{ajuste}}(K) = \mathrm{SSE}(K)/J$ el error cuadrático medio residual del ajuste, la validación cruzada generalizada puede expresarse como:

$$\mathrm{GCV}(K) = \frac{1}{J}\sum_{j=1}^{J}\left(\frac{y_j - \hat{y}_j}{1 - \nu/J}\right)^2 = \frac{J\ \mathrm{SSE}(K)}{(J-\nu)^2} = \frac{\mathrm{ECM}_{\text{ajuste}}(K)}{(1-\nu/J)^2}. \tag{2.16}$$

Se selecciona el valor de K que minimiza la Ecuación (2.16). La tercera igualdad muestra cómo se lee el criterio, ya que es el error cuadrático medio del ajuste penalizado por su complejidad, de manera que una base más rica solo resulta preferible si su mejora en el ajuste compensa los grados de libertad adicionales que consume.

2.1.3.4 Estadística descriptiva funcional

Una vez representadas las observaciones como funciones, los descriptores estadísticos habituales se extienden de forma directa al caso funcional. Sea $x_1(t), \ldots, x_N(t)$ una muestra de N datos funcionales sobre $\mathcal{T}$. La media funcional es

$$\bar{x}(t) = \frac{1}{N}\sum_{i=1}^{N} x_i(t), \tag{2.17}$$

y la varianza funcional

$$\mathrm{Var}_x(t) = \frac{1}{N-1}\sum_{i=1}^{N}\left(x_i(t) - \bar{x}(t)\right)^2. \tag{2.18}$$

A diferencia del caso escalar, ambas son funciones del dominio, de modo que describen cómo varían el promedio y la dispersión de la muestra a lo largo de $\mathcal{T}$ [9]. La dependencia entre dos puntos del dominio se recoge en la función de covarianza

$$\Sigma(s,t) = \frac{1}{N-1}\sum_{i=1}^{N}\left(x_i(s) - \bar{x}(s)\right)\left(x_i(t) - \bar{x}(t)\right), \qquad s,t \in \mathcal{T}, \tag{2.19}$$

y en su versión normalizada, la correlación funcional,

$$\rho(s,t) = \frac{\Sigma(s,t)}{\sqrt{\mathrm{Var}_x(s)\ \mathrm{Var}_x(t)}}. \tag{2.20}$$

La función de covarianza de la Ecuación (2.19) concentra toda la estructura de variabilidad de la muestra y es el objeto sobre el que se construye el análisis de componentes principales funcionales [25].

2.1.3.5 Análisis de componentes principales funcionales

La representación en una base fija describe cada función mediante K coeficientes, pero esa base se elige de antemano y sus elementos no guardan relación con la forma en que varían las curvas de la muestra. El análisis de componentes principales funcionales (FPCA, por sus siglas en inglés) parte de esa representación y busca, dentro del espacio que la base genera, las direcciones en las que las curvas más difieren entre sí [9]. El resultado es una nueva base, esta vez derivada de los datos, cuyas primeras funciones concentran la mayor parte de la variabilidad y permiten describir cada curva con una dimensión menor.

El punto de partida es la función de covarianza de la Ecuación (2.19), a partir de la cual se define el operador de covarianza Γ, que transforma una función ξ en otra según

$$(\Gamma\xi)(t) = \int_{\mathcal{T}} \Sigma(s,t)\,\xi(s)\,ds. \tag{2.21}$$

Las direcciones de máxima variabilidad se obtienen resolviendo la ecuación de valores propios asociada a este operador, $\Gamma\xi_m = \lambda_m\xi_m$, que escrita de forma explícita es

$$\int_{\mathcal{T}} \Sigma(s,t)\,\xi_m(s)\,ds = \lambda_m\,\xi_m(t), \qquad m = 1, 2, \ldots \tag{2.22}$$

Las soluciones ξ_m se denominan funciones propias o componentes principales funcionales, y los λ_m son sus valores propios, ordenados de forma decreciente $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$. Cada función propia representa un modo de variación de las curvas respecto a la media, y su valor propio mide cuánta variabilidad de la muestra explica ese modo. Las funciones propias forman además un sistema ortonormal,

$$\int_{\mathcal{T}} \xi_m(t)\,\xi_l(t)\,dt = \begin{cases} 1, & m = l, \\ 0, & m \neq l, \end{cases} \tag{2.23}$$

por lo que constituyen una base ortonormal del espacio que generan [15]. La diferencia con las bases de la Sección 2.1.3.2 está en su origen, ya que estas funciones no se fijan de antemano sino que se obtienen de la estructura de covarianza de los datos, y se expresan como combinaciones lineales de las funciones base empleadas en la representación previa. En términos de esta base, la función de covarianza admite la descomposición

$$\Sigma(s,t) = \sum_{m=1}^{\infty} \lambda_m\,\xi_m(s)\,\xi_m(t). \tag{2.24}$$

Sobre esta base, cualquier función de la muestra se expresa mediante la expansión de Karhunen-Loève como su desviación respecto de la media funcional,

$$x(t) = \bar{x}(t) + \sum_{m=1}^{\infty} s_m \, \xi_m(t), \tag{2.25}$$

donde los coeficientes s_m, llamados *scores*, indican en qué medida se expresa cada modo de variación en esa curva concreta. Gracias a la ortonormalidad de las funciones propias, cada score se obtiene proyectando la curva centrada sobre la componente correspondiente,

$$s_m = \langle x - \bar{x},\, \xi_m \rangle = \int_{\mathcal{T}} \big(x(t) - \bar{x}(t)\big)\, \xi_m(t)\, dt. \tag{2.26}$$

Los scores tienen media cero, varianza λ_m y están incorrelados entre sí [15]. Esta última propiedad es la que da su utilidad al método, porque la información de la curva queda repartida entre coeficientes que no se solapan, a diferencia de lo que ocurre con los coeficientes de una base no ortonormal.

En la práctica la suma de la Ecuación (2.25) se trunca en un número finito M de componentes,

$$x(t) \approx \bar{x}(t) + \sum_{m=1}^{M} s_m \, \xi_m(t), \tag{2.27}$$

y esa truncación tiene una propiedad de optimalidad: entre todas las bases de M funciones, la formada por las M primeras funciones propias es la que minimiza el error cuadrático medio de aproximación [15]. Ninguna otra base de la misma dimensión describe mejor el conjunto de curvas. El número de componentes disponibles está acotado por dos factores: la dimensión K de la base sobre la que se construye la FPCA y el tamaño N de la muestra, ya que para N funciones el número de valores propios no nulos es a lo sumo $N - 1$. Se cumple entonces que $M \leq \min\{K,\, N - 1\}$, de modo que la representación previa impone un techo a la reducción que la FPCA puede alcanzar [9].

La elección de M se hace habitualmente mediante el criterio de varianza acumulada, que consiste en retener las primeras componentes hasta alcanzar una proporción α de la variabilidad total,

$$M = \min \left\{ M' : \frac{\sum_{m=1}^{M'} \lambda_m}{\sum_{m=1}^{\infty} \lambda_m} \geq \alpha \right\}, \tag{2.28}$$

con valores de α que suelen situarse entre el 90 % y el 99 % [25]. Como los valores propios decrecen con rapidez en la mayoría de los conjuntos de datos funcionales, unas pocas componentes bastan para recoger la mayor parte de la variabilidad, y la curva completa queda descrita por un vector de M scores. Ese vector es un resumen de baja dimensión de la función, y permite aplicar sobre datos funcionales los métodos desarrollados para datos multivariantes [15].

El ADF ofrece además modelos de regresión y clasificación funcionales, en los que las funciones actúan como predictores o como respuestas. Estos modelos relacionan la forma completa de una curva con una variable de interés, como la pertenencia a un grupo, y son el punto de encuentro entre el ADF y las técnicas de aprendizaje automático [15], [25].

2.1.4 Redes neuronales y datos funcionales

Las redes neuronales artificiales son modelos computacionales que aprenden relaciones no lineales complejas a partir de datos de alta dimensión, lo que las ha convertido en herramientas de referencia en el procesamiento de señales [10]. Su aplicación a datos funcionales plantea, sin embargo, una dificultad de partida, porque estas redes reciben vectores de tamaño fijo mientras que el dato funcional es una curva. Las secciones siguientes recorren primero el fundamento de estos modelos y las familias de arquitecturas más extendidas, y después las que se han desarrollado específicamente para recibir funciones como entrada.

2.1.4.1 Fundamento de las redes neuronales

La unidad básica de una red neuronal es la neurona, que combina linealmente sus entradas y aplica sobre el resultado una función no lineal. Dado un vector de entrada $\mathbf{x} \in \mathbb{R}^p$, un vector de pesos $\mathbf{w}$ y un sesgo b, la salida de la neurona es

$$z = \sigma\left(\mathbf{w}^\top \mathbf{x} + b\right) = \sigma\left(\sum_{i=1}^{p} w_i x_i + b\right), \tag{2.29}$$

donde σ es la función de activación. Sin ella la red se reduciría a una composición de transformaciones lineales, equivalente a una sola, de modo que la no linealidad es lo que permite representar relaciones complejas [27]. Las activaciones más habituales son la unidad lineal rectificada, $\sigma(u) = \max(0, u)$, en las capas intermedias, y la función logística, $\sigma(u) = (1 + e^{-u})^{-1}$, en la capa de salida de un problema de clasificación binaria, donde su recorrido en el intervalo $(0, 1)$ permite interpretar la salida como una probabilidad.

Las neuronas se organizan en capas sucesivas. Si $\mathbf{h}^{(l-1)}$ denota la salida de la capa anterior, la capa l produce

$$\mathbf{h}^{(l)} = \sigma\left(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right), \tag{2.30}$$

con $\mathbf{W}^{(l)}$ la matriz de pesos y $\mathbf{b}^{(l)}$ el vector de sesgos de esa capa. El aprendizaje profundo se refiere al uso de redes con varias capas de este tipo, que aprenden representaciones jerárquicas de los datos, de manera que las primeras capas capturan patrones simples y las posteriores los combinan en descripciones cada vez más abstractas [10], [27]. La Figura 2.1 ilustra esta organización.

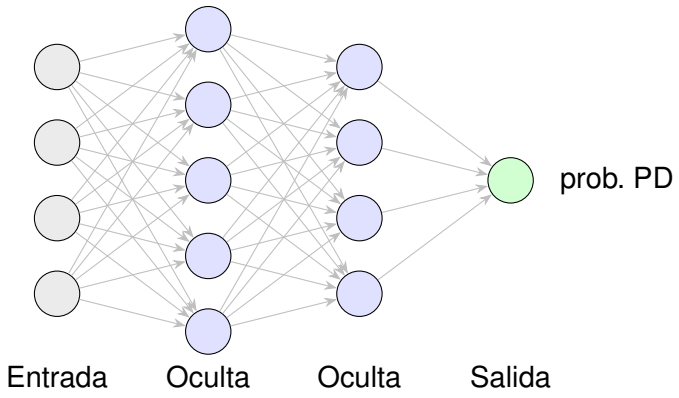


Figura 2.1: Esquema general de una red neuronal profunda tipo *feedforward*. Elaboración propia.

Los parámetros $\mathbf{W}^{(l)}$ y $\mathbf{b}^{(l)}$ se estiman minimizando una función de pérdida sobre los datos de entrenamiento. En clasificación binaria se emplea la entropía cruzada,

$$\mathcal{L} = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\right], \tag{2.31}$$

donde $y_i \in \{0,1\}$ es la etiqueta y $\hat{p}_i$ la probabilidad predicha. La minimización se realiza por descenso de gradiente, y los gradientes respecto a todos los parámetros se calculan mediante retropropagación, que aplica la regla de la cadena recorriendo la red desde la salida hacia la entrada [27].

El número de parámetros de estos modelos crece con rapidez, lo que los expone al sobreajuste cuando la muestra es reducida. Para contenerlo se emplean técnicas de regularización como el *dropout*, que desactiva al azar una fracción de las unidades en cada paso de entrenamiento, la normalización por lotes, que estabiliza la distribución de las activaciones intermedias, y la parada temprana, que interrumpe el entrenamiento cuando el desempeño sobre un conjunto de validación deja de mejorar [27].

2.1.4.2 Arquitecturas de propósito general

Dentro del aprendizaje profundo existen familias de arquitecturas que se distinguen por los supuestos que incorporan sobre la estructura de la entrada. Las tres siguientes son de uso extendido y no presuponen que el dato sea una función.

Perceptrón multicapa. El perceptrón multicapa (MLP) es la arquitectura básica y consiste en una sucesión de capas densas según la Ecuación (2.30), en las que cada unidad se conecta con todas las de la capa anterior. No incorpora ningún supuesto sobre la organización de la entrada, que se trata como un vector plano, de manera que el orden de sus componentes es indiferente para el modelo. Esta generalidad es a la vez su ventaja y su

limitación, porque le permite aplicarse a cualquier tipo de dato pero le impide aprovechar la estructura que ese dato pueda tener [27].

Redes convolucionales. Las redes convolucionales incorporan el supuesto de que la entrada tiene una estructura ordenada, ya sea espacial o secuencial, y de que los patrones relevantes son locales. En lugar de conectar cada unidad con toda la entrada, aplican un filtro de tamaño reducido que se desplaza a lo largo de ella. Para una señal unidimensional x y un filtro w de longitud F, la operación es

$$(x * w)[i] = \sum_{f=1}^{F} x[i + f - 1]\, w[f], \tag{2.32}$$

y el mismo filtro se reutiliza en todas las posiciones. Esta compartición de pesos reduce de forma drástica el número de parámetros frente a una capa densa equivalente y aporta invarianza a la traslación, ya que un patrón se detecta con independencia de dónde aparezca [10]. Tras las convoluciones se suelen aplicar operaciones de agregación, que resumen regiones vecinas y reducen la longitud de la representación. Al encadenar varios bloques de convolución y agregación, las primeras capas detectan patrones locales simples y las siguientes los combinan en descripciones de mayor alcance, hasta que una capa densa produce la salida (Figura 2.2).

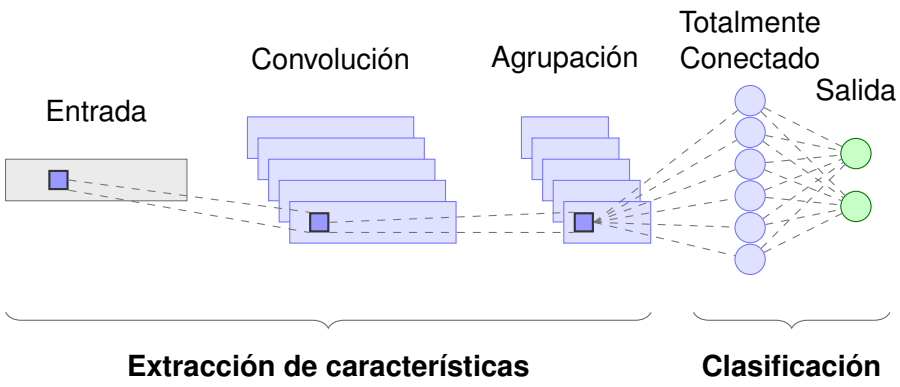


Figura 2.2: Esquema general de una red convolucional unidimensional (CNN1D). Elaboración propia.

Transformer. La arquitectura Transformer sustituye la localidad de la convolución por un mecanismo de atención, que pondera de forma explícita la relación entre todos los elementos de una secuencia [28]. Cada elemento se proyecta en tres representaciones, consulta $\mathbf{Q}$, clave $\mathbf{K}$ y valor $\mathbf{V}$, y la salida se obtiene como

$$\text{Atención}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d_k}}\right)\mathbf{V}, \tag{2.33}$$

donde d_k es la dimensión de las claves y el factor $\sqrt{d_k}$ evita que los productos internos alcancen magnitudes que saturen la función softmax. El resultado es que cada elemento se

representa como una combinación ponderada de todos los demás, con pesos aprendidos que dependen del contenido. La operación se repite en paralelo en varios subespacios, lo que se conoce como atención de múltiples cabezas, y permite recoger distintos tipos de relación de forma simultánea (Figura 2.3). Una propiedad de este mecanismo es que los pesos de atención pueden inspeccionarse para analizar cómo el modelo distribuye la atención entre los elementos de la entrada [28]. No obstante, estos pesos no deben interpretarse por sí solos como una medida definitiva de importancia ni como una explicación causal de la predicción [29].

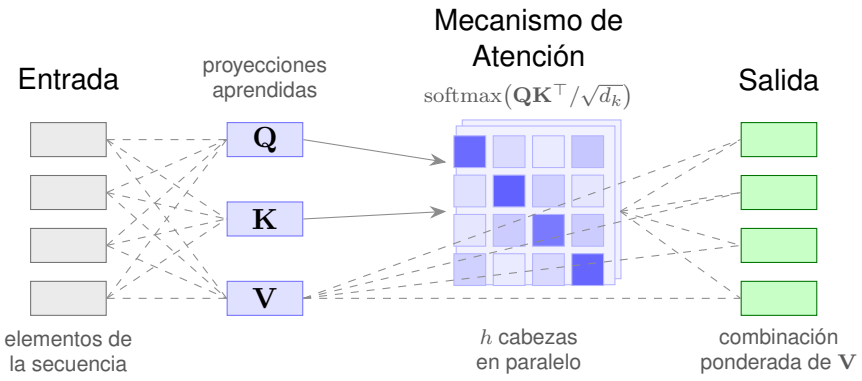


Figura 2.3: Esquema del mecanismo de atención de múltiples cabezas en una arquitectura Transformer. Elaboración propia.

2.1.4.3 Redes neuronales funcionales

Las arquitecturas anteriores reciben vectores, lo que obliga a decidir cómo presentar una curva ante ellas. Existen dos vías para combinar el ADF con las redes neuronales. La primera consiste en emplear la representación funcional, es decir, los coeficientes de la base o los scores de la FPCA, como vector de entrada de una red convencional, de manera que la red opera sobre una descripción compacta de la curva en lugar de sobre la señal cruda. La segunda consiste en reformular la propia red para que reciba funciones, lo que da lugar a las redes neuronales funcionales.

En una red neuronal funcional se modifica la operación de la primera capa. Mientras que la neurona convencional de la Ecuación (2.29) calcula una suma ponderada de entradas escalares, la neurona funcional integra la función de entrada $x(t)$ contra una función de peso $\beta(t)$ a lo largo del dominio,

$$z = \sigma\left(\int_{\mathcal{T}} x(t)\,\beta(t)\,dt + b\right), \tag{2.34}$$

de modo que la contribución de la curva se pondera de forma continua según su forma [30]. La integral de la Ecuación (2.34) es el producto interno de $L^2(\mathcal{T})$ definido en

la Ecuación (2.3), lo que sitúa esta operación dentro del marco funcional. Para hacerla computable, la función de peso se expande a su vez en una base, $\beta(t) = \sum_{k=1}^{K} \gamma_k \phi_k(t)$, con lo que

$$\int_{\mathcal{T}} x(t)\,\beta(t)\,dt = \sum_{k=1}^{K} \gamma_k \int_{\mathcal{T}} x(t)\,\phi_k(t)\,dt, \tag{2.35}$$

y el problema se reduce a estimar los coeficientes γ_k, un número finito de parámetros que se aprenden con los métodos habituales (Figura 2.4).

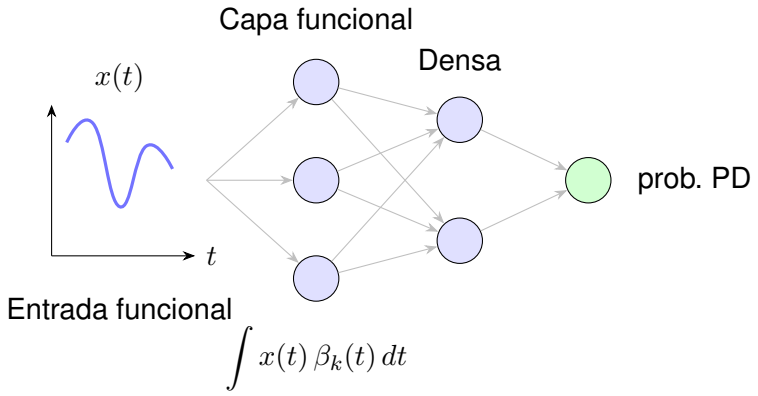


Figura 2.4: Esquema conceptual de una red neuronal funcional. Elaboración propia.

Un rasgo distintivo de estas redes es su interpretabilidad. Como las funciones de peso aprendidas están definidas sobre el mismo dominio que los datos, pueden representarse gráficamente e indican qué regiones de la curva resultan más influyentes para la predicción [31], una transparencia de la que carecen las redes que operan sobre vectores sin estructura.

Sobre esta idea, planteada inicialmente para redes de una sola capa funcional, se han desarrollado arquitecturas de mayor profundidad.

Red neuronal funcional. La red neuronal funcional (FNN) combina una capa funcional como la de la Ecuación (2.35) con capas densas convencionales, y fue formulada para tareas de clasificación con covariables funcionales [32].

Red densa profunda con entradas funcionales. La red densa profunda con entradas funcionales (FDNN) extiende el planteamiento anterior a redes densamente conectadas capaces de integrar de forma conjunta covariables funcionales y escalares, conservando la interpretabilidad de las funciones de peso estimadas [31].

Red con bases adaptativas. La arquitectura de bases adaptativas (AdaFNN) prescinde de una base fijada de antemano y aprende sus propias funciones base como parte del entrenamiento, mediante una capa cuyos parámetros definen las funciones sobre las que

se proyecta la curva de entrada [33]. De este modo la representación se ajusta a la tarea de clasificación en lugar de determinarse en un paso previo e independiente.

2.1.4.4 Arquitecturas específicas para EEG

Junto a las familias anteriores se han propuesto arquitecturas diseñadas para las particularidades de una señal concreta. En el caso del EEG, la referencia más extendida es EEGNet, una red convolucional compacta concebida originalmente para interfaces cerebro-computador [34]. Su diseño encadena tres tipos de convolución con propósitos distintos: una convolución temporal que actúa como un banco de filtros en frecuencia, una convolución *depthwise* que opera sobre el eje de los canales y aprende combinaciones espaciales, y una convolución separable que combina ambas dimensiones con un número reducido de parámetros. Esa economía de parámetros es su rasgo definitorio, ya que la hace entrenable con conjuntos de datos pequeños, una situación habitual en los estudios de EEG.

2.2 ANTECEDENTES

La clasificación automática de la enfermedad de Parkinson a partir de señales EEG ha recibido una atención creciente en la última década, impulsada por la búsqueda de biomarcadores neurofisiológicos que apoyen un diagnóstico más temprano y objetivo. Las revisiones sistemáticas del área coinciden en que el aprendizaje automático aplicado al EEG constituye una vía prometedora, si bien señalan una notable heterogeneidad en los conjuntos de datos, los métodos de validación y las representaciones empleadas, lo que dificulta la comparación directa entre trabajos [5]. Esta sección organiza los antecedentes en tres frentes: el primero reúne los trabajos que clasifican la enfermedad de Parkinson a partir de EEG mediante aprendizaje automático clásico, que representan la práctica más extendida y sirven de referencia a este trabajo; el segundo recoge las investigaciones que abordan esa misma tarea con aprendizaje profundo; y el tercero revisa el análisis de datos funcionales como representación para la clasificación de señales, que ha resultado eficaz en distintos dominios, incluidos problemas ajenos a la enfermedad de Parkinson. A estos frentes se suma una revisión de los trabajos que emplearon registros de la misma cohorte de la Universidad de Nuevo México analizada aquí, que ofrece la referencia más directa para valorar los resultados obtenidos. Del contraste entre estos antecedentes surge la oportunidad de investigación que este trabajo aborda.

2.2.1 Enfoques basados en aprendizaje automático clásico

Una primera línea de trabajo extrae características a partir de la señal EEG y las clasifica con modelos de aprendizaje automático tradicionales para distinguir a los pacientes con enfermedad de Parkinson de las personas sanas. Las características suelen derivarse

del contenido espectral, de medidas de entropía, de la descomposición wavelet o de la complejidad no lineal de la señal, y se combinan con clasificadores como máquinas de soporte vectorial, bosques aleatorios o k-vecinos más cercanos. A partir de registros de EEG, Anjum et al. [35] mostraron que características derivadas de la codificación predictiva lineal permiten distinguir los rasgos espectrales asociados a la enfermedad. La descomposición wavelet ha resultado especialmente productiva: sobre EEG de pacientes con Parkinson y controles, Khare et al. [36] emplearon la transformada wavelet de factor Q sintonizable para extraer características estadísticas de las subbandas, y Aljalal et al. [37] combinaron la transformada wavelet discreta con distintas medidas de entropía. En una línea afín, y también sobre EEG de reposo para separar pacientes de controles, Aljalal et al. [38] propusieron un enfoque basado en patrones espaciales comunes combinados con medidas de entropía, y Belyaev et al. [39] mostraron que las medidas de entropía, en particular la entropía difusa, permiten un diagnóstico rápido de la enfermedad. Igualmente sobre EEG de reposo, Yang y Huang [40] compararon una máquina de soporte vectorial con redes convolucionales, alimentadas con características espectrales, de coherencia y de entropía o con la señal cruda, y analizaron qué bandas y regiones presentan diferencias entre pacientes y controles. Este tipo de enfoque, basado en características del EEG y modelos clásicos, no se limita al Parkinson: también se ha aplicado a la detección de otras enfermedades neurodegenerativas, como la enfermedad de Alzheimer [41].

Ninguno de estos estudios representa la señal como un dato funcional. Todos resumen el espectro en un conjunto de características escalares, como la potencia media por banda o distintas medidas de entropía, con las que alimentan modelos de aprendizaje automático clásico. Esta representación aporta interpretabilidad y funciona con conjuntos de datos reducidos, pero al condensar la señal en unos pocos valores no conserva la forma completa del espectro, en la que reside parte de la información que distingue a los grupos y que este trabajo busca preservar.

2.2.2 Enfoques basados en aprendizaje profundo

El aprendizaje profundo se ha aplicado ampliamente a la clasificación de EEG en la enfermedad de Parkinson, con modelos que aprenden las representaciones directamente de los datos en lugar de depender de características diseñadas manualmente. Un primer grupo aplica redes convolucionales directamente sobre la señal. Sobre EEG de pacientes con Parkinson y controles, Oh et al. [42] propusieron una red convolucional de trece capas aplicada a la señal, alcanzando una exactitud del 88,25 %.

Un segundo grupo, muy numeroso, transforma la señal de EEG en imágenes de tiempo-frecuencia y aplica sobre ellas redes convolucionales bidimensionales, un enfoque tomado de la visión por computador. Para la clasificación entre pacientes con Parkinson y controles, Loh et al. [19] convirtieron el EEG en espectrogramas de Gabor, reportando una exactitud del 99,46 % en una tarea de tres clases; Khare et al. [18] emplearon

imágenes derivadas de una distribución de Wigner-Ville suavizada; y Shaban y Amara [43] aplicaron una red convolucional profunda sobre imágenes del dominio wavelet, incorporando además mapas de activación para visualizar las regiones influyentes. Estos enfoques reportaron exactitudes muy elevadas, cercanas al 99 %. No obstante, la conversión de la señal de EEG en imágenes implica una pérdida potencial de información del dominio temporal y espectral original, pues la representación pasa a depender de la transformación elegida y de su resolución.

Un tercer grupo explora arquitecturas híbridas, recurrentes y basadas en grafos, siempre sobre EEG para separar a los pacientes de los controles. Shah et al. [17] propusieron una red híbrida compacta basada en sistemas dinámicos; Lee et al. [16] combinaron capas convolucionales y recurrentes para modelar la dimensión temporal, alcanzando un 99,2 %; y Chang et al. [44] propusieron, sobre EEG registrado durante una tarea auditiva, una red convolucional de grafos con atención que representa las relaciones entre canales y selecciona los más relevantes, obteniendo un 87,67 % además de revelar una asimetría frontal característica en los pacientes. Otras propuestas incluyen redes capsulares, como la de Wang et al. [45], que trabajó sobre mapas de energía por banda de frecuencia con una exactitud del 89,34 %. Con un enfoque orientado a la generalización a partir de pocas muestras, Qiu et al. [46] combinaron redes convolucionales multiescala con redes de prototipos, alimentadas con la densidad espectral de potencia y la sincronía de fase entre canales, y las evaluaron con validación separada por sujeto. Junto a estas arquitecturas aplicadas al Parkinson, cabe mencionar que existen redes convolucionales diseñadas para el EEG en general, como EEGNet [34], una red compacta concebida originalmente para interfaces cerebro-computador que se ha convertido en una referencia transversal para la clasificación de señales cerebrales.

Más recientemente, los mecanismos de atención han comenzado a aplicarse mediante modelos Transformer. Sobre EEG de reposo de pacientes con Parkinson y controles, Mancazzo et al. [47] propusieron un modelo de extremo a extremo que aprovecha la atención de múltiples cabezas no solo para clasificar, sino también para identificar las bandas de frecuencia más relevantes, validándolo sobre tres conjuntos de datos públicos registrados con ojos abiertos, procedentes de las universidades de Iowa y de California en San Diego. Este trabajo es relevante por dos razones: incorpora la interpretabilidad como parte del diseño del modelo, y prioriza la validación multicéntrica frente a la máxima exactitud en un único conjunto.

Este último punto merece una consideración crítica. Muchos de los trabajos basados en aprendizaje profundo reportan exactitudes cercanas o superiores al 99 %, pero estos valores deben interpretarse con cautela, pues con frecuencia provienen de esquemas de validación que dividen los datos por segmentos o épocas sin separar por sujeto, o que se evalúan sobre un único conjunto de datos. Bajo estas condiciones, fragmentos de un mismo sujeto pueden aparecer simultáneamente en entrenamiento y prueba, lo que introduce fuga de información y produce estimaciones optimistas que no se sostienen al

generalizar a nuevos sujetos o cohortes [47], [48]. Los trabajos que adoptan validaciones más estrictas, separando por sujeto o evaluando entre conjuntos, tienden a obtener desempeños más moderados, y son estos los que ofrecen una referencia más realista del estado del arte, como se detalla para la cohorte analizada en la Sección 2.2.4.

2.2.3 Enfoques basados en análisis de datos funcionales

Un tercer frente, considerablemente menos explorado, aborda la señal desde el análisis de datos funcionales. La integración de datos funcionales en redes neuronales fue desarrollada por Rossi y Conan-Guez, quienes propusieron una extensión del perceptrón multicapa para entradas funcionales [49]. Posteriormente, Rossi et al. estudiaron distintas estrategias para representar datos funcionales en redes neuronales [30]. Thind et al. [32] propusieron redes neuronales funcionales para tareas de clasificación, mostrando su efectividad en datos espectrográficos, y posteriormente extendieron la idea a redes profundas densamente conectadas capaces de integrar covariables funcionales, con la ventaja adicional de producir funciones de peso interpretables [31]. En paralelo, Rao y Reimherr [50] formalizaron el modelado funcional no lineal mediante redes neuronales, ampliando el repertorio de arquitecturas disponibles para datos funcionales.

El análisis funcional se ha aplicado al EEG en diversos dominios, para la extracción de rasgos y el modelado de la señal. Particularmente cercano a la representación empleada en este trabajo, Xie y Lawniczak [51] transformaron el EEG a su espectro de potencia y aplicaron análisis de componentes principales funcionales para extraer sus rasgos, con aplicación al diagnóstico de epilepsia y a la detección de crisis, mostrando que la representación funcional del espectro es un extractor de características eficaz. En el dominio temporal, Hasenstab et al. [52] propusieron un análisis de componentes principales funcionales multidimensional para modelar potenciales evocados, y Zhang et al. [53] emplearon un modelo de regresión lineal funcional sobre EEG para predecir la capacidad de memoria de trabajo. Estos trabajos ilustran que la representación funcional captura de forma compacta e interpretable la estructura del EEG, tanto en el dominio del tiempo como en el de la frecuencia.

Más allá de la extracción de rasgos, el análisis funcional se ha empleado directamente para la clasificación de EEG, tanto con redes neuronales como con clasificadores clásicos. Con redes neuronales funcionales, Heinrichs et al. [54] introdujeron modelos invariantes al desplazamiento, diseñados para detectar señales de interés con independencia de su posición temporal, y los aplicaron a la clasificación de EEG; en la misma línea, Heim et al. [55] emplearon redes neuronales funcionales en una interfaz cerebro-computador para clasificar EEG en tiempo real durante tareas de imaginación y ejecución motora. Con clasificadores clásicos, Yi et al. [56] propusieron un algoritmo de tres etapas que representa el EEG como dato funcional y lo clasifica mediante una regresión logística funcional penalizada, seleccionando de forma interpretable los canales y las frecuencias relevan-

tes, y Bohorquez et al. [57] desarrollaron una regla de análisis discriminante cuadrático para datos funcionales espaciales, aplicada al reconocimiento de habla silenciosa a partir de EEG. Estos trabajos muestran que la representación funcional del EEG, que preserva su forma, su continuidad y su estructura espacial, puede sustentar clasificadores tanto lineales como no lineales de manera efectiva e interpretable, aunque su aplicación se ha dirigido a tareas distintas de la clasificación de la enfermedad de Parkinson.

El análisis funcional también se ha combinado con modelos de aprendizaje automático clásico en señales biomédicas distintas del EEG. Maturo y Verde [58] integraron el análisis de datos funcionales con bosques aleatorios para la clasificación supervisada de electrocardiogramas, mostrando la versatilidad de la representación funcional como entrada de modelos de conjunto.

En el caso específico de la enfermedad de Parkinson, el análisis de datos funcionales se ha empleado principalmente con fines de inferencia estadística. Jaramillo-Jiménez et al. [8] representaron la densidad espectral de potencia como una función continua y aplicaron herramientas funcionales para comparar grupos época a época, detectando con mayor sensibilidad que el promediado convencional un desplazamiento estable de la potencia hacia las bandas lentas en los pacientes. Este trabajo constituye el antecedente más directo del presente, pues emplea la representación funcional del espectro sobre datos de EEG en Parkinson; sin embargo, la utiliza para el contraste estadístico entre grupos y no como entrada de un modelo de clasificación.

2.2.4 Antecedentes sobre la cohorte analizada

Algunos de los trabajos descritos en las secciones anteriores, junto con otros de carácter metodológico, emplearon registros del mismo estudio de la Universidad de Nuevo México, aunque no necesariamente la versión pública `ds003490` utilizada en este trabajo. Revisarlos desde esta perspectiva permite una comparación más directa con los resultados obtenidos aquí, aunque condicionada por diferencias en el subconjunto de sujetos, la condición de registro y el esquema de validación. El método basado en codificación predictiva lineal de Anjum et al. [35] se evaluó sobre registros de 27 pacientes y 27 controles de ese estudio y, con validación dejando un sujeto fuera, alcanzó una exactitud del 85,3 %, y del 85,7 % en la evaluación externa sobre una cohorte independiente de la Universidad de Iowa. Con su combinación de transformada wavelet discreta y medidas de entropía, Aljalal et al. [37] obtuvieron exactitudes cercanas al 99,5 % con una validación cruzada en la que los segmentos de un mismo sujeto podían quedar simultáneamente en entrenamiento y prueba; con validación dejando un sujeto fuera y selección de canales, la mejor exactitud fue del 88,58 %, y los autores señalan que la diferencia puede deberse a la fuga de información entre segmentos. El modelo de Qiu et al. [46] se evaluó en tres conjuntos de datos, entre ellos la versión de 27 pacientes y 27 controles descrita por Anjum et al., reservando en cada iteración un paciente y un control para la prueba;

en la clasificación entre controles y pacientes sin medicación de esa cohorte obtuvo una exactitud del 92,5 %, el mejor resultado de sus experimentos dentro de cada conjunto. Chang et al. [44] emplearon registros del mismo estudio adquiridos durante la tarea oddball auditiva, con 24 pacientes y 24 controles emparejados, y con una validación que en cada iteración reserva un par formado por un paciente y su control obtuvieron una exactitud del 87,67 % en la clasificación frente a pacientes sin medicación; a diferencia de los anteriores, este resultado procede de EEG registrado durante una tarea y no en reposo. Por su parte, Del Pup et al. [48] emplearon el conjunto `ds003490`, junto con el de San Diego, para estudiar el efecto de la estrategia de partición sobre modelos de aprendizaje profundo, y advirtieron que las particiones que no separan sujetos pueden introducir fuga de información y sobrestimar el desempeño.

Estos antecedentes indican que las exactitudes cercanas al 99 % reportadas sobre esta cohorte deben interpretarse a la luz del esquema de partición empleado, y que la validación separada por sujeto tiende a producir estimaciones más moderadas. Conviene precisar, además, que la versión pública empleada en este trabajo [59] contiene 25 pacientes y 25 controles, que el análisis se restringió al registro con ojos cerrados y a la sesión sin medicación, y que tras el control de calidad se conservaron 24 sujetos por grupo.

2.2.5 Oportunidad de investigación

El recorrido por los tres frentes deja al descubierto un vacío preciso. Los enfoques de aprendizaje automático clásico clasifican la enfermedad de Parkinson, pero lo hacen sobre características definidas de antemano, que resumen el espectro y descartan la forma de la curva donde reside el biomarcador. Los enfoques de aprendizaje profundo emplean distintas representaciones de entrada, entre ellas la señal cruda, características espectrales discretas y transformaciones tiempo-frecuencia; sin embargo, los trabajos revisados no modelan explícitamente la forma continua del espectro como un dato funcional. El análisis de datos funcionales sí preserva esa forma completa y ha demostrado ser eficaz para clasificar señales en distintos dominios; sin embargo, en la enfermedad de Parkinson solo se ha empleado con fines de inferencia estadística, y no como representación de entrada para clasificar la enfermedad, y menos aún con arquitecturas de aprendizaje profundo.

El punto en el que convergen una representación funcional del espectro y un modelo de aprendizaje profundo que la reciba como entrada, aplicado a la clasificación de la enfermedad de Parkinson a partir de EEG, permanece sin explorar. Ninguno de los trabajos revisados aborda esa combinación: los que emplean aprendizaje profundo en Parkinson prescinden de la representación funcional, y los que emplean datos funcionales sobre EEG lo hacen en otros problemas o con fines de inferencia. Sobre este vacío se sitúa este trabajo, que evalúa el análisis de datos funcionales como entrada de modelos de aprendizaje profundo para clasificar la enfermedad, junto a modelos de referencia que

permiten valorar su aporte, bajo un esquema de validación separado por sujeto que evita la fuga de información y que permite contrastar sus resultados con los reportados sobre la misma cohorte en condiciones comparables. La Tabla 2.1 resume esta comparación.

Tabla 2.1: Resumen de trabajos previos en clasificación de señales EEG mediante aprendizaje automático, aprendizaje profundo y análisis de datos funcionales.

Enfoque	Estudio	Año	Técnica	Resultado, datos y validación
Aprendizaje automático	Anjum et al. [35]	2020	LPC con clasificador lineal	85,3 % acc., HC vs PD; UNM (27+27), LOSO; 85,7 % en validación externa (Iowa)
	Khare et al. [36]	2021	Wavelet Q sintonizable + ML	96,13 % acc., HC vs PD; San Diego
	Aljalal et al. [38]	2022	Patrones espaciales, entropía y ML	98-99 % acc., HC vs PD; San Diego y UNM
	Aljalal et al. [37]	2022	Wavelet discreta + entropía + ML	≈99,5 % acc. por segmentos; 88,58 % con LOSO; San Diego y UNM
	Yang y Huang [40]	2022	SVM y CNN con rasgos espectrales, coherencia y entropía	88,88 % acc. (SVM) y 98,66 % (CNN), HC vs PD en ON; datos propios (39+40), partición aleatoria de ventanas de 2 s
	Belyaev et al. [39]	2023	Entropía difusa + ML	≈99,9 % acc., HC vs PD; cohorte de Malasia (20+20), validación cruzada sobre segmentos
Aprendizaje profundo	Oh et al. [42]	2020	CNN de 13 capas sobre la señal	88,25 % acc., HC vs PD; cohorte de Malasia, 10 pliegues
	Loh et al. [19]	2021	CNN 2D sobre espectrogramas de Gabor	99,46 % acc., 3 clases; San Diego
	Khare et al. [18]	2021	CNN 2D sobre imágenes tiempo-frecuencia	≈99,9 % acc., HC vs PD; San Diego y datos privados
	Lee et al. [16]	2021	CNN-RNN híbrida	99,2 % acc., HC vs PD OFF; datos propios (20+21), 10 pliegues sobre épocas de 1 s
	Shaban y Amara [43]	2022	CNN 2D sobre imágenes wavelet	≈99,9 % acc., HC vs PD; San Diego
	Wang et al. [45]	2022	Red capsular sobre energía por banda	89,34 % acc. por época, HC vs PD; datos propios (55+30), 5 pliegues con sujetos distintos

Continúa en la página siguiente

Tabla 2.1 - *continuación*

Enfoque	Estudio	Año	Técnica	Resultado, datos y validación
	Chang et al. [44]	2023	CNN de grafos con atención entre canales	87,67 % acc., HC vs PD OFF; UNM (24+24), tarea oddball, LOSO por pares
	Qiu et al. [46]	2024	CNN multiescala con redes de prototipos	92,5 % acc., HC vs PD OFF; UNM (27+27), LOSO por pares
	Del Pup et al. [48]	2025	Estudio de estrategias de partición	Sobrestimación con particiones por muestras; `ds003490` y San Diego
	Mancazzo et al. [47]	2026	Transformer con atención múltiple	0,87 acc. por paciente (theta); Iowa y San Diego, ojos abiertos, separación por sujeto
Datos funcionales	Rossi y Conan-Guez [49]	2005	Functional Multi-Layer Perceptron (FMLP)	Fundamento de redes neuronales funcionales
	Hasenstab et al. [52]	2017	FPCA multidimensional	Modelado de ERP
	Thind et al. [32]	2020	Red neuronal funcional (FNN)	Clasificación de datos funcionales
	Xie y Lawniczak [51]	2020	FPCA sobre el espectro de potencia	Rasgos de EEG (epilepsia)
	Zhang et al. [53]	2020	Regresión lineal funcional	Memoria de trabajo (EEG)
	Yi et al. [56]	2022	Regresión logística funcional	Clasificación de EEG (comportamiento)
	Maturo y Verde [58]	2022	Bosques aleatorios funcionales	Señales biomédicas (ECG)
	Heinrichs et al. [54]	2023	FNN invariante al desplazamiento	Clasificación de EEG
	Thind et al. [31]	2023	Red densa funcional profunda (FDNN)	Regresión funcional interpretable
	Jaramillo-J. et al. [8]	2023	FDA (inferencia funcional)	Contraste HC vs PD
	Heim et al. [55]	2025	FNN en interfaz cerebro-computador	EEG en tiempo real
	Bohorquez et al. [57]	2026	Discriminante funcional espacial	Clasificación de EEG (habla silenciosa)

Nota. acc.: exactitud; HC: controles sanos; PD: pacientes con enfermedad de Parkinson; OFF: sin medicación; UNM: Universidad de Nuevo México; LOSO: validación dejando un sujeto fuera; LOSO por pares: en cada iteración se reserva un paciente y un control; tarea oddball: EEG registrado durante una tarea auditiva, no en reposo. Las exactitudes no son directamente comparables entre estudios, pues difieren en la cohorte, la condición de registro y el esquema de validación (Sección 2.2.4).

3. METODOLOGÍA

Esta investigación adopta un enfoque cuantitativo de alcance experimental, orientado a evaluar modelos de clasificación entre sujetos con enfermedad de Parkinson (EP) y personas sanas a partir de señales electroencefalográficas (EEG) en estado de reposo, utilizando representaciones derivadas del Análisis de Datos Funcionales (ADF) como entrada.

El desarrollo metodológico se organiza en nueve secciones: la descripción del conjunto de datos y los sujetos (Sección 3.1), el preprocesamiento de las señales (Sección 3.2), la estimación espectral (Sección 3.3), la construcción de las representaciones funcionales (Sección 3.4), los modelos de clasificación (Sección 3.5), el esquema de validación y las métricas (Sección 3.6), el análisis estadístico (Sección 3.7), las herramientas computacionales empleadas (Sección 3.8) y la síntesis del flujo metodológico (Sección 3.9).

3.1 CONJUNTO DE DATOS Y SUJETOS

Se utilizó el conjunto de datos público `ds003490`, disponible en el repositorio OpenNeuro y correspondiente a la cohorte de la Universidad de Nuevo México (UNM) descrita originalmente por Cavanagh et al. [60] y posteriormente publicada como conjunto de datos abierto en OpenNeuro [59]. El conjunto original contiene registros EEG de 50 participantes: 25 pacientes con enfermedad de Parkinson (PD) y 25 personas sanas (*healthy controls*, HC), apareados por edad y sexo.

Los registros se adquirieron con un montaje de 64 canales, a una frecuencia de muestreo de $500\,\mathrm{Hz}$ y con referencia en línea en el electrodo CPz. Para el presente estudio se utilizaron exclusivamente los segmentos de EEG en estado de reposo con ojos cerrados. Esta condición permite analizar de forma adecuada la actividad espectral espontánea y, en particular, el ritmo alfa posterior y los cambios relativos en las bandas theta y alfa descritos en pacientes con enfermedad de Parkinson [8].

Los pacientes disponen de registros correspondientes a condiciones de medicación ON y OFF. En este trabajo se seleccionaron exclusivamente las sesiones en estado **OFF-medicación**, obtenidas después de la retirada temporal del tratamiento dopaminérgico según el protocolo del conjunto de datos. Esta decisión busca reducir la influencia aguda de la levodopa sobre la actividad espectral cortical, dado que la administración dopaminérgica puede modificar la potencia EEG, especialmente en las bandas alfa y beta [61]. De esta manera, la comparación con el grupo control se realiza utilizando una condición menos influenciada por los efectos inmediatos del tratamiento.

La Tabla 3.1 resume las características demográficas de la cohorte original considerada antes del control de calidad. Las variables clínicas utilizadas en este trabajo se limitaron al diagnóstico de grupo y al estado de medicación; las comparaciones demográficas entre HC y PD se realizaron mediante las pruebas descritas en la Sección 3.7.

Tabla 3.1: Características demográficas de la cohorte original `ds003490`.

Característica	HC	PD (OFF)
n	25	25
Edad (años)	$69{,}3 \pm 9{,}6$	$69{,}7 \pm 8{,}7$
Rango de edad	48-84	49-83
Sexo (M/F)	16/9	16/9

Fuente: elaboración propia con datos de OpenNeuro ds003490.

Nota: Las características demográficas corresponden a la cohorte original. La muestra final utilizada para la construcción funcional y el modelado quedó constituida por 24 sujetos HC y 24 sujetos PD en estado OFF tras el control de calidad.

Durante el preprocesamiento se estableció un número mínimo de épocas válidas por sesión como criterio de calidad (Sección 3.2). Dos sesiones, una de cada grupo, no cumplieron este criterio, por lo que la muestra efectiva utilizada en la construcción funcional y el modelado quedó constituida por 48 sujetos: 24 HC y 24 PD en estado OFF. Los resultados detallados del control de calidad se presentan en el Capítulo 4.

Los procedimientos de adquisición del conjunto de datos original contaron con aprobación ética y consentimiento informado, según lo reportado por los autores del conjunto [60]. El presente estudio corresponde a un análisis secundario de datos públicos anonimizados y se plantea como una clasificación experimental orientada a la exploración de biomarcadores neurofisiológicos, no como un procedimiento de diagnóstico clínico.

3.2 PREPROCESAMIENTO DE LAS SEÑALES EEG

El preprocesamiento se implementó con la biblioteca MNE-Python [62], siguiendo una secuencia de etapas orientada a atenuar artefactos y ruido preservando el contenido espectral relevante para los análisis posteriores. Las señales se procesaron una sola vez, de forma común a todos los análisis posteriores, de modo que cualquier diferencia entre ellos provenga de la representación y no del tratamiento de la señal. A continuación se describen las etapas en su orden de aplicación.

3.2.1 Re-referenciado

Los registros originales, referenciados en línea al electrodo CPz, se re-referenciaron al *promedio común* de los canales EEG. Esta referencia promedio evita que la señal dependa de un único electrodo, lo que reduce el sesgo asociado a esa elección, y es una práctica habitual en el análisis espectral de EEG de reposo.

3.2.2 Filtrado

Se aplicó un filtro pasa-banda de respuesta finita al impulso (FIR, diseño `firwin`) con frecuencias de corte de $1\,\mathrm{Hz}$ y $40\,\mathrm{Hz}$. El corte inferior en $1\,\mathrm{Hz}$ elimina las derivas lentas y el componente de continua, mientras que el corte superior en $40\,\mathrm{Hz}$ atenúa la actividad muscular de alta frecuencia y sitúa la banda de línea eléctrica de $60\,\mathrm{Hz}$ fuera del rango analizado, evitando la necesidad de un filtro de rechazo de banda adicional.

3.2.3 Remuestreo

Las señales se remuestrearon de $500\,\mathrm{Hz}$ a $250\,\mathrm{Hz}$. Dado que el contenido de interés se limita a frecuencias inferiores a $40\,\mathrm{Hz}$, una frecuencia de muestreo de $250\,\mathrm{Hz}$ satisface holgadamente el criterio de Nyquist y reduce el costo computacional sin pérdida de información relevante.

3.2.4 Corrección de artefactos mediante ICA

La corrección de artefactos oculares se realizó mediante Análisis de Componentes Independientes (ICA), utilizando el algoritmo FastICA antes de la selección de los canales empleados posteriormente en el modelado. La descomposición se aplicó sobre el montaje EEG completo y se configuró con un máximo de 20 componentes independientes. Este número se mantuvo fijo para todas las sesiones como una configuración uniforme de preprocesamiento, orientada a la identificación y corrección de componentes asociados con actividad ocular, sin pretender una separación exhaustiva de las fuentes cerebrales.

La identificación de los componentes relacionados con actividad ocular se realizó utilizando los canales electrooculográficos (EOG) disponibles en los registros. Para ello se empleó la función `find_bads_eog` de MNE-Python, con un umbral de $3{,}0$. Los canales EOG estuvieron disponibles en las 50 sesiones candidatas, por lo que la detección de componentes oculares se realizó directamente a partir de estas señales.

Con el fin de limitar una corrección excesiva del EEG, se eliminaron como máximo dos

componentes ICA por sesión. Una vez identificados los componentes asociados con actividad ocular, estos se excluyeron y se reconstruyó la señal EEG corregida. La segmentación en épocas y el control de calidad posterior se realizaron sobre esta señal reconstruida.

3.2.5 Selección de canales

Después de la corrección de artefactos, el análisis se restringió a diez derivaciones de las regiones central, parietal y occipital: C3, Cz, C4, P7, P8, P3, Pz, P4, O1 y O2.

La selección de estos canales se fundamentó en criterios neurofisiológicos y en evidencia reportada en la literatura sobre alteraciones espectrales del EEG asociadas con la enfermedad de Parkinson. En particular, se han descrito cambios reproducibles en la actividad theta y pre-alfa, así como alteraciones de la frecuencia dominante con predominio en regiones posteriores [8].

Por esta razón, se incluyeron las derivaciones parietales y occipitales P7, P8, P3, Pz, P4, O1 y O2, con el propósito de representar la actividad espectral posterior y, especialmente, las variaciones asociadas con los ritmos theta y alfa.

Las derivaciones centrales C3, Cz y C4 se conservaron para incorporar información complementaria de regiones sensoriomotoras. En estudios previos se han reportado modificaciones de la potencia espectral en regiones centro-parietales, particularmente en las bandas alfa y beta, asociadas con la enfermedad y con la modulación dopaminérgica [61].

Finalmente, restringir el análisis a un subconjunto de diez canales reduce la dimensionalidad de las representaciones funcionales, aspecto especialmente relevante considerando el tamaño de la cohorte. Esta decisión es coherente con trabajos que han evaluado explícitamente la clasificación de Parkinson con configuraciones reducidas de electrodos y han mostrado que estas pueden conservar información discriminante relevante [63].

3.2.6 Segmentación en épocas

En esta etapa del preprocesamiento, la señal continua se segmentó en épocas no solapadas de $4\,\mathrm{s}$. A una frecuencia de muestreo de $250\,\mathrm{Hz}$, cada época estuvo constituida por 1000 muestras.

Estas épocas constituyeron las unidades sobre las que se aplicó el control de calidad posterior y a partir de las cuales se realizó la estimación espectral descrita en la Sección 3.3.

3.2.7 Rechazo de épocas

Después de la segmentación se aplicó un criterio combinado para descartar épocas con artefactos residuales. Una época se rechazó cuando, en cualquiera de los diez canales seleccionados, se cumplió al menos una de las siguientes condiciones: una amplitud pico a pico superior a $100\,\mu\mathrm{V}$ o una curtosis anómala, definida mediante una puntuación z absoluta superior a 5 respecto a la distribución de curtosis de ese canal dentro de la sesión.

El criterio de amplitud permite identificar segmentos con variaciones de gran magnitud, mientras que la curtosis complementa este control al detectar épocas con distribuciones atípicas asociadas, por ejemplo, con transitorios breves o picos residuales.

Finalmente, se estableció un mínimo de seis épocas válidas por sesión para que el registro continuara en las etapas posteriores. Las sesiones que no alcanzaron este mínimo fueron excluidas del análisis. El número de épocas conservadas y las sesiones finalmente incluidas se presentan en el Capítulo 4.

3.3 ESTIMACIÓN ESPECTRAL

A partir de las épocas válidas obtenidas después del preprocesamiento se estimó la densidad espectral de potencia (*power spectral density*, PSD) de forma independiente para cada época y canal. Esta estimación constituye la base espectral común a partir de la cual se construyeron los Enfoques funcionales A y B, así como las características escalares empleadas en la línea base sin ADF.

Aunque las tres estrategias parten de la misma estimación inicial de la PSD, difieren posteriormente en el orden en que se realizan el promedio entre épocas, la integración por bandas, la normalización respecto a la potencia total y la transformación logarítmica. Estas diferencias se describen en las subsecciones siguientes.

3.3.1 Estimación mediante el método de Welch

Para cada época y canal, la PSD se estimó mediante el método de Welch [64]. Cada época de $4\,\mathrm{s}$ se dividió internamente en ventanas de $2\,\mathrm{s}$ (500 muestras) con un solapamiento del 50 %. Los periodogramas obtenidos en estas ventanas se promediaron para producir una única estimación espectral por época y canal.

Con una frecuencia de muestreo de $250\,\mathrm{Hz}$ y ventanas de 500 muestras, la resolución

frecuencial resultante fue de aproximadamente $0{,}5\,\mathrm{Hz}$. Esta configuración es consistente con procedimientos de análisis espectral utilizados previamente en EEG de reposo en enfermedad de Parkinson [8].

La PSD se calculó inicialmente en escala lineal, en unidades de $\mu\mathrm{V}^2\,\mathrm{Hz}^{-1}$, sobre el intervalo de $1\,\mathrm{Hz}$ a $40\,\mathrm{Hz}$. La normalización y transformación posterior se describen en la siguiente subsección.

3.3.2 Procesamiento espectral según la estrategia de representación

A partir de la PSD lineal estimada para cada época y canal, el procesamiento posterior se adaptó a la unidad de análisis de cada estrategia. Aunque la línea base sin ADF y los Enfoques A y B parten de la misma estimación espectral, difieren en el orden en que se realizan el promedio entre épocas, la normalización respecto a la potencia total, la integración por bandas y la transformación logarítmica. Por esta razón, estos procedimientos se describen por separado a continuación.

El intervalo de $1\,\mathrm{Hz}$ a $40\,\mathrm{Hz}$ utilizado durante el filtrado y la estimación inicial de la PSD debe distinguirse de los intervalos empleados en las etapas posteriores. En las tres estrategias, la potencia total utilizada como referencia para la normalización se definió entre $1\,\mathrm{Hz}$ a $30\,\mathrm{Hz}$. A partir de esta referencia, cada estrategia conservó la información espectral correspondiente a su unidad de análisis: la línea base calculó características entre delta y beta, el Enfoque A restringió posteriormente la representación funcional al intervalo de $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$, y el Enfoque B utilizó las potencias relativas de las bandas theta y alfa.

3.3.2.1 Línea base sin ADF

Para la línea base se siguió un enfoque convencional de análisis espectral del EEG, basado en el promedio de las épocas y en la extracción de características por bandas entre delta y beta, como se ha empleado en estudios de biomarcadores espectrales de la enfermedad de Parkinson [8]. Este enfoque permite caracterizar alteraciones asociadas al enlentecimiento espectral, particularmente los cambios en las bandas theta y alfa y en su relación.

Las PSD lineales correspondientes a las épocas válidas de cada sujeto se promediaron primero, obteniendo una única PSD por sujeto y canal. El promedio de múltiples estimaciones espectrales permite reducir la variabilidad entre épocas, aumentar la estabilidad de la estimación espectral y obtener una representación resumen del registro [8], [65].

Sobre la PSD promedio se calculó la potencia total en el intervalo de $1\,\mathrm{Hz}$ a $30\,\mathrm{Hz}$ median-

te integración numérica con la regla de Simpson. Posteriormente se estimó la potencia relativa de las bandas delta ($1\,\mathrm{Hz}$ a $4\,\mathrm{Hz}$), theta ($4\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$), pre-alfa ($5{,}5\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$), alfa ($8\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$) y beta ($13\,\mathrm{Hz}$ a $30\,\mathrm{Hz}$):

$$P_b = \frac{\displaystyle\int_b \overline{S}(f)\,df}{\displaystyle\int_{1\,\mathrm{Hz}}^{30\,\mathrm{Hz}} \overline{S}(f)\,df}. \tag{3.1}$$

Debe señalarse que las bandas theta ($4\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$) y pre-alfa ($5{,}5\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$) se solapan en el intervalo de $5{,}5\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$. En consecuencia, las potencias relativas calculadas para estas bandas no corresponden a componentes espectrales mutuamente excluyentes ni deben interpretarse como términos cuya suma reproduzca la potencia total.

Las potencias relativas por banda se transformaron mediante logaritmo en base 10. El uso de transformaciones logarítmicas de estas medidas cuenta con antecedentes en el análisis espectral del EEG de reposo [8], [66]. Además, se calcularon la frecuencia dominante, expresada directamente en Hz, y el cociente alfa/theta, este último también transformado mediante logaritmo en base 10.

3.3.2.2 Enfoque A: representación espectral por época

En el Enfoque A, el procesamiento espectral se realizó de forma independiente para cada época y canal. En primer lugar, cada PSD se normalizó respecto a la potencia total comprendida entre $1\,\mathrm{Hz}$ a $30\,\mathrm{Hz}$:

$$S_{\mathrm{rel},e}(f) = \frac{S_e(f)}{\displaystyle\int_{1\,\mathrm{Hz}}^{30\,\mathrm{Hz}} S_e(\nu)\,d\nu}. \tag{3.2}$$

Posteriormente se aplicó la transformación logarítmica a nivel de época,

$$X_e(f) = \log_{10}\left(S_{\mathrm{rel},e}(f) + \varepsilon\right), \qquad \varepsilon = 10^{-20}, \tag{3.3}$$

antes de realizar cualquier promedio entre épocas. La aplicación de la transformación

logarítmica a nivel de ensayo antes del promedio se sustenta en la evidencia metodológica reportada para el análisis espectral de EEG de reposo [67].

Finalmente, las curvas se restringieron al intervalo de $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$, que comprende las bandas theta y alfa. A partir de esta representación, la estrategia A1 promedia las curvas transformadas de las épocas de cada sujeto, mientras que A2 conserva una representación funcional individual por época.

3.3.2.3 Enfoque B: potencia relativa por banda y época

En el Enfoque B, las características espectrales se calcularon también de forma independiente para cada época y canal, siguiendo el principio de conservar la variabilidad entre épocas empleado en el análisis funcional de características espectrales [8].

Para cada banda b, la potencia relativa de una época se calculó como

$$P_{b,e} = \frac{\displaystyle\int_{b} S_e(f)\,df}{\displaystyle\int_{1\,\mathrm{Hz}}^{30\,\mathrm{Hz}} S_e(f)\,df}, \tag{3.4}$$

utilizando la regla de Simpson para ambas integraciones. Posteriormente se aplicó la transformación

$$X_{b,e} = \log_{10}\left(P_{b,e} + \varepsilon\right), \qquad \varepsilon = 10^{-20}. \tag{3.5}$$

En la configuración final se conservaron las bandas theta ($4\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$) y alfa ($8\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$). La sucesión de estos valores a través de las épocas válidas constituye la información sobre la cual se construyeron posteriormente las trayectorias funcionales del Enfoque B.

3.4 CONSTRUCCIÓN DE LAS REPRESENTACIONES FUNCIONALES

A partir de las variables espectrales definidas en la Sección 3.3, se construyeron dos enfoques de representación mediante Análisis de Datos Funcionales (ADF). La elección de este marco metodológico responde a que las variables de interés pueden considerarse observaciones de funciones definidas sobre un dominio ordenado, lo que permite con-

servar su estructura y expresarlas mediante un número finito de coeficientes de base [9], [30].

El **Enfoque A** representa la información espectral como una función de la frecuencia en el intervalo de $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$. Sobre esta misma construcción funcional se evaluaron dos estrategias: A1, con una representación por sujeto, y A2, con representaciones individuales por época.

El **Enfoque B** representa la variación de la potencia relativa de las bandas theta y alfa a través del orden normalizado de las épocas válidas. En este caso, el dominio funcional se define en el intervalo $[0, 1]$ y representa la posición relativa de las épocas conservadas, no el tiempo físico transcurrido durante el registro. Este planteamiento sigue la motivación del análisis funcional de la variabilidad época a época aplicado previamente al EEG de reposo en enfermedad de Parkinson [8].

En ambos enfoques, las observaciones discretas se aproximaron mediante bases B-spline. La configuración de la base, la construcción de las coordenadas funcionales y las transformaciones utilizadas posteriormente para el modelado se describen a continuación.

3.4.1 Configuración de la base funcional

Las observaciones discretas de ambos dominios funcionales se representaron mediante bases B-spline cúbicas. Esta familia se seleccionó por su flexibilidad para representar curvas suaves y por su capacidad de controlar localmente la forma de la función mediante un número reducido de coeficientes. Aunque existen otras familias de bases funcionales, la elección se realizó de acuerdo con las características de las representaciones analizadas y con el objetivo de obtener una aproximación suave y de dimensión controlada. Además, aunque la PSD original es una magnitud no negativa, las representaciones funcionales se construyeron sobre potencia relativa transformada logarítmicamente, por lo que no fue necesario imponer una restricción de positividad sobre la base.

Para una base $\{\phi_k(t)\}_{k=1}^{K}$, una función $x(t)$ se aproxima mediante

$$x(t) \approx \sum_{k=1}^{K} c_k \, \phi_k(t), \tag{3.6}$$

donde c_k representa el coeficiente asociado a la k-ésima función base. Las bases B-

spline proporcionan una representación finita de funciones suaves y poseen soporte local, propiedad especialmente útil para aproximar curvas en dominios unidimensionales [9], [30].

Para una curva observada sobre una malla de n puntos, los coeficientes se estimaron mediante mínimos cuadrados con una regularización de crestas de pequeña magnitud:

$$\mathbf{c} = \left(\mathbf{\Phi}^\top \mathbf{\Phi} + \lambda_r \mathbf{I}\right)^{-1} \mathbf{\Phi}^\top \mathbf{x}, \qquad \lambda_r = 10^{-6}, \tag{3.7}$$

donde $\mathbf{\Phi}$ contiene las funciones base evaluadas en los puntos del dominio. El término λ_r se utilizó para mejorar la estabilidad numérica del ajuste y no como mecanismo principal de suavizado.

La dimensión de la base se seleccionó mediante validación cruzada generalizada (*Generalized Cross-Validation*, GCV). Para cada número candidato de nudos se calculó

$$\mathrm{GCV} = \frac{\mathrm{ECM}_{\mathrm{ajuste}}}{\left(1 - \frac{\mathrm{tr}(H)}{n}\right)^2}. \tag{3.8}$$

donde $\mathrm{ECM}_{\mathrm{ajuste}}$ corresponde al error cuadrático medio residual del ajuste, $\mathbf{H}$ corresponde a la matriz de ajuste y $\mathrm{tr}(\mathbf{H})$ representa los grados de libertad efectivos del modelo. Este criterio permite evaluar el compromiso entre fidelidad de reconstrucción y complejidad de la representación [9], [26].

La selección se realizó de manera independiente para los dos dominios funcionales y sin utilizar las etiquetas de grupo ni el desempeño posterior de los clasificadores. Para el dominio de frecuencia se establecieron 9 nudos, que generan 11 funciones B-spline cúbicas. Para las trayectorias del Enfoque B se establecieron 2 nudos, equivalentes a 4 funciones base, de manera independiente para theta y alfa.

Como análisis de sensibilidad se evaluó adicionalmente una representación penalizada mediante P-splines para el Enfoque A. La comparación se realizó sobre el mismo dominio espectral y el parámetro de penalización se seleccionó mediante GCV. Los resultados de este análisis se presentan en el Capítulo 4.

3.4.2 Construcción funcional en el dominio de la frecuencia

Para esta representación se utilizaron las curvas espectrales definidas en la Sección 3.3.2, evaluadas en el dominio $f \in [4, 13]$ Hz. Cada curva se proyectó sobre la base B-spline cúbica de $K_A = 11$ funciones:

$$x_{s,c,e}(f) \approx \sum_{k=1}^{K_A} c_{s,c,e,k}\, \phi_k(f), \qquad K_A = 11, \tag{3.9}$$

donde s identifica al sujeto, c al canal y e a la época válida.

Para la estrategia A1, las curvas correspondientes a las épocas válidas de cada sujeto se promediaron antes de realizar la proyección sobre la base funcional:

$$\bar{x}_{s,c}(f) = \frac{1}{E_s} \sum_{e=1}^{E_s} x_{s,c,e}(f), \tag{3.10}$$

donde E_s corresponde al número de épocas válidas del sujeto s. La curva promedio resultante se representó posteriormente mediante los 11 coeficientes B-spline.

En A2, cada curva por época se proyectó individualmente sobre la misma base, sin realizar el promedio previo. La separación de las épocas por sujeto y la agregación posterior de las predicciones se describen en la Sección 3.6.

En ambos casos se obtuvieron 11 coeficientes por canal. Considerando los diez canales seleccionados, cada observación quedó inicialmente representada por 110 coeficientes funcionales.

3.4.3 Construcción funcional sobre el orden normalizado de las épocas

Para esta representación se utilizaron las potencias relativas logarítmicas de theta y alfa calculadas por época según el procedimiento descrito en la Sección 3.3.2.

Debido a que el número de épocas válidas puede variar entre sujetos, el dominio se nor-

malizó al intervalo $[0, 1]$. Para un sujeto con E_s épocas válidas, la posición correspondiente a la época e se definió como

$$t_{s,e} = \frac{e-1}{E_s - 1}, \qquad e = 1, \ldots, E_s. \tag{3.11}$$

De esta forma, todos los sujetos comparten un mismo dominio funcional, independientemente del número de épocas conservadas.

Para cada sujeto, canal y banda $b \in \{\theta, \alpha\}$ se construyó una trayectoria funcional

$$x_{s,c,b}(t) \approx \sum_{k=1}^{K_B} c_{s,c,b,k}\, \phi_{b,k}(t), \qquad K_B = 4, \tag{3.12}$$

utilizando una base B-spline cúbica de cuatro funciones para cada banda. Los coeficientes de theta y alfa se concatenaron posteriormente dentro de cada canal.

Por tanto, cada canal quedó representado mediante ocho coeficientes funcionales, cuatro correspondientes a theta y cuatro a alfa. Para los diez canales seleccionados, la representación inicial del Enfoque B estuvo constituida por 80 coeficientes por sujeto.

3.4.4 Incorporación de la geometría funcional mediante Cholesky

Los coeficientes obtenidos mediante una base B-spline constituyen coordenadas de la función dentro del subespacio generado por la base. Sin embargo, las funciones B-spline no forman, en general, una base ortonormal. En consecuencia, la distancia euclídea entre los vectores de coeficientes no coincide directamente con la distancia funcional definida en el espacio L^2 [30].

Para incorporar esta geometría se construyó la matriz de Gram de la base:

$$G_{ij} = \int_{\mathcal{D}} \phi_i(t)\phi_j(t)\, dt, \tag{3.13}$$

donde $\mathcal{D}$ corresponde al dominio funcional considerado: $[4, 13]$ Hz para el Enfoque A y $[0, 1]$ para el Enfoque B.

Las integrales de la matriz de Gram se calcularon numéricamente mediante la regla de Simpson sobre una malla uniforme de 1001 puntos del dominio. Este procedimiento permite aproximar los productos internos entre las funciones base mediante cuadratura numérica, como se requiere cuando la base utilizada no es ortonormal [30].

Una vez obtenida la matriz de Gram, se aplicó su factorización de Cholesky:

$$\mathbf{G} = \mathbf{L}\mathbf{L}^{\top}, \tag{3.14}$$

donde $\mathbf{L}$ es una matriz triangular inferior. Si los coeficientes de una función se almacenan como un vector fila $\mathbf{c}$, las nuevas coordenadas se obtienen mediante

$$\mathbf{z} = \mathbf{c}\mathbf{L}. \tag{3.15}$$

Con esta transformación se cumple

$$\|\mathbf{z}_1 - \mathbf{z}_2\|_2^2 = (\mathbf{c}_1 - \mathbf{c}_2)\mathbf{G}(\mathbf{c}_1 - \mathbf{c}_2)^{\top} = \|x_1 - x_2\|_{L^2}^2. \tag{3.16}$$

Por tanto, las coordenadas transformadas permiten utilizar operaciones euclídeas sobre los vectores de entrada preservando la geometría funcional inducida por la base. Esta transformación no modifica la función aproximada, no introduce un nuevo suavizado y no reduce su dimensión; constituye un cambio de coordenadas del mismo objeto funcional.

En adelante, los coeficientes B-spline originales se denotan X_{raw} y las coordenadas obtenidas mediante la transformación de Cholesky se denotan X_{chol}. Para el Enfoque B la transformación se realizó independientemente para los bloques correspondientes a theta y alfa.

3.4.5 Reducción dimensional mediante FPCA

Además de las representaciones X_{raw} y X_{chol}, se evaluó una tercera representación basada en Análisis de Componentes Principales Funcionales (*Functional Principal Component Analysis*, FPCA). El objetivo de esta etapa fue representar la variabilidad funcional mediante un conjunto reducido de componentes ortogonales, conservando la mayor parte de la variabilidad presente en los datos [9], [15].

Dado que la transformación de Cholesky incorpora la métrica funcional L^2 en las coordenadas, la FPCA se implementó mediante un análisis de componentes principales sobre X_{chol}. En estas coordenadas, el PCA convencional constituye la representación finito-dimensional del análisis de componentes principales en el subespacio funcional generado por la base.

Para el Enfoque A, la descomposición se realizó independientemente para cada canal. Para el Enfoque B se realizó de manera independiente para cada combinación canal-banda, evitando mezclar directamente las trayectorias theta y alfa durante la estimación de los componentes.

En cada bloque se retuvo el número mínimo de componentes necesario para explicar al menos el 95 % de la varianza acumulada. Cuando distintos canales o bandas requirieron diferente número de componentes, las representaciones se completaron con ceros hasta la dimensión máxima correspondiente, con el fin de mantener una estructura matricial común para los modelos.

El PCA se aplicó directamente sobre las coordenadas de Cholesky, sin estandarización previa de estas coordenadas. El centrado se realizó como parte del ajuste de PCA. Una vez seleccionadas las componentes y obtenidas sus puntuaciones, estas se estandarizaron mediante `StandardScaler` antes de utilizarlas como entradas de los clasificadores. Por tanto, el orden de procesamiento fue transformación de Cholesky, reducción mediante FPCA y estandarización de las puntuaciones. El criterio del 95 % de varianza acumulada se evaluó antes de esta estandarización.

La estimación de las componentes principales y de los parámetros de estandarización se realizó dentro de cada partición externa, sin utilizar los sujetos del conjunto de prueba. Los datos de prueba se proyectaron y escalaron utilizando los parámetros estimados con los datos de entrenamiento correspondientes, sin volver a ajustarlos. El tratamiento de la validación interna dependió del escenario de entrenamiento y se describe en la Sección 3.6.2.

La representación resultante se denota $X_{\mathrm{chol+FPCA}}$. De esta manera, las tres entradas funcionales consideradas posteriormente en el modelado fueron

$$X_{\mathrm{raw}}, \qquad X_{\mathrm{chol}}, \qquad X_{\mathrm{chol+FPCA}}. \tag{3.17}$$

3.5 MODELOS DE CLASIFICACIÓN

Para evaluar el aporte de las distintas representaciones de entrada se compararon dos modelos de aprendizaje automático clásico y siete arquitecturas de aprendizaje profundo. Esta estrategia permite examinar si el desempeño depende principalmente de la representación de los datos, de la complejidad del clasificador o de la interacción entre ambos.

Los modelos se evaluaron sobre las representaciones funcionales construidas en la Sección 3.4. La línea base sin ADF se utilizó como referencia para contrastar estas representaciones con características espectrales escalares. Todas las configuraciones se evaluaron bajo el mismo esquema de validación agrupada por sujeto, descrito en la Sección 3.6.

Las siete arquitecturas de aprendizaje profundo se consideraron alternativas candidatas para implementar el modelo de Deep Learning basado en ADF planteado en esta investigación. La configuración final del modelo propuesto se seleccionó posteriormente entre estas arquitecturas de acuerdo con la mayor exactitud balanceada observada, definida como métrica principal de evaluación. Los modelos clásicos se mantuvieron como referencias comparativas y no formaron parte de esta selección.

3.5.1 Modelos de referencia

Como modelos de referencia se emplearon dos clasificadores clásicos, con el propósito de disponer de puntos de comparación de menor complejidad frente a las arquitecturas de aprendizaje profundo:

- **Regresión logística**: modelo lineal con regularización $\mathrm{L2}$ y ponderación automática de clases mediante `class_weight=balanced`.

- **Random Forest**: modelo de ensamblado no lineal compuesto por 200 árboles de decisión, con profundidad máxima acotada y ponderación automática de clases mediante `class_weight=balanced`.

3.5.2 Arquitecturas de aprendizaje profundo

Se evaluaron siete arquitecturas de aprendizaje profundo, seleccionadas para explorar diferentes formas de procesar las representaciones espectrales y funcionales utilizadas en este estudio. Estas incluyeron modelos de propósito general, arquitecturas diseñadas para trabajar con datos funcionales y una arquitectura convolucional específica para EEG. En todos los casos, la salida del modelo se definió mediante un único *logit* para la clasificación binaria entre sujetos HC y PD.

3.5.2.1 Arquitecturas de propósito general

Se evaluaron tres arquitecturas de propósito general:

- **MLP**: los coeficientes de todos los canales se concatenaron en un único vector y se procesaron mediante dos capas densas de 128 y 64 unidades, respectivamente, antes de la capa de salida.

- **Transformer**: los coeficientes de cada canal se proyectaron a un espacio latente de dimensión 64 y se complementaron con embeddings posicionales aprendibles. La representación se procesó mediante dos bloques Transformer con atención multi-cabeza y posteriormente se agregó la información entre canales antes de la clasificación.

- **CNN1D**: la entrada conservó la estructura canal$\times$coeficientes y se procesó mediante dos convoluciones unidimensionales sobre el eje de los coeficientes, seguidas de agrupamiento adaptativo y una capa lineal de salida.

3.5.2.2 Arquitecturas orientadas a datos funcionales

Se incluyeron tres arquitecturas inspiradas en modelos orientados al procesamiento de entradas funcionales:

- **FNN** [30], [32]: empleó unidades funcionales que combinan los coeficientes de entrada mediante pesos aprendibles, generando una representación intermedia que posteriormente se procesa mediante capas densas.

- **FDNN** [31]: procesó inicialmente la información dentro de cada canal, realizó posteriormente una combinación entre canales y proyectó la dimensión funcional antes de la etapa final de clasificación.

- **AdaFNN** [33]: utilizó bases adaptativas cuyos parámetros se aprendieron conjuntamente con el clasificador. Las proyecciones obtenidas para cada canal se combinaron posteriormente antes de la capa de salida.

La Figura 3.1 resume la estructura general de las seis arquitecturas descritas anteriormente y la forma en que procesan las representaciones de entrada.

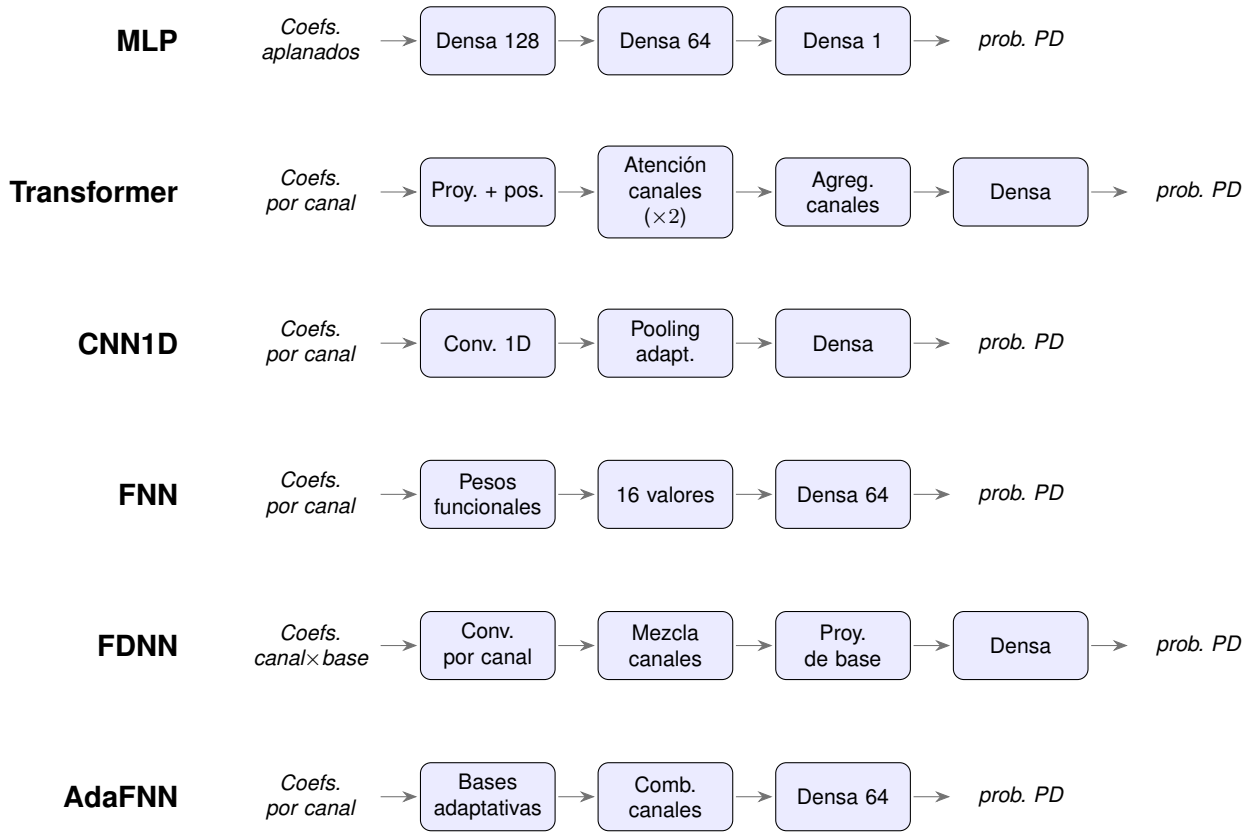


Figura 3.1: Esquemas de las arquitecturas de propósito general y funcionales evaluadas. Elaboración propia.

3.5.2.3 EEGNet adaptada a representaciones funcionales

Se incluyó EEGNet [34] como una arquitectura convolucional compacta diseñada originalmente para el procesamiento de señales EEG. En este trabajo, la arquitectura se adaptó para recibir las representaciones funcionales organizadas en la forma canal×coeficientes, en lugar de la señal EEG temporal cruda.

La primera convolución operó sobre el eje de los coeficientes funcionales. Posteriormente, una convolución *depthwise* integró la información entre los canales EEG y una con-

volución separable generó una representación compacta antes de las etapas de agrupamiento, *dropout* y clasificación. El tamaño del núcleo sobre el eje funcional se ajustó a la dimensión de la representación de entrada.

La Figura 3.2 muestra de forma esquemática la adaptación de EEGNet utilizada en este estudio.

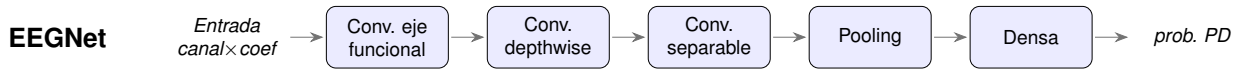


Figura 3.2: Arquitectura EEGNet adaptada a las representaciones funcionales utilizadas en el estudio. Elaboración propia.

Las implementaciones de FNN, FDNN y AdaFNN utilizadas en este trabajo corresponden a adaptaciones de las formulaciones originales a las representaciones finito-dimensionales empleadas en el estudio, por lo que operan sobre coeficientes funcionales o *scores* derivados y no reproducen literalmente las arquitecturas propuestas en sus trabajos de origen. De manera análoga, CNN1D y EEGNet se adaptaron para operar sobre el eje de coeficientes de las representaciones funcionales. En estas últimas, la interpretación de la convolución como extracción de patrones locales debe considerarse con cautela, ya que las coordenadas obtenidas mediante Cholesky y los *scores* de FPCA no conservan necesariamente una noción de vecindad temporal o frecuencial directa. Por tanto, estas arquitecturas se evaluaron como adaptaciones exploratorias a las representaciones funcionales consideradas.

3.5.2.4 Configuración de entrenamiento

Las arquitecturas de aprendizaje profundo se entrenaron utilizando una configuración común de optimización, regularización y parada temprana. Los hiperparámetros se mantuvieron fijos durante la evaluación y no se realizó una optimización específica para cada arquitectura. En consecuencia, los resultados obtenidos corresponden al desempeño de los modelos bajo las configuraciones evaluadas.

Durante el entrenamiento se utilizó un subconjunto interno de validación para controlar la parada temprana. Esta partición mantuvo la separación por sujeto, incluida la estrategia A2, en la que todas las épocas pertenecientes a un mismo individuo permanecieron exclusivamente en entrenamiento interno o en validación interna. El procedimiento empleado para prevenir la fuga de información se describe en la Sección 3.6.2.

A diferencia de las arquitecturas de aprendizaje profundo, los modelos de referencia LogReg y Random Forest no requirieron una partición interna para parada temprana y se

ajustaron utilizando la totalidad del conjunto de entrenamiento externo de cada partición. En consecuencia, las arquitecturas profundas actualizaron sus parámetros utilizando un subconjunto menor de sujetos independientes, mientras que el conjunto de validación interna se reservó para controlar el entrenamiento y seleccionar el estado del modelo. Esta diferencia debe considerarse al interpretar las comparaciones entre modelos clásicos y arquitecturas profundas.

La configuración detallada del entrenamiento, incluyendo el optimizador, la tasa de aprendizaje, el tamaño de lote, el decaimiento de pesos, el *dropout*, el número máximo de épocas, la parada temprana, el planificador de la tasa de aprendizaje y la función de pérdida, se presenta en el Anexo B. En este anexo también se resumen los principales parámetros estructurales utilizados para cada una de las arquitecturas evaluadas.

3.5.3 Diseño de la comparación

El diseño experimental combinó los nueve modelos de clasificación con las representaciones definidas para cada enfoque y con la línea base sin ADF. A partir de estas configuraciones se establecieron tres comparaciones principales.

La primera comparación enfrentó las representaciones funcionales con la línea base basada en características espectrales escalares. Su propósito fue evaluar el comportamiento de los modelos cuando la información EEG se expresa mediante representaciones funcionales frente a una caracterización espectral convencional. Esta comparación debe interpretarse considerando que la línea base incorpora un conjunto espectral más amplio de bandas, por lo que no aísla exclusivamente el efecto de la representación funcional.

La segunda comparación se realizó entre las dos construcciones funcionales: el Enfoque A, definido sobre el dominio de la frecuencia, y el Enfoque B, definido sobre el orden normalizado de las épocas válidas. Esta comparación permitió evaluar dos formas diferentes de representar la información espectral: la forma continua del espectro y la variabilidad de las características theta y alfa entre épocas.

La tercera comparación se estableció dentro del Enfoque A entre las estrategias A1 y A2. Mientras A1 utiliza una única representación funcional por sujeto, obtenida después de promediar sus épocas válidas, A2 conserva las representaciones individuales por época durante el entrenamiento y agrega posteriormente las probabilidades a nivel de sujeto. Por tanto, A2 incrementa el número de observaciones disponibles para el ajuste sin aumentar el número de sujetos independientes.

En las arquitecturas de aprendizaje profundo, este mayor número de observaciones tam-

bién incrementa el número de actualizaciones de los parámetros realizadas en cada época de entrenamiento, dado que se mantiene un tamaño de lote fijo. En consecuencia, la comparación entre A1 y A2 debe interpretarse como una comparación entre estrategias de entrenamiento y no permite atribuir las diferencias observadas exclusivamente a la disponibilidad de múltiples representaciones por sujeto. El tratamiento de estas observaciones durante la partición, el entrenamiento y la evaluación se describe en la Sección 3.6.

El conjunto de configuraciones evaluadas y sus resultados se presenta en el Capítulo 4.

3.5.4 Análisis complementario para aislar el aporte específico del ADF

La comparación principal entre la línea base basada en características espectrales escalares y el Enfoque A permite contrastar distintas formas de representar la información espectral del EEG. Sin embargo, como se señaló en la Sección 3.5.3, estas estrategias difieren también en el intervalo frecuencial y en el nivel de detalle espectral conservado. Por esta razón, se planteó un análisis complementario orientado a examinar de forma más controlada el aporte específico de la representación mediante Análisis de Datos Funcionales.

Para este análisis se utilizó regresión logística como clasificador común en todas las representaciones. La elección de un único clasificador tuvo como propósito mantener constante el algoritmo de clasificación y centrar la comparación en la forma de representar la información de entrada, en lugar de evaluar simultáneamente diferencias asociadas con la arquitectura del modelo.

Se consideraron tres representaciones no funcionales. La primera estuvo constituida por las potencias relativas theta y alfa de los diez canales, complementadas con la frecuencia del pico alfa (PAF), para un total de 21 variables por sujeto. Esta configuración proporcionó una representación espectral resumida mediante características escalares.

La segunda representación conservó directamente la PSD relativa transformada logarítmicamente entre 4 Hz y 13 Hz sobre la malla frecuencial obtenida mediante el método de Welch. Dada la resolución aproximada de 0,5 Hz, se utilizaron 19 valores por canal, equivalentes a 190 variables por sujeto. Esta representación no empleó bases B-spline, transformación de Cholesky ni FPCA, por lo que se utilizó como control discretizado sin ADF sobre el mismo dominio frecuencial del Enfoque A.

Como tercer control se aplicó análisis de componentes principales (PCA) a la PSD discretizada entre 4 Hz y 13 Hz. El PCA se ajustó exclusivamente con los sujetos pertenecientes al conjunto de entrenamiento de cada partición y se retuvieron las componentes necesa-

rias para explicar al menos el 95 % de la varianza. Los sujetos del conjunto de prueba se proyectaron posteriormente utilizando únicamente los parámetros estimados sobre el entrenamiento.

Estas tres representaciones se compararon con las variantes de la estrategia A1 del Enfoque A: los coeficientes B-spline originales (X_{raw}), las coordenadas obtenidas mediante la transformación de Cholesky (X_{chol}) y la representación reducida mediante FPCA ($X_{\mathrm{chol+FPCA}}$). En todos los casos cada sujeto constituyó una única observación de entrada, manteniendo la misma unidad de análisis durante la comparación.

Todas las configuraciones se evaluaron utilizando las mismas quince evaluaciones externas definidas en la Sección 3.6, obtenidas mediante cinco particiones y tres semillas. La estandarización y, cuando correspondía, PCA o FPCA se ajustaron exclusivamente con los datos de entrenamiento de cada partición y se aplicaron posteriormente al conjunto de prueba.

Este análisis se diseñó para comparar, bajo un mismo clasificador y esquema de validación, una caracterización espectral resumida, una representación discretizada de la PSD y las representaciones funcionales de A1. De esta forma, se buscó evaluar por separado el efecto de conservar la estructura espectral detallada en el intervalo de 4 Hz a 13 Hz y el efecto de representarla mediante herramientas de ADF.

3.5.5 Interpretabilidad funcional mediante reconstrucción de funciones de peso

Como análisis complementario de interpretabilidad se empleó la estrategia A1 del Enfoque A, utilizando las coordenadas transformadas mediante Cholesky y regresión logística. Esta configuración permite relacionar de forma explícita los coeficientes de un clasificador lineal con el dominio funcional original y examinar qué regiones del espectro contribuyen a la decisión del modelo en cada canal.

Para un canal c, la curva espectral funcional se expresa mediante la base B-spline como

$$x_c(f) = \sum_{k=1}^{K} c_{ck}\phi_k(f), \tag{3.18}$$

donde c_{ck} corresponde al coeficiente asociado con la k-ésima función base. Como se describió en la Sección 3.4.4, las coordenadas utilizadas por el clasificador después de incorporar la geometría funcional se obtienen mediante

$$\mathbf{z}_c = \mathbf{c}_c L, \tag{3.19}$$

donde L corresponde al factor triangular inferior de la descomposición de Cholesky de la matriz de Gram, $G = LL^\top$.

Antes del ajuste de la regresión logística, las coordenadas se estandarizaron utilizando los parámetros estimados exclusivamente sobre el conjunto de entrenamiento de cada partición. Si $\mathbf{w}_c$ representa los coeficientes de la regresión logística estimados sobre las variables estandarizadas, $\boldsymbol{\mu}_c$ sus medias y $\mathbf{s}_c$ sus desviaciones estándar, los pesos correspondientes a las coordenadas de Cholesky se recuperaron como

$$\mathbf{a}_c = \mathbf{w}_c \oslash \mathbf{s}_c, \tag{3.20}$$

donde $\oslash$ representa la división elemento a elemento. El intercepto se ajustó de forma correspondiente para deshacer el efecto del centrado utilizado durante la estandarización.

A partir de la relación $\mathbf{z}_c = \mathbf{c}_c L$, los coeficientes de la función de peso sobre la base B-spline original se obtuvieron mediante

$$\mathbf{b}_c = L^{-\top} \mathbf{a}_c. \tag{3.21}$$

De esta forma se reconstruyó, para cada canal, una función de peso continua sobre el dominio frecuencial,

$$\beta_c(f) = \sum_{k=1}^{K} b_{ck} \phi_k(f). \tag{3.22}$$

Con esta parametrización, el predictor lineal de la regresión logística puede expresarse mediante productos internos funcionales como

$$\eta = \beta_0^* + \sum_{c=1}^{10} \int_4^{13} x_c(f) \beta_c(f)\, df, \tag{3.23}$$

donde β_0^* representa el intercepto después de deshacer la estandarización.

La reconstrucción se realizó independientemente en cada una de las quince evaluaciones externas. Como verificación numérica del procedimiento, se comprobó en cada partición que el predictor lineal obtenido mediante las funciones de peso reconstruidas coincidiera con el producido directamente por la regresión logística.

La estabilidad de las funciones $\beta_c(f)$ se examinó entre particiones para cada canal. Para ello se consideraron la función media, su variabilidad entre particiones, la correlación entre las funciones reconstruidas y la concordancia del signo a lo largo del dominio. Adicionalmente, los pesos se resumieron en intervalos frecuenciales de interés neurofisiológico: theta (4–8 Hz), theta lenta (4–5,5 Hz), theta rápida o pre-alfa (5,5–8 Hz) y alfa (8–13 Hz). Para cada intervalo se calcularon resúmenes de la magnitud y del signo de la función de peso a través de las particiones.

Dado que las funciones B-spline situadas en los extremos del dominio presentan un soporte distinto al de las funciones interiores, se realizó además un análisis de sensibilidad de borde. Este análisis examinó el condicionamiento de la matriz de Gram y la amplitud relativa de las funciones de peso en los extremos respecto de la región interior, con el propósito de identificar posibles amplificaciones asociadas con la parametrización de la base antes de realizar su interpretación neurofisiológica.

El signo de $\beta_c(f)$ se interpretó de acuerdo con la codificación del clasificador, donde PD_OFF corresponde a la clase positiva. Por tanto, valores positivos de la función de peso indican una contribución hacia un mayor *log-odds* predicho de PD_OFF, mientras que valores negativos indican una contribución en la dirección de HC, condicionada al resto de las variables incluidas en el modelo. Estas funciones se emplearon como herramienta de interpretación del clasificador y no como estimaciones causales ni como pruebas inferenciales de diferencias poblacionales entre los grupos.

3.6 ESQUEMA DE VALIDACIÓN Y MÉTRICAS

La estrategia de evaluación se diseñó para preservar la independencia entre sujetos y reducir el riesgo de fuga de información durante el entrenamiento. En todas las configuraciones, el sujeto se consideró la unidad final de evaluación, incluso cuando el entrenamiento se realizó utilizando múltiples épocas por individuo. A continuación se describen el esquema de validación cruzada, las medidas de control de fuga de información, la agregación de predicciones y las métricas empleadas.

3.6.1 Validación cruzada agrupada por sujeto

La evaluación externa se realizó mediante validación cruzada estratificada y agrupada por sujeto (`StratifiedGroupKFold`) con cinco particiones. El identificador del sujeto se utilizó como variable de agrupación, garantizando que todas las observaciones correspondientes a un mismo individuo permanecieran exclusivamente en entrenamiento o en prueba dentro de cada partición.

Este criterio es especialmente importante en A2, donde un sujeto aporta múltiples épocas correlacionadas. Una partición realizada directamente por épocas podría introducir información del mismo individuo en entrenamiento y prueba y producir una estimación optimista de la capacidad de generalización.

La estratificación mantuvo una distribución comparable de las clases HC y PD entre las particiones. El procedimiento se repitió con tres semillas (42, 123 y 2024), obteniéndose quince evaluaciones externas (cinco particiones por tres semillas).

3.6.2 Prevención de fuga de información

Todas las transformaciones dependientes de los datos se ajustaron utilizando exclusivamente la información disponible en el conjunto de entrenamiento de cada partición externa, sin utilizar datos del conjunto de prueba. Esto incluyó la estandarización de las características y, cuando correspondía, la reducción mediante FPCA (Sección 3.4.5). Una vez ajustadas, estas transformaciones se aplicaron al conjunto de prueba sin volver a estimar sus parámetros.

Para las arquitecturas de aprendizaje profundo, el conjunto de entrenamiento externo se dividió adicionalmente en entrenamiento interno y validación interna para aplicar parada temprana, manteniendo la separación por sujeto. En A1 y en el Enfoque B, la estandarización y, cuando correspondía, la FPCA se ajustaron sobre el conjunto de entrenamiento externo antes de realizar esta división. Por tanto, los sujetos destinados a validación interna participaron en el ajuste no supervisado de dichas transformaciones. En la estrategia A2, la división interna se realizó antes de ajustar las transformaciones; la FPCA y el escalador se estimaron exclusivamente con el entrenamiento interno y se aplicaron posteriormente a la validación interna y a la prueba externa.

Como control adicional, el procedimiento verificó en cada partición la ausencia de sujetos compartidos entre los conjuntos correspondientes y detuvo la ejecución si esta condición no se cumplía. De esta forma, el conjunto de prueba externo permaneció aislado durante todo el proceso de ajuste y selección del modelo.

3.6.3 Agregación de predicciones a nivel de sujeto

En A2, los modelos generan inicialmente una probabilidad para cada época. Para obtener una única predicción por individuo, las probabilidades correspondientes a todas las épocas del mismo sujeto se promediaron:

$$\hat{p}_s = \frac{1}{E_s} \sum_{e=1}^{E_s} \hat{p}_{s,e}, \tag{3.24}$$

donde E_s es el número de épocas evaluadas del sujeto s y $\hat{p}_{s,e}$ la probabilidad estimada para la época e.

Las métricas se calcularon posteriormente utilizando una única probabilidad y una única etiqueta por sujeto. De esta manera, los individuos con mayor número de épocas no adquieren un peso mayor en la evaluación final. En A1 y en el Enfoque B cada sujeto constituye directamente una observación, por lo que no se requiere esta agregación.

3.6.4 Métricas de evaluación

El desempeño se evaluó mediante varias métricas complementarias calculadas a nivel de sujeto. Se incluyeron sensibilidad, especificidad y exactitud balanceada para caracterizar por separado el comportamiento del clasificador en ambas clases. Se consideró PD como clase positiva y HC como clase negativa.

La **sensibilidad** es la proporción de pacientes correctamente identificados y la especificidad es la proporción de personas sanas correctamente identificadas:

$$\text{Sensibilidad} = \frac{\text{VP}}{\text{VP} + \text{FN}}, \qquad \text{Especificidad} = \frac{\text{VN}}{\text{VN} + \text{FP}}. \tag{3.25}$$

La **exactitud balanceada** corresponde a la media entre sensibilidad y especificidad, por lo que otorga el mismo peso al desempeño del clasificador en ambas clases:

$$\text{Exactitud balanceada} = \frac{\text{Sensibilidad} + \text{Especificidad}}{2}. \tag{3.26}$$

El **F1-score** combina la precisión, es decir, la proporción de aciertos entre los sujetos que el modelo marca como pacientes, con la sensibilidad, mediante su media armónica:

$$\text{Precisión} = \frac{\text{VP}}{\text{VP} + \text{FP}}, \qquad F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}. \tag{3.27}$$

Por último, el **área bajo la curva ROC** (AUC) resume la capacidad de discriminación del clasificador considerando todos los posibles umbrales de decisión. Puede interpretarse como la probabilidad de que una observación positiva seleccionada al azar reciba una puntuación mayor que una observación negativa seleccionada al azar. El AUC toma valores entre 0 y 1; un valor de 0,5 indica ausencia de capacidad discriminante, mientras que valores próximos a 1 indican una mejor separación entre las clases.

El umbral de decisión para las métricas dependientes de clase se fijó en 0,5. Para cada configuración, las métricas se resumieron mediante la media y la desviación estándar de las quince evaluaciones externas. Adicionalmente, se examinaron matrices de confusión a nivel de sujeto para caracterizar la distribución de aciertos y errores.

3.7 ANÁLISIS ESTADÍSTICO

Las comparaciones estadísticas entre los grupos HC y PD se realizaron como parte de la caracterización de la cohorte y del análisis espectral. Dado el tamaño moderado de los grupos y que no se estableció como requisito una distribución normal de las variables continuas, se adoptó un enfoque no paramétrico para estas comparaciones. Este tipo de pruebas también ha sido empleado en estudios previos de EEG de reposo en enfermedad de Parkinson, seleccionándose de acuerdo con las características de las variables analizadas [8].

Para las variables cuantitativas, entre ellas la edad, el número de épocas válidas por sujeto, el número de componentes ICA excluidos por sesión y la frecuencia del pico alfa (PAF), se utilizó la prueba U de Mann–Whitney para dos muestras independientes. Esta prueba opera sobre los rangos de las observaciones y permite evaluar diferencias en la distribución de los valores entre ambos grupos sin requerir el supuesto de normalidad. Todas las pruebas se plantearon de forma bilateral.

Para la variable categórica sexo se utilizó la prueba χ^2 de independencia, con el propósito de evaluar la asociación entre la distribución por sexo y el grupo de estudio.

En las comparaciones de la PAF y del número de componentes ICA excluidos, el valor p se complementó con el tamaño de efecto rank-biserial, con el fin de cuantificar la magnitud de las diferencias entre los grupos. A partir del estadístico U de Mann-Whitney se calculó como

$$r_{\mathrm{rb}} = 1 - \frac{2U}{n_1 n_2}, \tag{3.28}$$

donde n_1 y n_2 representan los tamaños de los grupos. El coeficiente toma valores entre -1 y 1; valores próximos a cero indican una elevada superposición entre las distribuciones, mientras que una mayor magnitud absoluta indica una mayor separación. El signo depende del orden asignado a los grupos en el cálculo.

El nivel de significancia se fijó en $\alpha = 0{,}05$. No se aplicó una corrección formal por comparaciones múltiples, dado que los contrastes estadísticos correspondieron a un conjunto reducido de análisis descriptivos definidos previamente. Por esta razón, los valores p se interpretaron junto con la magnitud del efecto y el contexto neurofisiológico, y no de forma aislada.

El análisis inferencial descrito en esta sección se aplicó a la caracterización de los grupos y no a la comparación formal entre los modelos de clasificación.

3.8 HERRAMIENTAS COMPUTACIONALES

El desarrollo computacional se realizó en **Python**, utilizando **Google Colab** como entorno de ejecución y Google Drive para el almacenamiento de datos, resultados intermedios y salidas experimentales. Para el entrenamiento de las arquitecturas de aprendizaje profundo se empleó aceleración mediante GPU NVIDIA T4.

El preprocesamiento de las señales EEG se implementó con **MNE-Python** [62]. Las operaciones numéricas y el procesamiento espectral se realizaron principalmente con **NumPy** y **SciPy**; esta última se utilizó para la estimación espectral mediante Welch, la integración numérica mediante la regla de Simpson y las operaciones de álgebra lineal requeridas en la construcción de la matriz de Gram y su factorización de Cholesky. **pandas** se utilizó para la organización, manipulación y almacenamiento de los resultados tabulares generados durante las distintas etapas del análisis.

La construcción de las representaciones funcionales se realizó mediante herramientas de propósito general. Las bases B-spline se generaron con `SplineTransformer` de **scikit-learn** [68]. La transformación asociada con la geometría funcional se implementó mediante las rutinas de álgebra lineal de SciPy, mientras que la FPCA se llevó a cabo mediante análisis de componentes principales aplicado sobre las coordenadas transformadas por Cholesky, según el procedimiento descrito en la Sección 3.4.5.

scikit-learn se utilizó además para la estandarización de las características, los modelos de referencia, la validación cruzada estratificada y agrupada por sujeto, y el cálculo de las métricas de evaluación. Las arquitecturas de aprendizaje profundo se implementaron con **PyTorch**, y las figuras y visualizaciones de los análisis se generaron principalmente con **Matplotlib**.

Para favorecer la reproducibilidad, se fijaron semillas en los procedimientos con componentes aleatorios y los experimentos de clasificación se repitieron con las semillas 42, 123 y 2024. Asimismo, las distintas etapas del flujo se organizaron en cuadernos independientes de preprocesamiento, construcción de representaciones funcionales y modelado, almacenando resultados intermedios para evitar repetir transformaciones previas y facilitar la trazabilidad entre las etapas del análisis.

Como referencia del entorno computacional documentado al cierre del proyecto, se registraron las siguientes versiones de las principales dependencias: Python 3.13.15, MNE-Python 1.12.1, NumPy 2.1.3, SciPy 1.16.3, pandas 2.2.3, scikit-learn 1.6.1, PyTorch 2.11.0 y Matplotlib 3.10.0.

El código, la estructura de ejecución y los archivos de trazabilidad necesarios para reproducir los experimentos se encuentran disponibles en el repositorio indicado en el Anexo C.

3.9 SÍNTESIS DEL FLUJO METODOLÓGICO

El flujo metodológico integró el preprocesamiento del EEG, la estimación de la PSD, la construcción de la línea base y de las representaciones funcionales A y B, y la evaluación de los clasificadores manteniendo la separación por sujeto. Como análisis complementarios, se realizó una comparación controlada del aporte del ADF y un análisis de interpretabilidad mediante funciones de peso.

La Figura 3.3 resume el flujo metodológico.

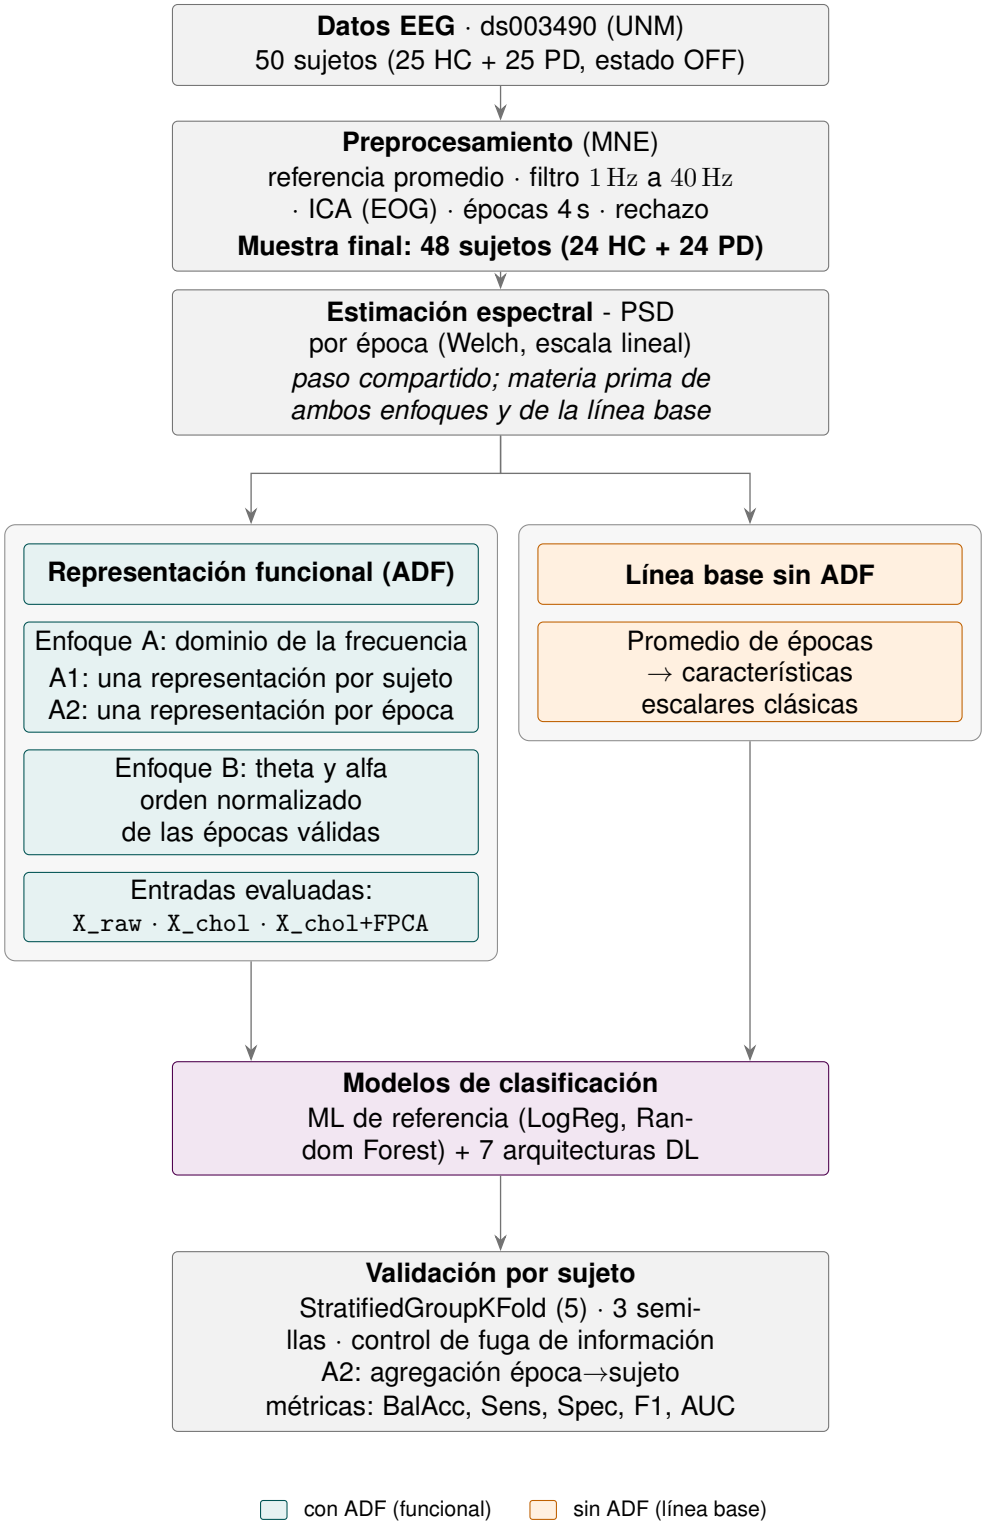


Figura 3.3: Esquema general de la metodología propuesta. Elaboración propia.

4. RESULTADOS

El método descrito en el capítulo anterior se aplicó sobre la cohorte de estudio para evaluar en qué medida la representación funcional de las señales EEG permite distinguir entre pacientes con enfermedad de Parkinson y personas sanas. Los resultados se presentan a continuación, cada uno acompañado del experimento que lo genera y de su lectura neurofisiológica.

4.1 PREPROCESAMIENTO Y LIMPIEZA DE LA SEÑAL

El capítulo de metodología describe el procedimiento de preprocesamiento (Sección 3.2); esta sección muestra su efecto sobre la cohorte: cuánto se limpió la señal, cuántos artefactos se eliminaron y con qué calidad quedaron los datos que alimentan la representación funcional.

4.1.1 Filtrado y corrección de artefactos

El efecto de las etapas de limpieza se ilustra en la Figura 4.1 en el dominio temporal y en las Figuras 4.2 y 4.3 en el dominio de la frecuencia. La comparación temporal muestra ejemplos de un sujeto HC y un sujeto PD_OFF antes y después del preprocesamiento, mientras que las comparaciones espectrales presentan la PSD en el canal Pz para un sujeto de cada grupo. En el dominio del tiempo se observa una reducción de las derivas lentas y de los transitorios presentes en el registro crudo. En el dominio de la frecuencia, el filtrado atenúa las componentes fuera del intervalo de análisis, incluido el contenido asociado a la red eléctrica, y conserva la banda de interés.

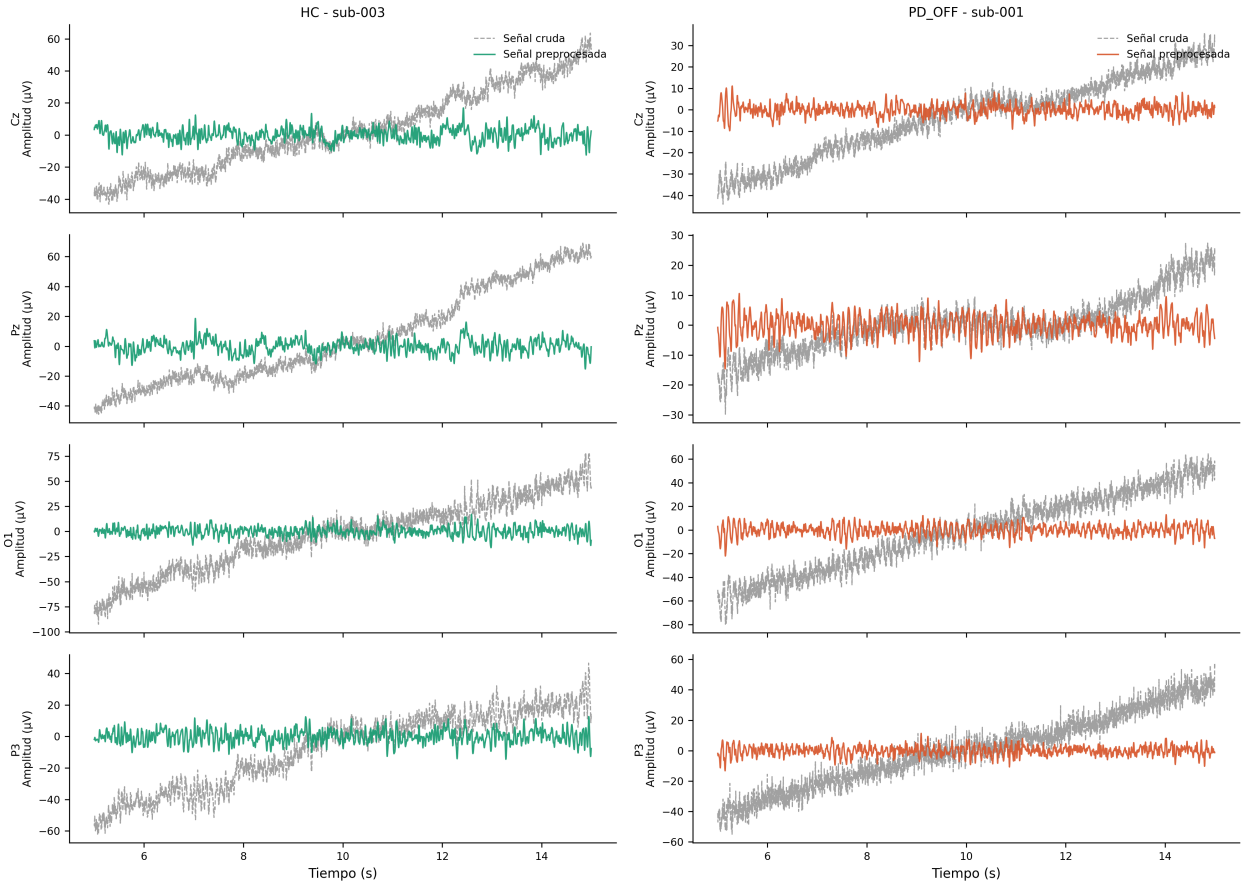


Figura 4.1: Comparación temporal antes y después del preprocesamiento en ejemplos de HC y PD_OFF. Elaboración propia con datos de OpenNeuro ds003490.

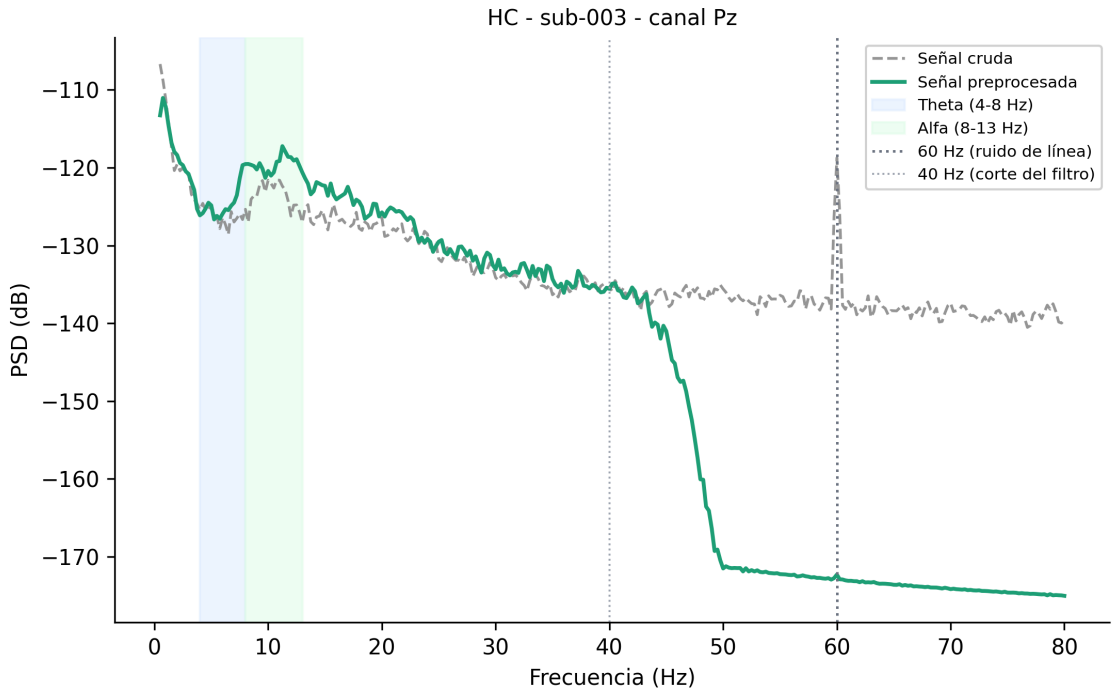


Figura 4.2: Comparación espectral antes y después del preprocesamiento en un sujeto HC, canal Pz. Elaboración propia con datos de OpenNeuro ds003490.

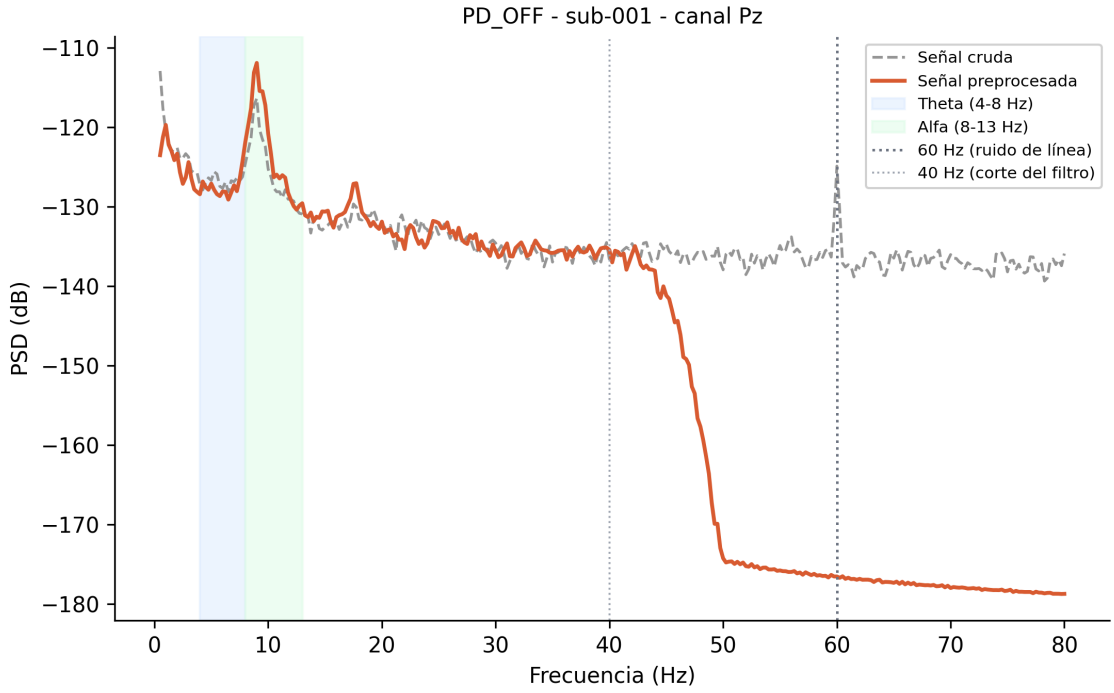


Figura 4.3: Comparación espectral antes y después del preprocesamiento en un sujeto PD_OFF, canal Pz. Elaboración propia con datos de OpenNeuro ds003490.

Como indicador del proceso de corrección, se registró el número de componentes ICA excluidos por sesión. En promedio, se eliminaron $1,20 \pm 0,65$ componentes en HC y $0,52 \pm 0,59$ en PD_OFF, con una media global de $0,86 \pm 0,70$ componentes por sesión (Tabla 4.1). La comparación entre grupos mediante la prueba U de Mann–Whitney mostró una diferencia estadísticamente significativa en el número de componentes excluidos ($U = 474,5$; $p = 0,0006$), con un tamaño de efecto rank-biserial de magnitud $|r_{rb}| = 0,518$. Por tanto, el procedimiento automático de corrección identificó y excluyó un mayor número de componentes asociados con actividad ocular en HC que en PD_OFF.

Este resultado describe una diferencia entre grupos en la salida del procedimiento de corrección mediante ICA, pero no permite inferir por sí solo que los participantes HC presentaran una mayor cantidad de artefactos oculares ni atribuir dicha diferencia a la condición clínica. El número de componentes identificados puede estar influido por características de la actividad ocular, la señal EOG, la calidad del registro y la propia descomposición ICA. El procedimiento, el umbral de detección y el límite máximo de dos componentes excluidos por sesión fueron los mismos para ambos grupos.

La corrección mediante ICA se realizó antes de la segmentación de la señal en épocas. Por tanto, la exclusión de componentes ICA no constituyó un criterio directo para el rechazo posterior de épocas; este último se basó exclusivamente en los criterios de amplitud pico a pico y curtosis descritos en la Sección 4.1.2.

Tabla 4.1: Componentes ICA excluidos durante la corrección de artefactos.

Grupo	Componentes ICA excluidos por sesión
HC	$1{,}20 \pm 0{,}65$
PD_OFF	$0{,}52 \pm 0{,}59$
Total	$0{,}86 \pm 0{,}70$

Fuente: elaboración propia con datos de OpenNeuro ds003490.

4.1.2 Rechazo de épocas y control de calidad

Tras segmentar la señal en épocas de $4\,\mathrm{s}$, se aplicó un criterio combinado de control de calidad para identificar artefactos residuales. Una época se descartó si presentaba una amplitud pico a pico superior a $100\,\mu\mathrm{V}$ o una curtosis que se apartara de forma marcada de la distribución del registro (Sección 3.2).

Como resultado de este procedimiento, entre las 48 sesiones finalmente incluidas se conservó, en promedio por sesión, el $95{,}5\,\%$ de las épocas en HC y el $96{,}4\,\%$ en PD, con una media global de $95{,}9\,\%$. La Tabla 4.2 resume la conservación de épocas en la muestra final.

Tabla 4.2: Conservación de épocas en las sesiones incluidas.

Grupo	Sesiones incluidas/total	Conservación media por sesión (%)
HC	24/25	95,5
PD_OFF	24/25	96,4
Total	48/50	95,9

Fuente: elaboración propia con datos de OpenNeuro ds003490.

Para caracterizar la contribución de cada criterio de control de calidad, se calcularon además sus tasas de marcado sobre las épocas generadas en las 50 sesiones candidatas, antes de la exclusión de sesiones. El criterio de amplitud pico a pico (PTP) marcó el $7{,}0\,\%$ de las épocas, mientras que el criterio de curtosis marcó el $0{,}5\,\%$. La Tabla 4.3 presenta estas tasas por grupo.

Tabla 4.3: Tasas de marcado de los criterios de rechazo sobre las 50 sesiones candidatas.

Grupo	Épocas generadas	Marcadas por PTP (%)	Marcadas por curtosis (%)
HC	410	6,6	1,0
PD_OFF	375	7,5	0,0
Total	785	7,0	0,5

Fuente: elaboración propia con datos de OpenNeuro ds003490.

Las tasas de marcado corresponden a los mismos criterios utilizados para el rechazo de épocas, pero se calcularon sobre el conjunto completo de 50 sesiones candidatas. Por esta razón, no son directamente comparables con el porcentaje medio de conservación calculado sobre las 48 sesiones incluidas. Asimismo, las tasas de PTP y curtosis no deben sumarse para estimar el porcentaje total de rechazo, ya que una misma época puede cumplir simultáneamente ambos criterios.

El criterio de curtosis tuvo una contribución marginal al rechazo de épocas ($0{,}5\,\%$ en el conjunto completo). En el grupo PD no se identificaron épocas que superaran el umbral establecido. Estas tasas se interpretan únicamente como indicadores descriptivos del proceso de control de calidad y no como evidencia de diferencias entre los grupos.

De las 50 sesiones candidatas, dos se excluyeron por no alcanzar el mínimo de épocas válidas establecido para el análisis posterior, una de cada grupo. La muestra final quedó constituida por 48 sujetos (24 HC y 24 PD), como se describe en la Sección 3.1.

No se observaron diferencias estadísticamente significativas en el número de épocas conservadas entre HC y PD (prueba U de Mann–Whitney, $U = 262$, $p = 0{,}493$). Por tanto, no se encontró evidencia de una retención diferencial de épocas entre los grupos.

4.2 CARACTERIZACIÓN ESPECTRAL DE LOS DATOS

Antes de evaluar la capacidad de clasificación, se examinó si la cohorte presentaba un patrón espectral compatible con el enlentecimiento descrito en la enfermedad de Parkinson [6], [69]. Esta caracterización permite contextualizar las representaciones funcionales y describir la cohorte con métodos estadísticos convencionales, de manera independiente del clasificador.

4.2.1 Dominancia y distribución espacial del ritmo alfa

En reposo con ojos cerrados, la actividad cerebral está dominada por el ritmo alfa ($8\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$), que refleja la actividad rítmica del sistema tálamo-cortical. La Figura 4.4 muestra la densidad espectral de potencia relativa promediada por región para cada grupo. Se sombrea el intervalo funcional de $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$, que comprende theta ($4\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$) y alfa ($8\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$) y que constituye el dominio continuo del Enfoque A. Las curvas se presentan con su intervalo de confianza del $95\,\%$. El pico alfa aparece en todas las regiones y es el componente dominante en esta condición de registro. Incluir también theta permite que la representación funcional capture el desplazamiento de potencia hacia frecuencias más lentas y la transición theta-alfa asociada al enlentecimiento espectral.

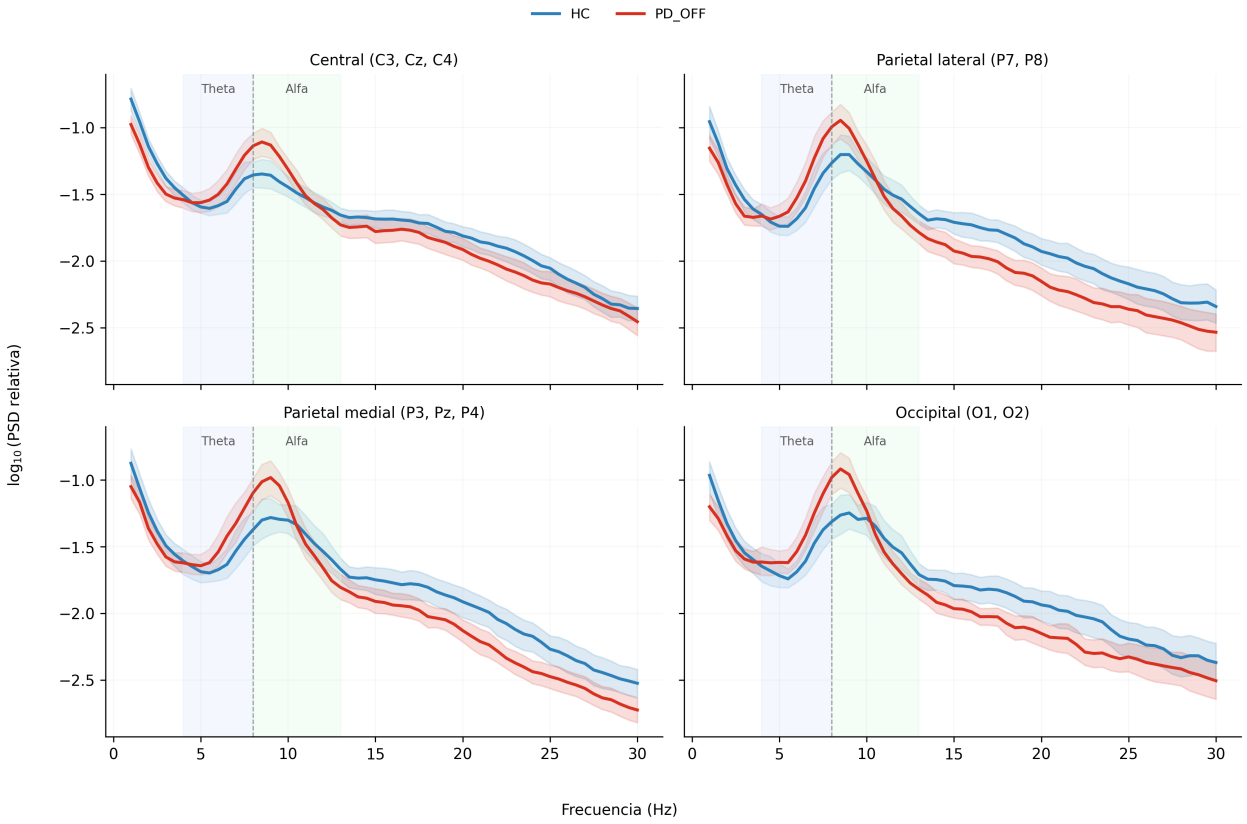


Figura 4.4: Densidad espectral de potencia relativa por región en HC y PD_OFF. Elaboración propia con datos de OpenNeuro ds003490.

El aspecto de mayor interés para este trabajo es el desplazamiento del contenido espectral de los pacientes hacia frecuencias más bajas, visible en la región theta-alfa y cuantificado en el apartado siguiente mediante la frecuencia del pico alfa. Las diferencias observadas fuera del intervalo $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$ se consideran descriptivas y no forman parte de las representaciones funcionales utilizadas para la clasificación.

4.2.2 Enlentecimiento del pico alfa

Una manifestación relevante del enlentecimiento espectral descrito en Parkinson es el desplazamiento de la actividad dominante hacia frecuencias más bajas, acompañado en distintos estudios por cambios relativos en theta y alfa [6], [8]. En esta cohorte, ese fenómeno se cuantificó mediante la frecuencia del pico alfa (*Peak Alpha Frequency*, PAF), que resume la posición espectral alrededor de la cual se concentra la potencia en el intervalo alfa [14].

La PAF se calculó sobre los canales posteriores (O1, O2, Pz, P3 y P4), donde el ritmo

alfa se expresa con más claridad, promediando el contenido espectral por sujeto. Dentro de la banda de $7\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$, la PAF se estimó como el centro de gravedad del espectro, es decir, la media de las frecuencias ponderada por su potencia, que da una estimación estable y poco sensible al ruido.

La comparación de la PAF entre grupos se realizó con la prueba U de Mann-Whitney y el tamaño de efecto rank-biserial, según lo descrito en la Sección 3.7. El análisis mediante centro de gravedad evidenció una PAF menor en los pacientes (mediana 9,06 Hz) que en los controles (mediana 9,60 Hz), con una diferencia de aproximadamente 0,54 Hz. La prueba U de Mann–Whitney mostró una diferencia estadísticamente significativa ($U = 418$, $p = 0,0076$, bilateral), con un tamaño de efecto rank-biserial de $-0,451$. Una estimación alternativa basada en la frecuencia de máxima potencia mostró la misma dirección, pero no alcanzó significancia ($p = 0{,}167$); por tanto, se interpreta como evidencia complementaria y no como una confirmación independiente.

El enlentecimiento del PAF observado en la caracterización no se incorporó como una característica adicional independiente a los modelos. Sin embargo, el patrón neurofisiológico que cuantifica sí está contenido en las representaciones utilizadas para la clasificación. La línea base incluye la frecuencia dominante como característica espectral, mientras que el Enfoque A conserva la forma completa del espectro entre $4\,\mathrm{Hz}$ y $13\,\mathrm{Hz}$, incluida la posición del pico alfa. De este modo, la caracterización permite identificar y cuantificar un patrón que posteriormente puede ser aprovechado por los clasificadores a través de las representaciones espectrales empleadas.

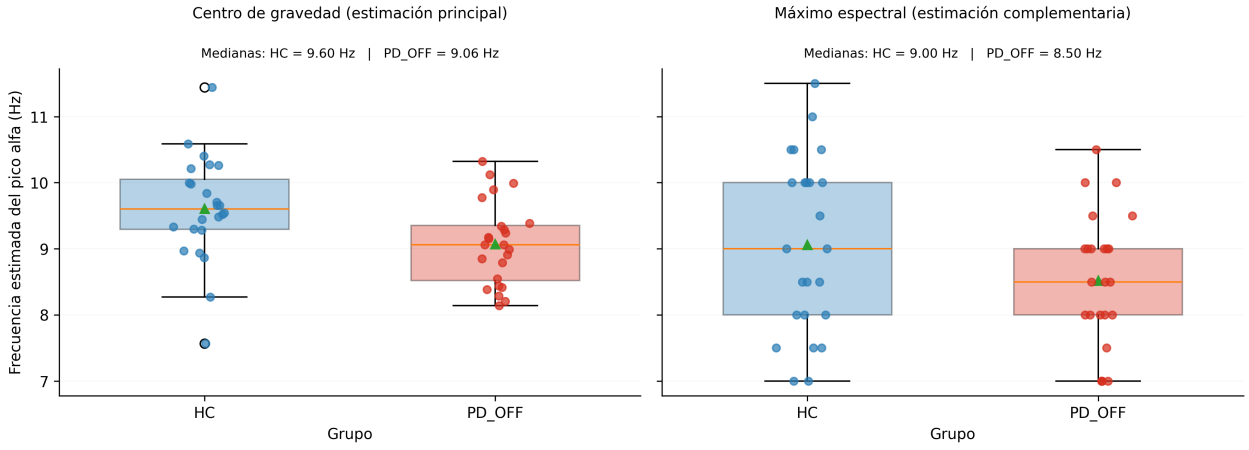


Figura 4.5: Distribución de la frecuencia del pico alfa en personas sanas y pacientes. Elaboración propia con datos de OpenNeuro ds003490.

4.3 CONFIGURACIÓN Y CARACTERIZACIÓN DE LA REPRESENTACIÓN FUNCIONAL

Fijadas las decisiones que la metodología deja abiertas, esta sección concreta cómo se configuraron las representaciones funcionales utilizadas posteriormente en los modelos de clasificación. Primero se justifica la elección de la familia B-spline. Después se selecciona la complejidad de la base de forma independiente para los enfoques A y B, se valida la transformación de Cholesky y se caracteriza la reducción de dimensión mediante FPCA. Finalmente, se muestran ejemplos que integran las distintas etapas de la representación funcional y permiten visualizar qué información se conserva antes de su entrada a los modelos. Las comparaciones visuales entre HC y PD_OFF presentadas en esta sección tienen carácter descriptivo y no constituyen, por sí solas, evidencia de separación estadística entre los grupos.

4.3.1 Elección de la base funcional

La familia B-spline se adoptó como representación común de las curvas funcionales (Sección 3.4.1). Como análisis de sensibilidad, en el Enfoque A se contrastó esta elección con una P-spline sobre el mismo dominio espectral de $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$. La P-spline utilizó una base de 17 coeficientes y el GCV seleccionó una penalización $\lambda = 2{,}15 \times 10^{-2}$, con aproximadamente $11{,}5$ grados de libertad efectivos. Aunque el ajuste penalizado obtuvo un GCV menor, ambas representaciones reprodujeron adecuadamente la forma espectral en el intervalo analizado.

Se mantuvo B-spline para el Enfoque A definitivo porque permitió representar las curvas con 11 coeficientes por canal, frente a los 17 utilizados con P-spline, conservando una reconstrucción funcional adecuada y una representación más compacta y uniforme entre sujetos y canales. La Figura 4.6 muestra esta comparación como análisis de sensibilidad de la representación funcional.

En el Enfoque B se conservó la misma familia B-spline para mantener un marco funcional homogéneo entre ambas representaciones. Sin embargo, la complejidad se seleccionó nuevamente mediante GCV y de forma independiente para las bandas theta y alfa. De este modo, la familia de base se mantuvo común entre los enfoques A y B, mientras que el número de funciones base se adaptó a la estructura específica de cada representación.

4.3.2 Enfoque A: selección de la base y representación funcional

Para las curvas espectrales del Enfoque A, construidas según lo descrito en la Sección 3.4.2, se fijó el número de funciones base mediante validación cruzada generalizada

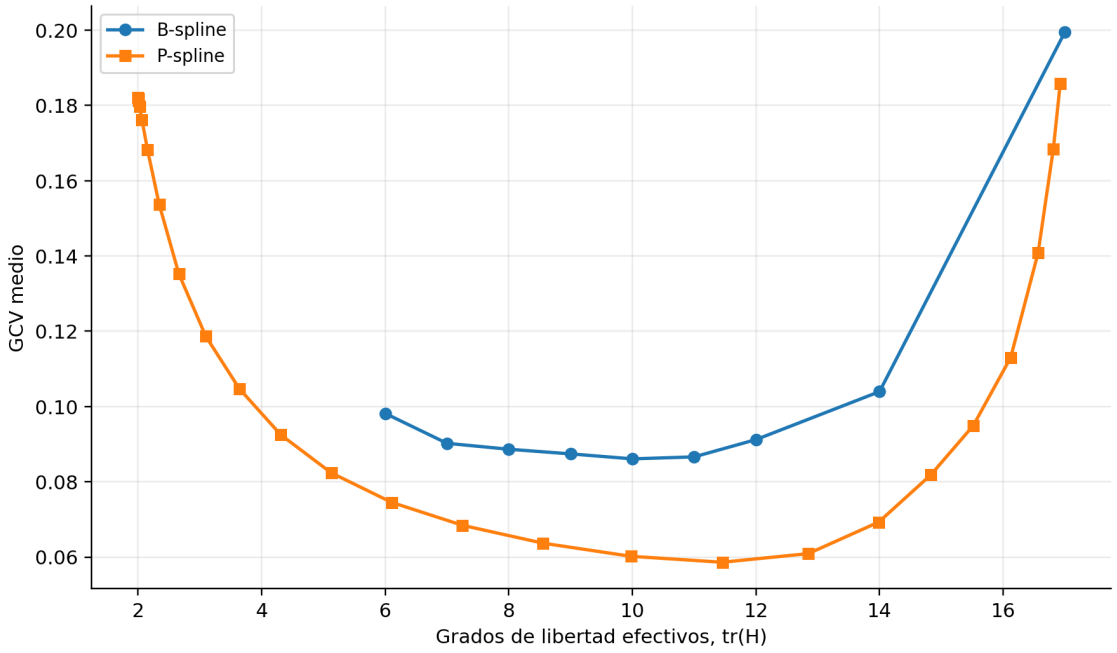


Figura 4.6: Comparación entre B-spline y P-spline en el Enfoque A. Elaboración propia con datos de OpenNeuro ds003490.

(GCV). El GCV medio presentó un perfil en forma de valle y alcanzó su mínimo en **9 nudos**, equivalentes a **11 funciones base**, que fue el valor adoptado (Figura 4.7).

Una vez fijada la dimensión de la base, se examinaron las curvas funcionales obtenidas. La Figura 4.8 muestra las representaciones B-spline del Enfoque A en el intervalo de $4\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$. Las curvas funcionales conservan la forma general del espectro, incluida la transición theta-alfa y la localización del máximo espectral, mientras atenúan las irregularidades locales de la estimación de PSD.

Las curvas individuales permiten observar la variabilidad entre sujetos y canales, mientras que las medias funcionales de HC y PD_OFF facilitan la comparación descriptiva entre ambos grupos.

Cada canal queda representado por 11 coeficientes B-spline. Por tanto, considerando los diez canales seleccionados, la representación inicial del Enfoque A contiene 110 coeficientes. En la estrategia A1 estos coeficientes describen una única observación por sujeto, mientras que en A2 corresponden a cada época válida utilizada como observación durante el entrenamiento.

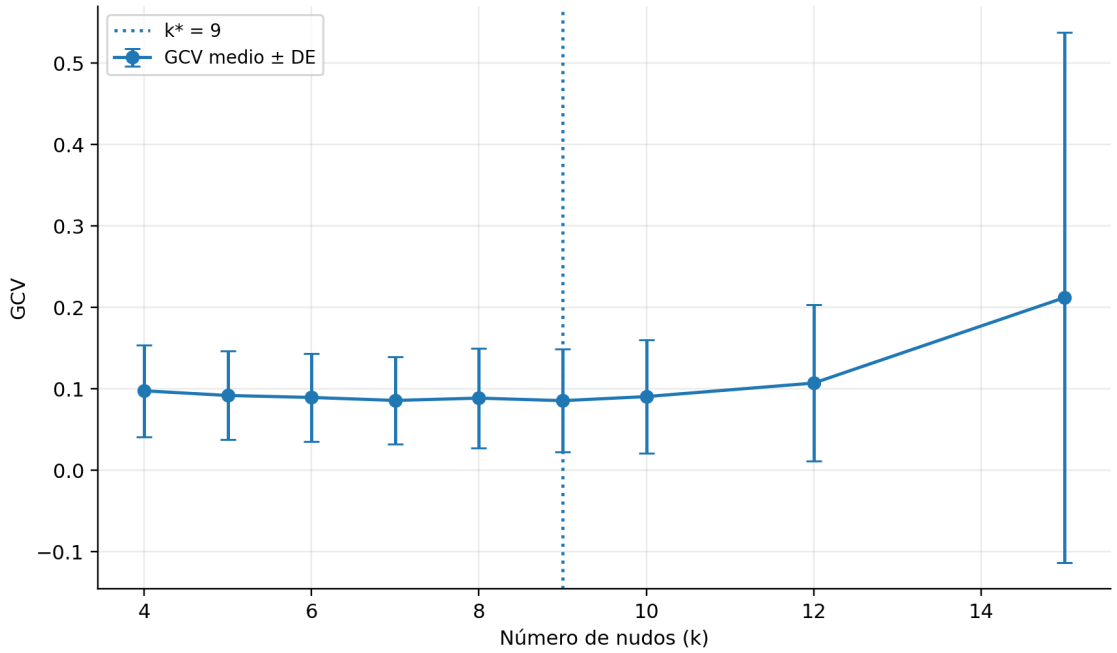


Figura 4.7: Selección del número de nudos por GCV en el Enfoque A. Elaboración propia con datos de OpenNeuro ds003490.

4.3.3 Enfoque B: selección de la base y representación funcional

El Enfoque B representa, para cada sujeto y canal, la potencia relativa logarítmica de las bandas theta ($4\,\mathrm{Hz}$ a $8\,\mathrm{Hz}$) y alfa ($8\,\mathrm{Hz}$ a $13\,\mathrm{Hz}$) a lo largo del orden normalizado de las épocas válidas conservadas después del preprocesamiento. La complejidad de la base B-spline se seleccionó de forma independiente para cada banda mediante validación cruzada generalizada (GCV).

Como se observa en la Figura 4.9, tanto para theta como para alfa el menor valor de GCV se obtuvo con la configuración de menor complejidad evaluada, correspondiente a cuatro funciones B-spline por banda. A partir de esta configuración, el GCV aumentó progresivamente al incrementar el número de nudos. Este comportamiento indica que, dentro del rango analizado, el aumento de la flexibilidad de la base no produjo una mejora del ajuste suficiente para compensar el incremento de complejidad. En consecuencia, se adoptó la representación de menor GCV para el análisis posterior.

Una vez fijada la dimensión de la base, se reconstruyeron las trayectorias funcionales correspondientes a las dos bandas. Las Figuras 4.10 y 4.11muestra las representaciones obtenidas mediante B-splines. En las dos graficas de la primera fila, las líneas grises corresponden a las trayectorias funcionales de las distintas combinaciones sujeto-canal, mientras que la línea de mayor grosor representa su media dentro de cada grupo. La

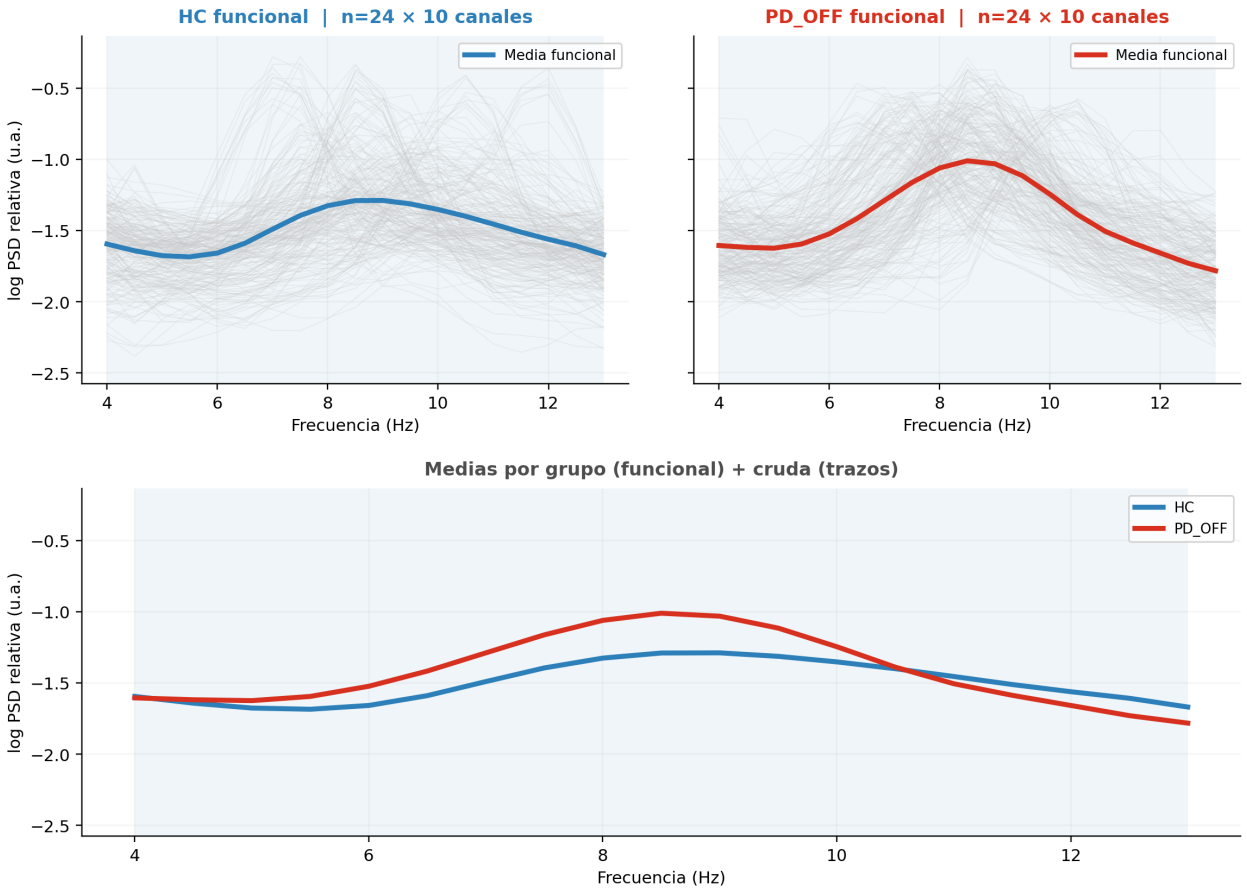


Figura 4.8: Curvas funcionales del Enfoque A en HC y PD_OFF. Elaboración propia con datos de OpenNeuro ds003490.

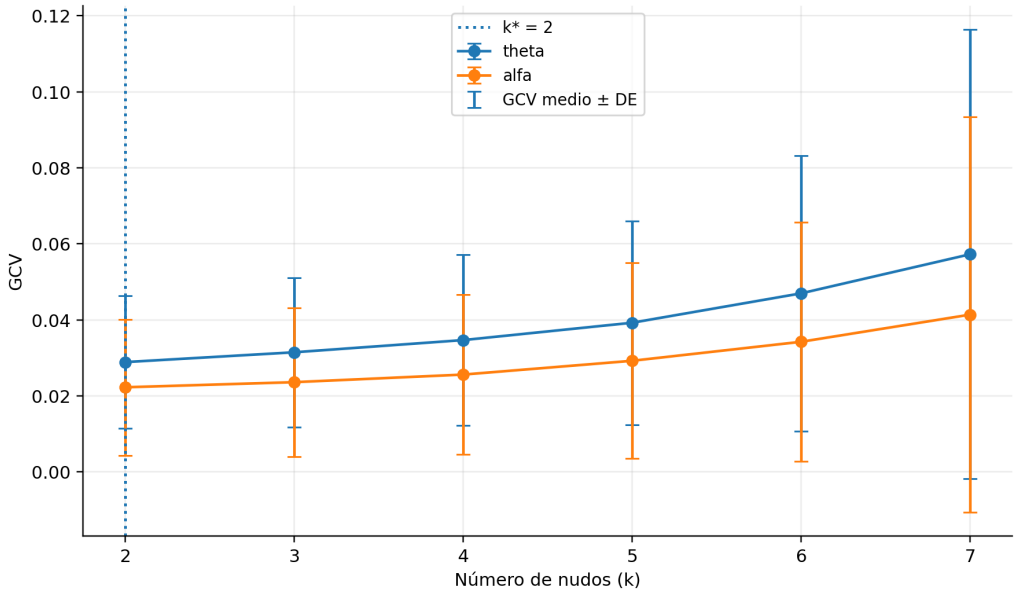


Figura 4.9: Selección del número de nudos por GCV en theta y alfa. Elaboración propia con datos de OpenNeuro ds003490.

figura de la parte inferior permite comparar directamente las medias funcionales de HC y PD_OFF.

Las trayectorias suavizadas conservan las variaciones de baja frecuencia a lo largo del orden normalizado de las épocas y atenúan las fluctuaciones locales entre segmentos consecutivos. Descriptivamente, las medias funcionales de HC y PD_OFF presentan diferencias de nivel en ambas bandas.

La forma de las trayectorias medias sugiere que las diferencias entre los grupos se manifiestan principalmente como diferencias de nivel, más que como cambios marcados en la forma a lo largo del orden normalizado de las épocas. La selección de una base de baja complejidad es coherente con una representación orientada a conservar estas variaciones globales y suaves, sin requerir mayor flexibilidad para describir las fluctuaciones locales entre épocas.

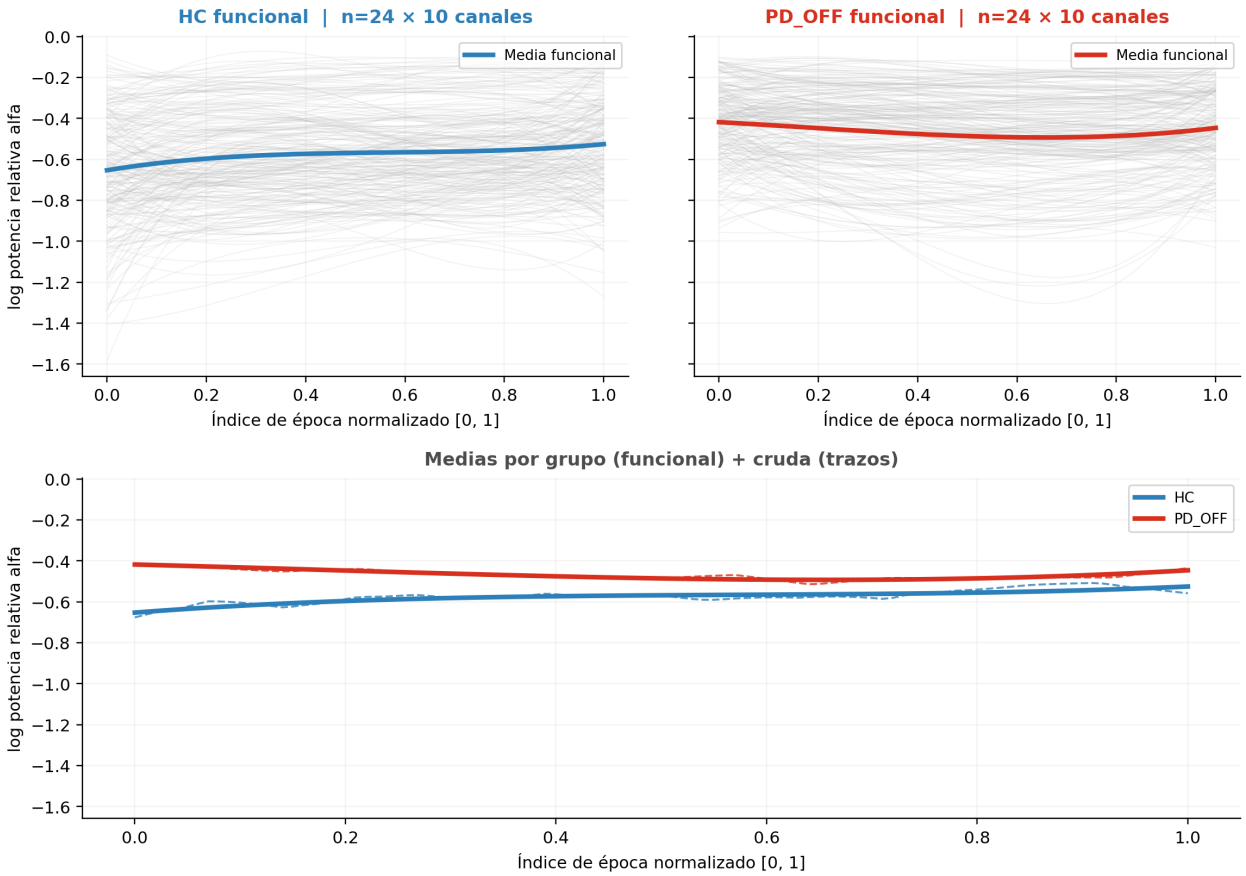


Figura 4.10: Trayectorias funcionales alfa del Enfoque B. Elaboración propia con datos de OpenNeuro ds003490.

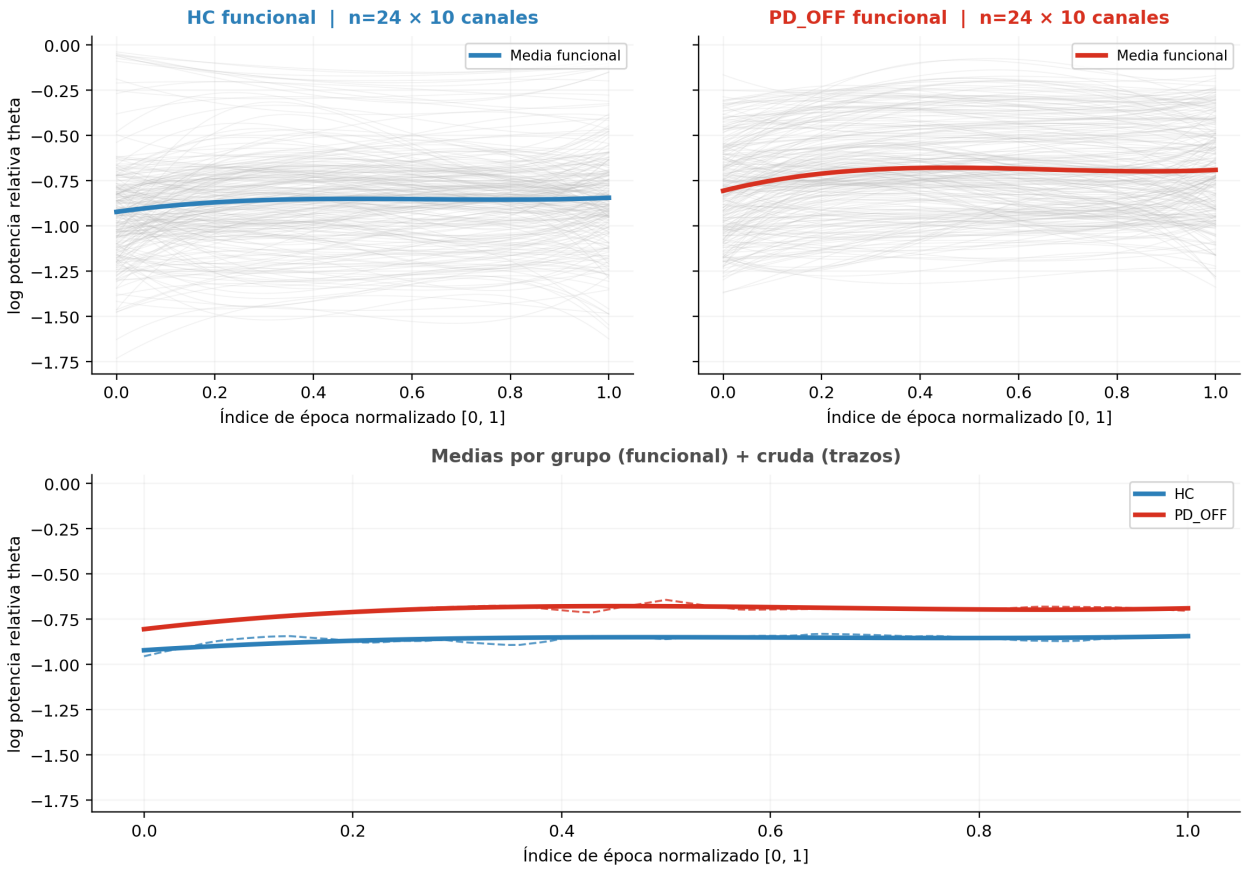


Figura 4.11: Trayectorias funcionales theta del Enfoque B. Elaboración propia con datos de OpenNeuro ds003490.

Cada banda queda representada por cuatro coeficientes B-spline por canal. Por tanto, considerando diez canales y dos bandas, la representación inicial del Enfoque B contiene 80 coeficientes por sujeto.

4.3.4 Validación de la transformación de Cholesky

Antes de aplicar la FPCA y utilizar los coeficientes transformados como entrada de los clasificadores, se verificó numéricamente la transformación de Cholesky descrita en la Sección 3.4.4. Las matrices de Gram se calcularon mediante integración de Simpson sobre una malla densa de 1001 puntos.

La Tabla 4.4 resume las principales comprobaciones. En todos los casos, la matriz de Gram resultó simétrica y definida positiva, con autovalores mínimos estrictamente mayores que cero, condición necesaria para realizar su descomposición de Cholesky.

Tabla 4.4: Validación numérica de la transformación de Cholesky.

Representación	Dimensión de G	$\lambda_{\text{mín}}(G)$	$\text{cond}(G)$	Error máx.
Enfoque A	11×11	$7{,}72 \times 10^{-4}$	$1{,}40 \times 10^{3}$	$7{,}99 \times 10^{-15}$
Enfoque B, theta	4×4	$6{,}09 \times 10^{-5}$	$6{,}97 \times 10^{3}$	$1{,}89 \times 10^{-15}$
Enfoque B, alfa	4×4	$6{,}09 \times 10^{-5}$	$6{,}97 \times 10^{3}$	$2{,}57 \times 10^{-15}$

Fuente: elaboración propia con datos de OpenNeuro ds003490.

Adicionalmente, se verificó que la distancia funcional calculada mediante la matriz de Gram coincidiera con la distancia euclidiana obtenida después de la transformación de Cholesky. Los errores máximos fueron inferiores a 10^{-14}, compatibles con la precisión numérica de punto flotante.

Estos resultados confirman que los coeficientes transformados preservan la geometría L^2 de las curvas. La transformación no modifica la función B-spline representada ni reduce su dimensión; únicamente cambia el sistema de coordenadas. Por esta razón, X_{raw} y X_{chol} no se representan gráficamente como dos curvas diferentes.

Esta validación comprueba la corrección numérica de la transformación y la preservación de la geometría funcional. Su efecto sobre el desempeño predictivo se evaluó posteriormente de forma empírica, observándose mejoras en algunas configuraciones de modelos y representaciones, aunque no de manera uniforme.

4.3.5 Reducción de dimensión mediante FPCA

La FPCA se ajustó dentro de cada partición de validación utilizando exclusivamente los datos de entrenamiento. Para cada canal se retuvieron las primeras componentes necesarias para explicar al menos el 95 % de la varianza funcional. De este modo, el número de componentes no se fijó de antemano, sino que se adaptó a la estructura de variabilidad observada en cada partición.

En el Enfoque A, que parte de 11 coeficientes Cholesky por canal, se necesitaron generalmente entre cinco y seis componentes para alcanzar el umbral establecido. La Tabla 4.5 presenta el número de componentes retenidas y la varianza explicada por canal, resumidos sobre las quince evaluaciones correspondientes a cinco particiones y tres semillas.

La selección fue estable entre particiones. Considerando únicamente las componentes efectivamente retenidas, la representación utilizó en promedio $51{,}3 \pm 0{,}8$ componentes frente a los 110 coeficientes originales, lo que corresponde a una reducción aproximada

Tabla 4.5: Componentes FPCA retenidos por canal en el Enfoque A.

Canal	Componentes (media $\pm$ DE)	Rango	Varianza explicada (%)
C3	$5{,}00 \pm 0{,}00$	5	95,9
Cz	$5{,}40 \pm 0{,}51$	5 a 6	96,0
C4	$5{,}07 \pm 0{,}26$	5 a 6	95,8
P7	$5{,}00 \pm 0{,}00$	5	96,0
P8	$5{,}00 \pm 0{,}00$	5	97,0
P3	$5{,}00 \pm 0{,}00$	5	96,1
Pz	$5{,}80 \pm 0{,}41$	5 a 6	96,9
P4	$5{,}00 \pm 0{,}00$	5	96,9
O1	$5{,}07 \pm 0{,}26$	5 a 6	95,7
O2	$5{,}00 \pm 0{,}00$	5	96,5
Global	$5{,}13 \pm 0{,}34$	5 a 6	-

Fuente: elaboración propia con datos de OpenNeuro ds003490.

del 53,3 %.

Como los canales deben compartir una dimensión común dentro de cada partición para formar la entrada de los modelos, se utilizó relleno con ceros hasta el máximo número de componentes seleccionado en el fold. Con este procedimiento, la dimensión final fue de $58{,}7 \pm 3{,}5$ variables (rango 50 a 60), equivalente a una reducción media del $46{,}7\,\%$.

En el Enfoque B, la FPCA se ajustó de forma independiente para cada combinación canal-banda, manteniendo separadas las representaciones theta y alfa. A partir de cuatro coeficientes B-spline por banda, theta requirió entre una y tres componentes, mientras que alfa requirió generalmente entre dos y tres para alcanzar el 95 % de la varianza explicada.

Partiendo de 80 coeficientes por sujeto (10 canales $\times$ 2 bandas $\times$ 4 coeficientes), se conservaron en promedio $40{,}3 \pm 2{,}1$ componentes efectivamente seleccionadas. Después del relleno necesario para mantener una dimensión común dentro de cada partición, la representación tuvo una dimensión media de $56{,}0 \pm 5{,}1$ variables.

La Figura 4.12 resume el número de componentes retenidos por canal y banda. Estos resultados muestran que una fracción importante de la variabilidad funcional puede representarse con un número menor de coordenadas que el proporcionado inicialmente por las bases B-spline. Esta reducción se interpreta como una compactación de la representación y no implica, por sí sola, una mejora del desempeño predictivo.

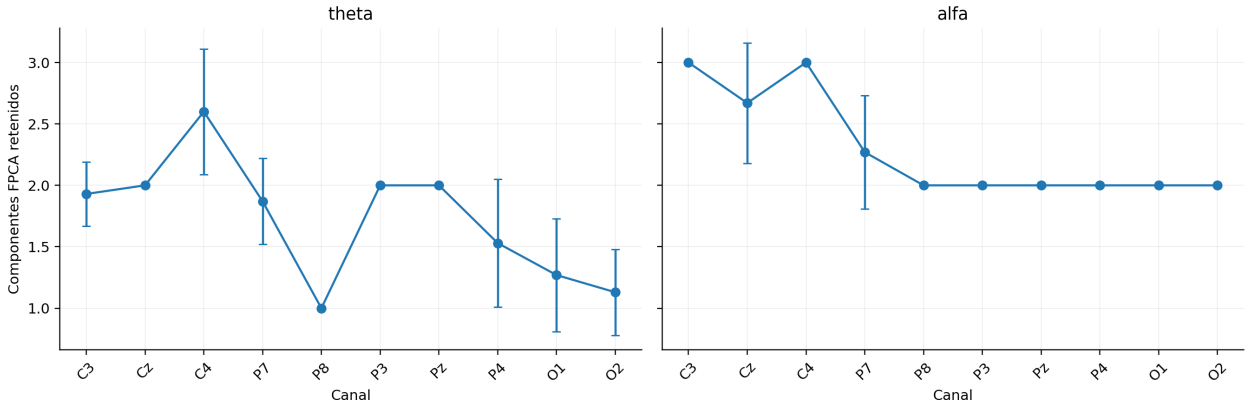


Figura 4.12: Componentes FPCA retenidos por canal y banda en el Enfoque B. Elaboración propia con datos de OpenNeuro ds003490.

4.3.6 Representaciones funcionales y entradas al modelado

Una vez construidas las funciones B-spline, validada la transformación de Cholesky y caracterizada la reducción mediante FPCA, se examinó visualmente el efecto de estas etapas sobre ejemplos representativos de ambos enfoques.

La transformación de Cholesky no se representa mediante una curva adicional, puesto que X_{raw} y X_{chol} describen el mismo objeto funcional en sistemas de coordenadas diferentes. En cambio, la reconstrucción obtenida a partir de FPCA permite visualizar qué estructura de la función se conserva después de retener las componentes necesarias para explicar al menos el 95 % de la variabilidad.

En el Enfoque A, la Figura 4.13 muestra un ejemplo en el canal Pz. Se presenta la PSD relativa promedio observada para el sujeto, el ajuste B-spline correspondiente a X_{raw} y la reconstrucción obtenida a partir de las componentes FPCA retenidas. La reconstrucción conserva la forma espectral principal de la función, incluida la transición entre theta y alfa.

De forma análoga, las Figuras 4.14 y 4.15presentan el proceso para el Enfoque B en el mismo canal. En este caso, los puntos corresponden a los valores de potencia relativa obtenidos para las épocas válidas, la curva continua representa el ajuste B-spline sobre el orden normalizado de las épocas y la reconstrucción FPCA muestra la información conservada en las bandas theta y alfa después de la reducción dimensional.

Estas reconstrucciones tienen un propósito descriptivo y permiten visualizar el efecto de la reducción dimensional. No constituyen una cuarta representación de entrada. En los experimentos de clasificación se evaluaron tres formas de la representación funcional: los coeficientes B-spline originales (X_{raw}), los coeficientes transformados mediante Cholesky

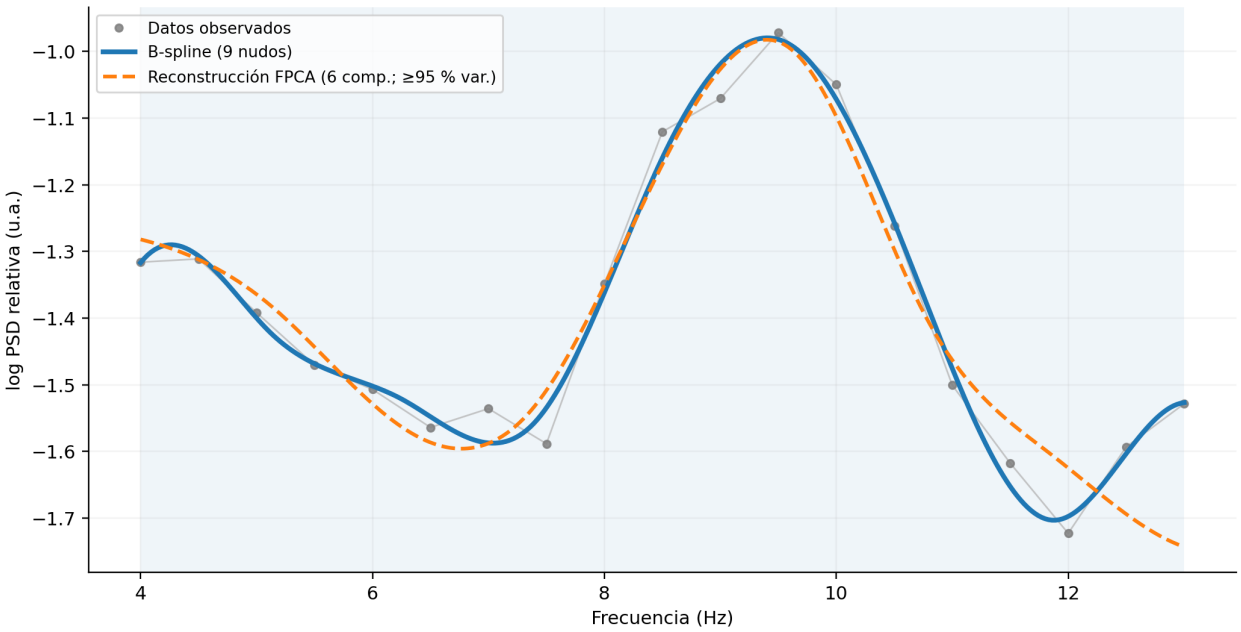


Figura 4.13: Ejemplo de reconstrucción funcional del Enfoque A en el canal Pz. Elaboración propia con datos de OpenNeuro ds003490.

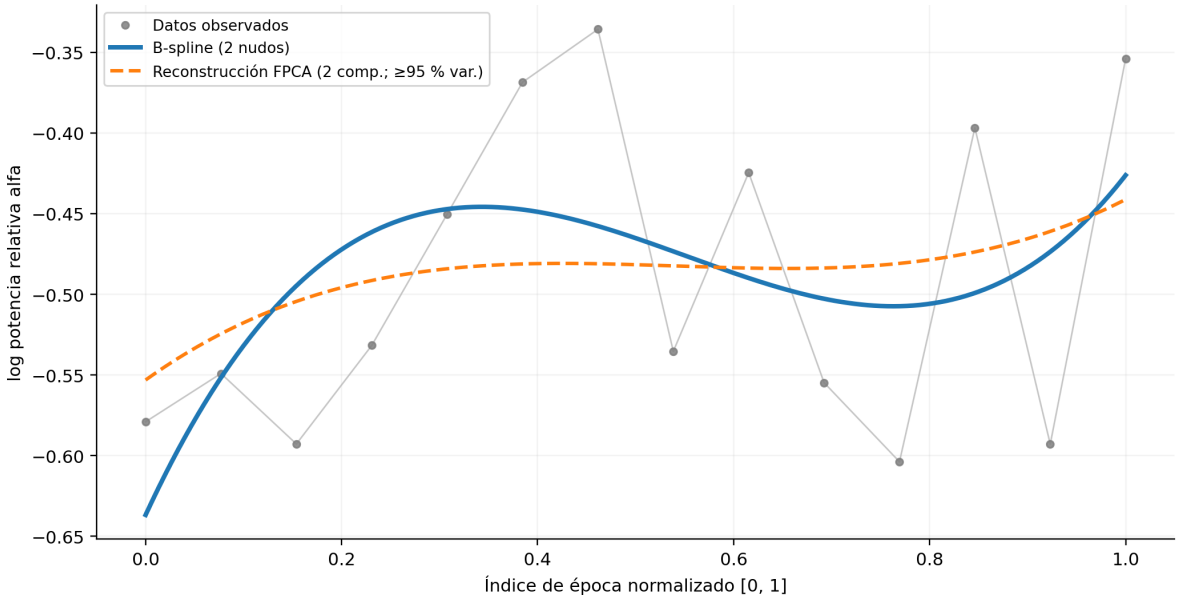


Figura 4.14: Ejemplo de reconstrucción funcional del Enfoque B en el canal Pz en alfa. Elaboración propia con datos de OpenNeuro ds003490.

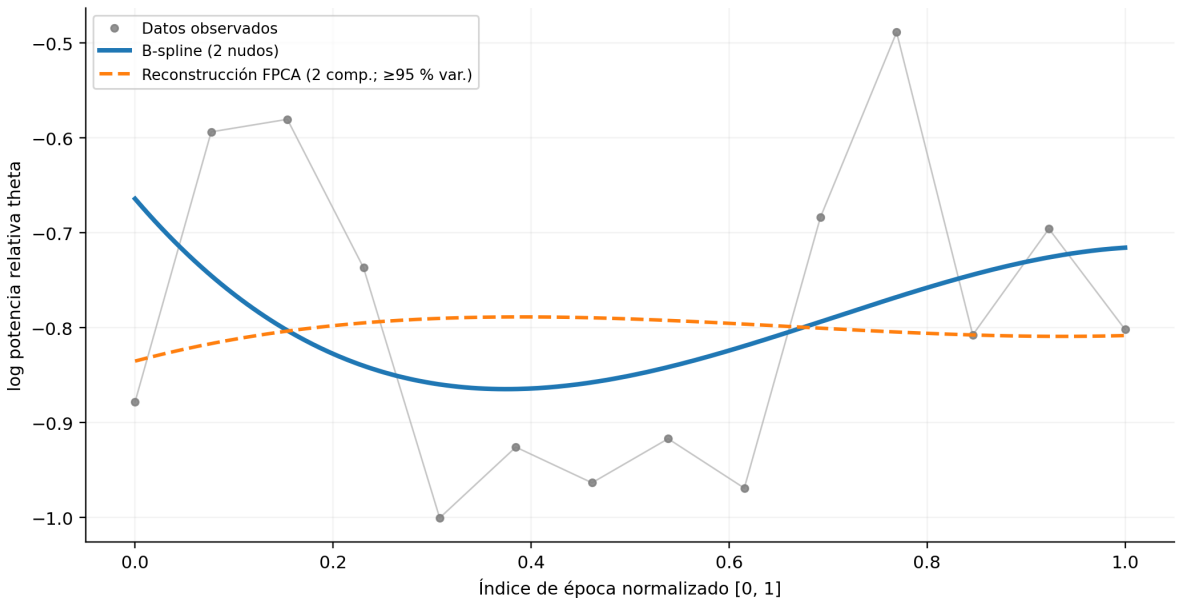


Figura 4.15: Ejemplo de reconstrucción funcional del Enfoque B en el canal Pz en theta. Elaboración propia con datos de OpenNeuro ds003490.

(X_{chol}) y los scores obtenidos mediante FPCA a partir de X_{chol}.

4.4 COMPARACIÓN DE MODELOS Y REPRESENTACIONES

Caracterizado el patrón espectral y construidas las representaciones funcionales, se comparó el desempeño de los clasificadores bajo un esquema de validación estricta por sujeto. Se mantiene la nomenclatura definida en la metodología: **A1** corresponde a la estrategia con una representación funcional por sujeto, mientras que **A2** corresponde a la estrategia con representaciones por época y agregación posterior de las probabilidades a nivel de sujeto.

El Enfoque B mantiene una única observación por sujeto y representa las trayectorias funcionales de potencia relativa en las bandas theta y alfa a lo largo del orden normalizado de las épocas. Sobre las representaciones funcionales de los Enfoques A y B se evaluaron los nueve modelos definidos en la metodología.

Como referencia independiente, la línea base sin ADF se evaluó con cuatro modelos compatibles con su representación basada en características espectrales escalares. Las demás arquitecturas emplean como entrada una estructura organizada por canal y coeficientes funcionales.

La métrica principal de comparación fue la exactitud balanceada. De forma complementa-

ria, se evaluaron sensibilidad, especificidad, F1-score y AUC. Los resultados se resumen como media $\pm$ desviación estándar sobre las quince evaluaciones correspondientes a cinco particiones y tres semillas. Las comparaciones de desempeño presentadas en esta sección se interpretan de manera descriptiva, ya que no se realizaron contrastes inferenciales formales de superioridad entre configuraciones.

4.4.1 Desempeño de las representaciones por sujeto

La comparación inicial considera las configuraciones en las que cada sujeto constituye directamente una observación de entrada: la línea base sin ADF, A1 y el Enfoque B. La Tabla 4.6 presenta, para cada representación, la configuración con mayor exactitud balanceada. La Tabla 4.7 muestra el mejor modelo de aprendizaje profundo bajo el mismo criterio. El Anexo A contiene los resultados completos de todas las combinaciones evaluadas.

Tabla 4.6: Mejor desempeño observado por representación según exactitud balanceada.

Enfoque	Representación	Modelo	Exactitud bal.	Sens.	Espec.	F1	AUC
Sin ADF	Escalares	Transformer	$0{,}732 \pm 0{,}124$	$0{,}797 \pm 0{,}152$	$0{,}667 \pm 0{,}215$	$0{,}746 \pm 0{,}115$	$0{,}814 \pm 0{,}106$
A1	B-spline	LogReg	$0{,}792 \pm 0{,}114$	$0{,}840 \pm 0{,}155$	$0{,}744 \pm 0{,}145$	$0{,}795 \pm 0{,}109$	$0{,}806 \pm 0{,}153$
A1	Cholesky	LogReg	$\mathbf{0{,}818 \pm 0{,}109}$	$0{,}840 \pm 0{,}155$	$0{,}796 \pm 0{,}149$	$0{,}816 \pm 0{,}103$	$0{,}879 \pm 0{,}097$
A1	Cholesky+FPCA	LogReg	$0{,}803 \pm 0{,}138$	$0{,}827 \pm 0{,}167$	$0{,}779 \pm 0{,}167$	$0{,}803 \pm 0{,}129$	$0{,}855 \pm 0{,}116$
B	B-spline	Transformer	$0{,}672 \pm 0{,}127$	$0{,}717 \pm 0{,}181$	$0{,}627 \pm 0{,}276$	$0{,}676 \pm 0{,}119$	$0{,}737 \pm 0{,}182$
B	Cholesky	CNN1D	$0{,}762 \pm 0{,}141$	$0{,}730 \pm 0{,}194$	$0{,}793 \pm 0{,}176$	$0{,}747 \pm 0{,}156$	$0{,}861 \pm 0{,}123$
B	Cholesky+FPCA	Random Forest	$0{,}781 \pm 0{,}094$	$0{,}877 \pm 0{,}150$	$0{,}686 \pm 0{,}141$	$0{,}794 \pm 0{,}097$	$0{,}849 \pm 0{,}128$

Fuente: elaboración propia con datos de OpenNeuro ds003490.

Aunque la selección de cada fila se realizó por exactitud balanceada, el mayor AUC observado en el Enfoque B correspondió a LogReg con Cholesky+FPCA, con $0{,}912 \pm 0{,}098$, y una exactitud balanceada de $0{,}778 \pm 0{,}126$.

Tabla 4.7: Mejor desempeño observado de aprendizaje profundo por representación.

Enfoque	Representación	Modelo	Exactitud bal.	Sens.	Espec.	F1	AUC
Sin ADF	Escalares	Transformer	$0{,}732 \pm 0{,}124$	$0{,}797 \pm 0{,}152$	$0{,}667 \pm 0{,}215$	$0{,}746 \pm 0{,}115$	$0{,}814 \pm 0{,}106$
A1	B-spline	MLP	$0{,}715 \pm 0{,}120$	$0{,}713 \pm 0{,}247$	$0{,}717 \pm 0{,}223$	$0{,}679 \pm 0{,}219$	$0{,}687 \pm 0{,}181$
A1	Cholesky	MLP	$\mathbf{0{,}752 \pm 0{,}142}$	$0{,}770 \pm 0{,}183$	$0{,}733 \pm 0{,}195$	$0{,}748 \pm 0{,}139$	$0{,}780 \pm 0{,}139$
A1	Cholesky+FPCA	Transformer	$0{,}718 \pm 0{,}152$	$0{,}730 \pm 0{,}194$	$0{,}707 \pm 0{,}196$	$0{,}715 \pm 0{,}146$	$0{,}805 \pm 0{,}194$
B	B-spline	Transformer	$0{,}672 \pm 0{,}127$	$0{,}717 \pm 0{,}181$	$0{,}627 \pm 0{,}276$	$0{,}676 \pm 0{,}119$	$0{,}737 \pm 0{,}182$
B	Cholesky	CNN1D	$\mathbf{0{,}762 \pm 0{,}141}$	$0{,}730 \pm 0{,}194$	$0{,}793 \pm 0{,}176$	$0{,}747 \pm 0{,}156$	$0{,}861 \pm 0{,}123$
B	Cholesky+FPCA	Transformer	$0{,}752 \pm 0{,}148$	$0{,}793 \pm 0{,}251$	$0{,}711 \pm 0{,}214$	$0{,}740 \pm 0{,}226$	$0{,}862 \pm 0{,}103$

Fuente: elaboración propia con datos de OpenNeuro ds003490.

En A1, el mayor desempeño observado correspondió a LogReg con Cholesky, con una

exactitud balanceada de $0{,}818 \pm 0{,}109$ y un AUC de $0{,}879 \pm 0{,}097$. Frente a la línea base con mayor exactitud balanceada, Transformer ($0{,}732 \pm 0{,}124$), la diferencia absoluta observada fue de 0,086. En la línea base, Random Forest obtuvo el mayor AUC ($0{,}837 \pm 0{,}115$), aunque no presentó la mayor exactitud balanceada.

En el Enfoque B, Random Forest con Cholesky+FPCA alcanzó el mayor valor observado de exactitud balanceada, con $0{,}781 \pm 0{,}094$, mientras que LogReg con la misma representación obtuvo el mayor AUC del enfoque ($0{,}912 \pm 0{,}098$). Estos resultados indican que las trayectorias funcionales de theta y alfa contienen información útil para la clasificación experimental, aunque las configuraciones que maximizan las métricas difieren entre los enfoques evaluados.

Entre los modelos profundos, el mayor valor observado en A1 correspondió a MLP con Cholesky, con una exactitud balanceada de $0{,}752 \pm 0{,}142$. En el Enfoque B, CNN1D con Cholesky alcanzó $0{,}762 \pm 0{,}141$. Ninguna de estas configuraciones superó el máximo observado de los modelos clásicos en su respectivo enfoque.

4.4.2 Estrategia A2: entrenamiento con representaciones por época

A2 utiliza la misma representación funcional en frecuencia que A1, pero modifica la unidad utilizada durante el entrenamiento. Mientras que en A1 cada sujeto aporta una única representación funcional, en A2 cada época válida genera una representación B-spline y una predicción individual. La probabilidad final de cada sujeto se obtiene posteriormente mediante el promedio de las probabilidades correspondientes a sus épocas.

La separación externa entre entrenamiento y prueba se mantuvo estrictamente agrupada por sujeto, de modo que todas las épocas pertenecientes a un mismo individuo permanecieran exclusivamente en uno de los dos conjuntos. Por tanto, el uso de múltiples épocas durante el entrenamiento no supone un incremento en el número de sujetos independientes disponibles.

La Tabla 4.8 presenta conjuntamente los resultados de A1 y A2 con el propósito de examinar el efecto de modificar la unidad de entrenamiento dentro del mismo Enfoque A. Los valores corresponden a la exactitud balanceada media $\pm$ desviación estándar y, en ambas estrategias, la evaluación final se realiza a nivel de sujeto. Esta comparación debe interpretarse como un contraste entre estrategias de entrenamiento y no como una comparación entre dos representaciones funcionales diferentes.

El efecto de A2 fue heterogéneo entre modelos y representaciones. En LogReg, los valores observados de exactitud balanceada pasaron de $0{,}792$ a $0{,}806$ con B-spline, de $0{,}818$

Tabla 4.8: Comparación entre las estrategias A1 y A2 del Enfoque A.

		B-spline		Cholesky		Cholesky+FPCA	
Tipo	Modelo	A1	A2	A1	A2	A1	A2
Referencia	LogReg	$0{,}792 \pm 0{,}114$	$0{,}806 \pm 0{,}114$	$0{,}818 \pm 0{,}109$	$\mathbf{0{,}824 \pm 0{,}092}$	$0{,}803 \pm 0{,}138$	$\mathbf{0{,}824 \pm 0{,}115}$
	Random Forest	$0{,}724 \pm 0{,}156$	$0{,}692 \pm 0{,}121$	$0{,}728 \pm 0{,}125$	$0{,}734 \pm 0{,}127$	$0{,}719 \pm 0{,}154$	$0{,}727 \pm 0{,}098$
Profundos	MLP	$0{,}715 \pm 0{,}120$	$0{,}764 \pm 0{,}125$	$0{,}752 \pm 0{,}142$	$0{,}778 \pm 0{,}133$	$0{,}694 \pm 0{,}159$	$0{,}756 \pm 0{,}108$
	Transformer	$0{,}667 \pm 0{,}168$	$0{,}724 \pm 0{,}094$	$0{,}687 \pm 0{,}127$	$0{,}740 \pm 0{,}127$	$0{,}718 \pm 0{,}152$	$0{,}680 \pm 0{,}118$
	FDNN	$0{,}650 \pm 0{,}140$	$0{,}666 \pm 0{,}155$	$0{,}633 \pm 0{,}157$	$0{,}767 \pm 0{,}113$	$0{,}642 \pm 0{,}147$	$\mathbf{0{,}781 \pm 0{,}113}$
	FNN	$0{,}598 \pm 0{,}175$	$0{,}764 \pm 0{,}148$	$0{,}596 \pm 0{,}151$	$0{,}772 \pm 0{,}121$	$0{,}672 \pm 0{,}182$	$0{,}739 \pm 0{,}108$
	AdaFNN	$0{,}591 \pm 0{,}143$	$0{,}734 \pm 0{,}140$	$0{,}594 \pm 0{,}178$	$0{,}708 \pm 0{,}096$	$0{,}609 \pm 0{,}142$	$0{,}738 \pm 0{,}103$
	EEGNet	$0{,}641 \pm 0{,}156$	$0{,}752 \pm 0{,}128$	$0{,}570 \pm 0{,}140$	$0{,}709 \pm 0{,}150$	$0{,}643 \pm 0{,}137$	$0{,}741 \pm 0{,}133$
	CNN1D	$0{,}601 \pm 0{,}146$	$0{,}655 \pm 0{,}150$	$0{,}584 \pm 0{,}139$	$0{,}688 \pm 0{,}127$	$0{,}710 \pm 0{,}145$	$0{,}707 \pm 0{,}111$

Fuente: elaboración propia con datos de OpenNeuro ds003490.

a $0{,}824$ con Cholesky y de $0{,}803$ a $0{,}824$ con Cholesky+FPCA. Estas dos últimas configuraciones de A2 alcanzaron el máximo valor medio observado de exactitud balanceada del estudio. Entre las arquitecturas profundas, A2 presentó valores superiores a A1 en varias configuraciones, especialmente en FDNN, FNN y MLP, aunque el efecto no fue uniforme. Por ejemplo, CNN1D con Cholesky+FPCA presentó valores similares en ambas estrategias, con $0{,}710 \pm 0{,}145$ en A1 y $0{,}707 \pm 0{,}111$ en A2.

El mayor desempeño observado entre las arquitecturas de aprendizaje profundo correspondió a FDNN con Cholesky+FPCA bajo la estrategia A2, con una exactitud balanceada de $0{,}781 \pm 0{,}113$ y un AUC de $0{,}875 \pm 0{,}090$. Esta configuración se adopta como la realización final del modelo de Deep Learning basado en ADF propuesto en esta investigación. Su selección se fundamenta en la métrica principal definida para el estudio y corresponde a una elección empírica entre las configuraciones profundas evaluadas. Con la misma representación, la regresión logística alcanzó una exactitud balanceada de $0{,}824 \pm 0{,}115$ y un AUC de $0{,}902 \pm 0{,}111$, por lo que el modelo propuesto no constituyó la configuración con el mayor desempeño observado del estudio.

Es importante señalar que las épocas procedentes de un mismo sujeto están correlacionadas. A2 incrementa el número de observaciones utilizadas para optimizar los modelos, pero no aumenta el número de sujetos independientes. En consecuencia, esta estrategia no debe interpretarse como equivalente a disponer de una cohorte de mayor tamaño.

4.4.3 Efecto de las transformaciones funcionales

El efecto de las distintas representaciones depende tanto del enfoque como del clasificador, por lo que su contribución debe analizarse mediante comparaciones dentro de un mismo modelo.

En A1, LogReg pasó de una exactitud balanceada de $0{,}792$ con los coeficientes B-spline crudos a $0{,}818$ después de la transformación de Cholesky, y a $0{,}803$ tras incorporar FPCA. En el Enfoque B, los mejores resultados observados también dependieron de la representación y del clasificador. Por ejemplo, LogReg alcanzó su mayor exactitud balanceada con Cholesky+FPCA, con $0{,}778 \pm 0{,}126$, mientras que en los modelos profundos CNN1D obtuvo su máximo valor observado con Cholesky, con $0{,}762 \pm 0{,}141$. En A2, LogReg alcanzó el mayor valor medio observado de exactitud balanceada con $0{,}824$, tanto con Cholesky como con Cholesky+FPCA.

Estos resultados son coherentes con el papel diferente de cada transformación. Cholesky no añade nueva información a las curvas, sino que reexpresa los coeficientes de manera que la geometría euclidiana utilizada por los modelos sea más coherente con la distancia funcional L^2. En varias configuraciones evaluadas, esta transformación se asoció con valores observados de desempeño superiores a los obtenidos con los coeficientes B-spline crudos, aunque dicho efecto no fue uniforme entre modelos y representaciones. FPCA, por su parte, concentra las principales direcciones de variabilidad funcional en un número menor de componentes. Por tanto, ninguna de las dos transformaciones garantiza por sí sola una mejora predictiva; su contribución depende de la representación funcional y del clasificador utilizado.

En el Enfoque B, estos resultados deben considerarse conjuntamente con la estructura de las trayectorias obtenidas. La selección mediante GCV favoreció representaciones theta y alfa de baja complejidad, en las que las diferencias descriptivas entre HC y PD_OFF estuvieron asociadas principalmente con el nivel de las curvas y menos con cambios marcados de su forma a lo largo del orden normalizado de las épocas. Una representación funcional adecuada de estas trayectorias no implica necesariamente una elevada capacidad discriminativa entre grupos, ya que la variabilidad entre sujetos puede producir solapamiento aun cuando las tendencias medias sean diferentes. No obstante, el aumento del desempeño observado en varias configuraciones después de incorporar Cholesky y, en algunos casos, FPCA indica que las trayectorias contenían información aprovechable para la clasificación experimental y que su utilidad dependió de la forma en que dicha información funcional fue representada ante el clasificador.

Para examinar el tipo de errores producidos, la Figura 4.16 presenta tres configuraciones representativas del Enfoque A: LogReg+Cholesky, configuración con el mayor desempeño observado en A1; MLP+Cholesky, modelo profundo con el mayor desempeño observado en A1; y FDNN+Cholesky+FPCA, modelo profundo con el mayor desempeño observado en A2 y configuración adoptada como modelo propuesto. Las matrices se encuentran normalizadas por clase real.

LogReg+Cholesky en A1 combinó una sensibilidad de $0{,}840 \pm 0{,}155$ y una especificidad de $0{,}796 \pm 0{,}149$. Entre los modelos profundos de A1, MLP+Cholesky presentó una sensi-

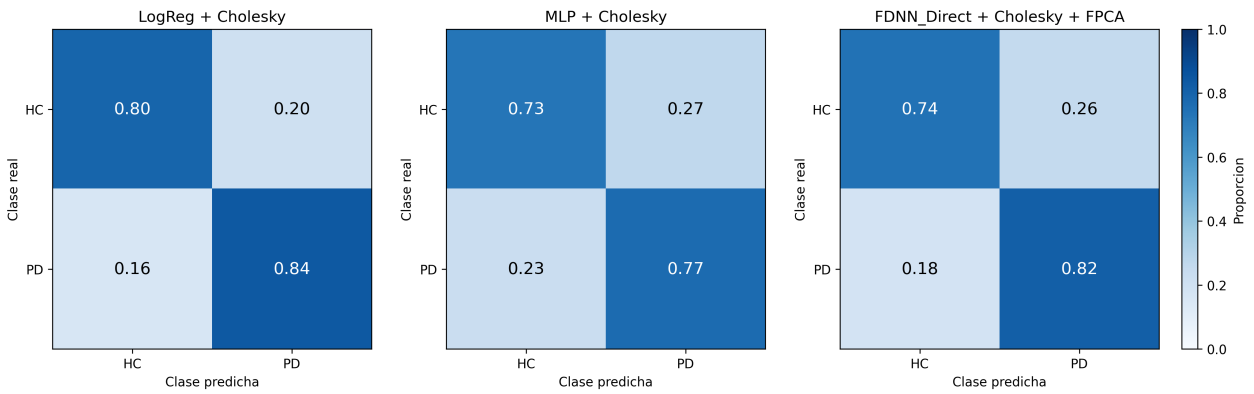


Figura 4.16: Matrices de confusión de configuraciones seleccionadas de A1 y A2. Elaboración propia con datos de OpenNeuro ds003490.

bilidad de $0{,}770 \pm 0{,}183$ y una especificidad de $0{,}733 \pm 0{,}195$. En A2, el modelo propuesto FDNN+Cholesky+FPCA alcanzó una sensibilidad de $0{,}818 \pm 0{,}187$ y una especificidad de $0{,}744 \pm 0{,}276$.

4.5 CURVAS DE VALIDACIÓN

Las curvas de validación se utilizaron como diagnóstico complementario para examinar la diferencia entre ajuste y generalización y la sensibilidad del desempeño al número de sujetos independientes disponibles.

4.5.1 Control del sobreajuste

La Figura 4.17 muestra la evolución del AUC de entrenamiento y validación en los tres modelos profundos seleccionados de la estrategia A2: FDNN con Cholesky+FPCA, MLP con Cholesky y FNN con Cholesky. Las curvas se utilizan como diagnóstico del entrenamiento y no deben compararse directamente con las métricas finales, que se calculan a nivel de sujeto.

En los tres modelos, el AUC de entrenamiento aumenta rápidamente hasta alcanzar valores próximos a uno, mientras que el AUC de validación permanece en niveles inferiores y presenta mayor variabilidad entre ejecuciones. Después de las primeras épocas, el desempeño de validación tiende a estabilizarse o disminuir ligeramente mientras el desempeño de entrenamiento continúa aumentando. Este comportamiento evidencia una separación progresiva entre ajuste y generalización y es consistente con una tendencia al sobreajuste.

La parada temprana limita la continuación de este proceso cuando la pérdida de valida-

ción deja de mejorar. Para la construcción de la figura, las ejecuciones se prolongaron hasta un horizonte diagnóstico común de 80 épocas, de manera que cada punto de las curvas se calculó utilizando las mismas 15 ejecuciones correspondientes a cinco particiones y tres semillas. La línea vertical representa la mediana de la época de parada (`stop_epoch`) entre particiones y semillas, no la época de máximo AUC. La prolongación posterior a dicho criterio se realizó exclusivamente con fines diagnósticos y no intervino en el cálculo de las métricas finales de los modelos.

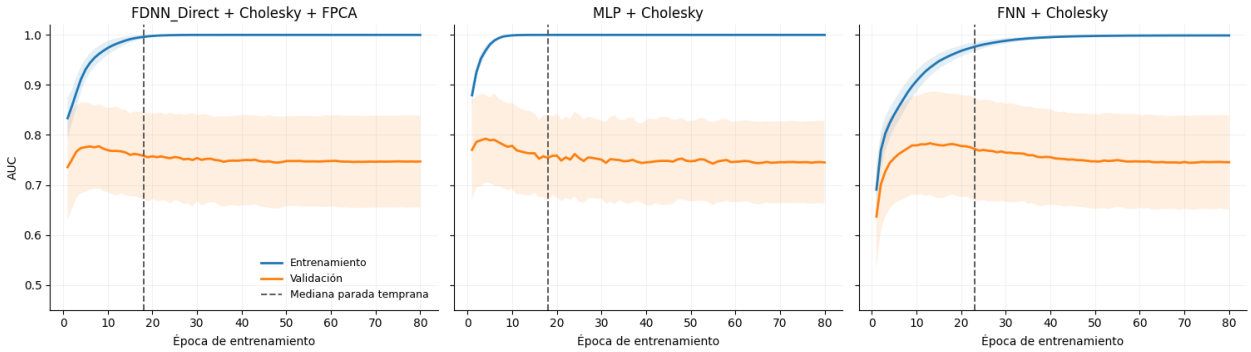


Figura 4.17: Evolución del AUC de entrenamiento y validación en modelos profundos seleccionados de la estrategia A2. Elaboración propia con datos de OpenNeuro ds003490.

4.5.2 Curva de aprendizaje por número de sujetos

Para evaluar la sensibilidad del desempeño al tamaño de la cohorte se construyó una curva de aprendizaje utilizando la estrategia A2 del Enfoque A y la representación Cholesky. El análisis se realizó mediante cinco repeticiones con diferentes particiones aleatorias. En cada repetición se reservó un conjunto de prueba estratificado de 10 sujetos (5 HC y 5 PD_OFF), que permaneció fijo para todos los tamaños de entrenamiento y modelos evaluados dentro de esa repetición.

A partir de los 38 sujetos restantes se evaluaron subconjuntos balanceados de 12, 18, 24, 30, 36 y 38 sujetos. Para cada tamaño se utilizó la misma selección de sujetos en los tres modelos considerados: LogReg + Cholesky, MLP + Cholesky y FNN + Cholesky. De esta manera, la comparación se realizó bajo las mismas condiciones y utilizando la misma representación funcional. En las arquitecturas profundas, los sujetos disponibles para el desarrollo del modelo se dividieron adicionalmente, manteniendo la separación por sujeto, en entrenamiento interno y validación interna para controlar la parada temprana. Las probabilidades obtenidas para las épocas del conjunto de prueba se agregaron posteriormente a nivel de sujeto mediante su promedio.

La Figura 4.18 muestra la evolución de la exactitud balanceada (panel izquierdo) y del AUC (panel derecho) a medida que aumenta el número de sujetos disponibles para el de-

sarrollo del modelo. En términos generales, LogReg + Cholesky, MLP + Cholesky y FNN + Cholesky presentan valores superiores en los tamaños muestrales mayores respecto a los subconjuntos más pequeños, aunque las trayectorias no son monótonas y las bandas de variabilidad son amplias.

La ausencia de una evolución estrictamente monótona es consistente con la incertidumbre esperable en una cohorte de tamaño reducido y con la variación en la composición de los subconjuntos seleccionados para cada tamaño muestral. Además, cada conjunto de prueba contiene únicamente cinco sujetos por clase, por lo que las métricas son sensibles a cambios en un número pequeño de clasificaciones.

Dado que la variación con el tamaño muestral se observa tanto en LogReg + Cholesky como en las arquitecturas profundas MLP + Cholesky y FNN + Cholesky, la sensibilidad al número de sujetos no puede atribuirse exclusivamente a la complejidad de los modelos profundos. Los resultados respaldan que el número de sujetos independientes constituye una fuente importante de incertidumbre en la estimación del desempeño y que una cohorte mayor permitiría caracterizar con mayor precisión la capacidad de generalización de los modelos evaluados. Las líneas representan la media y las bandas sombreadas ± 1 desviación estándar sobre las cinco repeticiones.

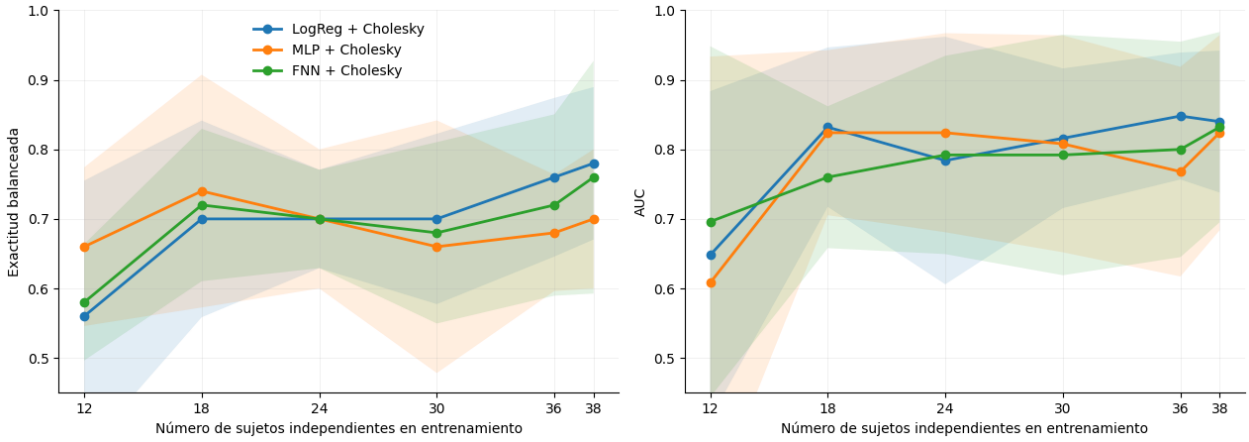


Figura 4.18: Curva de aprendizaje según el número de sujetos independientes utilizados para entrenamiento. Elaboración propia con datos de OpenNeuro ds003490.

4.6 ANÁLISIS COMPLEMENTARIOS DEL APORTE DEL ADF

4.6.1 Aislamiento del aporte específico del ADF

El análisis complementario descrito en la Sección 3.5.4 permitió comparar, mediante un mismo clasificador y bajo las mismas particiones externas, representaciones espectrales

resumidas, discretizadas y funcionales. La Tabla 4.9 presenta los resultados obtenidos mediante regresión logística.

Tabla 4.9: Desempeño de las representaciones evaluadas en el análisis de ablación.

Representación	Exactitud bal.	Sens.	Espec.	F1	AUC
Theta + alfa + PAF	$0,758 \pm 0,143$	$0,783 \pm 0,192$	$0,733 \pm 0,188$	$0,760 \pm 0,152$	$0,845 \pm 0,119$
PSD discreta 4-13 Hz	$0,818 \pm 0,117$	$0,840 \pm 0,172$	$0,796 \pm 0,149$	$0,814 \pm 0,116$	$0,879 \pm 0,124$
PSD discreta 4-13 Hz + PCA	$0,798 \pm 0,126$	$0,813 \pm 0,192$	$0,782 \pm 0,138$	$0,790 \pm 0,136$	$0,848 \pm 0,114$
A1 B-spline	$0,792 \pm 0,114$	$0,840 \pm 0,155$	$0,744 \pm 0,145$	$0,795 \pm 0,109$	$0,806 \pm 0,153$
A1 Cholesky	$0,818 \pm 0,109$	$0,840 \pm 0,155$	$0,796 \pm 0,149$	$0,816 \pm 0,103$	$0,879 \pm 0,097$
A1 Cholesky + FPCA	$0,803 \pm 0,138$	$0,827 \pm 0,167$	$0,779 \pm 0,167$	$0,803 \pm 0,129$	$0,855 \pm 0,116$

Fuente: elaboración propia con datos de OpenNeuro ds003490.

La representación escalar basada en theta, alfa y PAF alcanzó una exactitud balanceada de $0,758 \pm 0,143$. Al conservar directamente la forma detallada de la PSD entre 4 Hz y 13 Hz, sin emplear ADF, la exactitud balanceada aumentó a $0,818 \pm 0,117$ y el AUC a $0,879 \pm 0,124$. Este resultado indica que, bajo el clasificador evaluado, parte importante de la información discriminante se encuentra en la estructura espectral detallada del intervalo theta-alfa y no queda completamente representada mediante un conjunto reducido de características escalares.

La proyección funcional mediante B-splines obtuvo una exactitud balanceada de $0,792 \pm 0,114$, mientras que la representación discreta sobre el mismo intervalo alcanzó $0,818 \pm 0,117$. La diferencia descriptiva media entre A1 B-spline y la PSD discretizada fue de $-0,026$ en exactitud balanceada. Por tanto, en esta comparación controlada no se observó una ganancia predictiva adicional atribuible exclusivamente a la proyección mediante B-splines.

Al incorporar la transformación de Cholesky, A1 alcanzó una exactitud balanceada de $0,818 \pm 0,109$ y un AUC de $0,879 \pm 0,097$, valores prácticamente equivalentes a los obtenidos mediante la PSD discretizada. La posterior reducción mediante FPCA tampoco produjo una mejora adicional, con una exactitud balanceada de $0,803 \pm 0,138$. De forma análoga, la aplicación de PCA a la PSD discretizada produjo un desempeño de $0,798 \pm 0,126$.

En conjunto, estos resultados no muestran una ventaja predictiva adicional atribuible exclusivamente al uso del ADF en la estrategia A1 con regresión logística. Sin embargo, la representación funcional permite describir la misma información espectral mediante una base de menor dimensión, incorporar explícitamente la geometría funcional mediante la transformación de Cholesky y mantener la posibilidad de reconstruir e interpretar el comportamiento del clasificador sobre el dominio continuo de la frecuencia.

Las diferencias se interpretan de manera descriptiva. No se realizaron pruebas de hipótesis sobre las quince evaluaciones como si fueran observaciones independientes, debido

a la dependencia introducida por la reutilización de sujetos entre las particiones de la validación cruzada repetida.

4.6.2 Interpretabilidad funcional mediante funciones de peso

El procedimiento descrito en la Sección 3.5.5 permitió reconstruir las funciones de peso $\beta_c(f)$ de la regresión logística sobre el dominio frecuencial original. La transformación inversa reprodujo numéricamente el predictor lineal del clasificador, con un error máximo del orden de $3,1 \times 10^{-14}$, lo que confirmó la equivalencia entre la formulación utilizada durante el entrenamiento y su expresión mediante funciones de peso.

La Figura 4.19 muestra las funciones obtenidas para los diez canales en la región comprendida entre 4 Hz y 10 Hz. Para cada canal se presentan las funciones correspondientes a las quince evaluaciones externas, su media y la variabilidad entre particiones. Las líneas verticales delimitan theta lenta (4 a 5,5 Hz), pre-alfa o theta rápida (5,5 a 8 Hz) y el inicio de la banda alfa.

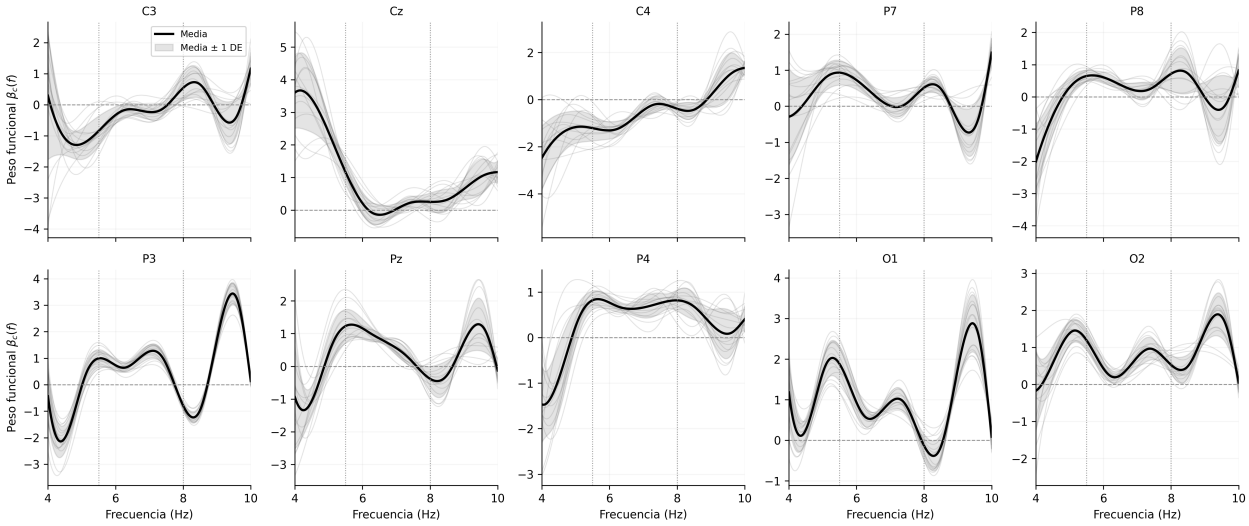


Figura 4.19: Funciones de peso reconstruidas por canal entre 4 y 10 Hz. Elaboración propia con datos de OpenNeuro ds003490.

El patrón más consistente se observó en el intervalo pre-alfa de 5,5 Hz a 8 Hz. En los siete canales posteriores considerados en el estudio (P7, P8, P3, Pz, P4, O1 y O2), la integral firmada de la función de peso sobre este intervalo fue positiva en las quince particiones externas. En consecuencia, dentro del modelo multivariado ajustado, una mayor potencia relativa logarítmica en esta región espectral contribuyó de manera consistente hacia un mayor *log-odds* predicho de PD_OFF en las derivaciones parietales y occipitales.

La banda theta completa (4 a 8 Hz) presentó también contribuciones positivas en varias

derivaciones posteriores, aunque con una estructura menos homogénea a lo largo de todo el intervalo. Al separar theta en las subregiones definidas previamente, theta lenta (4 a 5,5 Hz) mostró una mayor heterogeneidad espacial, mientras que el patrón positivo posterior se concentró de forma más consistente en pre-alfa. Esta subdivisión se utilizó para localizar la estructura del peso funcional dentro de theta y no para sustituir el análisis de la banda completa ni para seleccionar posteriormente el intervalo con mayor asociación.

La estabilidad no fue uniforme en todas las combinaciones de canal y frecuencia. Las funciones correspondientes a P3 y O1 presentaron una elevada concordancia de forma entre particiones, mientras que otros canales mostraron mayor variabilidad. Por esta razón, la interpretación se fundamentó en patrones reproducibles entre particiones y en resúmenes sobre intervalos frecuenciales, y no en máximos puntuales de las funciones de peso.

El análisis de sensibilidad mostró además una amplificación de los pesos en la proximidad del límite superior del dominio, alrededor de 13 Hz. La matriz de Gram presentó un número de condición aproximado de $1,40 \times 10^3$ y las funciones B-spline de los extremos tuvieron un soporte efectivo menor que las funciones interiores. En consecuencia, los máximos aislados próximos a 13 Hz se consideraron sensibles a la parametrización de borde y no se utilizaron para establecer conclusiones neurofisiológicas. Este comportamiento no afecta la interpretación principal del intervalo pre-alfa, que se encuentra alejado del límite superior del dominio.

Las funciones $\beta_c(f)$ deben interpretarse como pesos condicionales del clasificador. Por tanto, el patrón positivo observado en regiones posteriores no constituye por sí mismo una diferencia univariada de potencia entre HC y PD_OFF, ni demuestra una relación causal. Su aporte consiste en mostrar qué regiones del dominio funcional contribuyeron de forma estable a las decisiones del modelo después de considerar conjuntamente los diez canales.

5. CONCLUSIONES

Este trabajo desarrolló y evaluó una estrategia de clasificación que integra Análisis de Datos Funcionales y aprendizaje profundo para representar señales EEG de reposo en la clasificación experimental entre pacientes con enfermedad de Parkinson y personas sanas. A partir de la evaluación de distintas arquitecturas profundas, se seleccionó una configuración final del modelo propuesto, manteniendo modelos clásicos y características escalares como referencias comparativas.

5.1 PRINCIPALES HALLAZGOS Y CONTRIBUCIÓN

El objetivo general de esta investigación se cumplió mediante el desarrollo y evaluación de una propuesta de clasificación que integra representaciones obtenidas mediante Análisis de Datos Funcionales con modelos de aprendizaje profundo para señales EEG. Para operacionalizar esta propuesta se evaluaron siete arquitecturas profundas sobre distintas representaciones funcionales. De acuerdo con la métrica principal definida para el estudio, la configuración FDNN con Cholesky+FPCA bajo la estrategia A2 alcanzó la mayor exactitud balanceada observada entre las arquitecturas de aprendizaje profundo ($0,781 \pm 0,113$), con un AUC de $0,875 \pm 0,090$, y se adoptó como configuración final del modelo propuesto. Esta selección corresponde al mejor desempeño observado dentro del conjunto de modelos profundos evaluados y no al mejor resultado global del estudio. Los modelos clásicos se incluyeron como referencias comparativas y, en varias configuraciones, alcanzaron valores observados superiores. En consecuencia, bajo las condiciones evaluadas, una mayor complejidad del clasificador no garantizó un mejor desempeño.

5.1.1 Contribución de la representación funcional

La caracterización espectral de la cohorte mostró un patrón compatible con el enlentecimiento descrito en la enfermedad de Parkinson. En las derivaciones posteriores, la frecuencia del pico alfa fue menor en los pacientes que en las personas sanas, con una diferencia estadísticamente significativa y un tamaño de efecto moderado. Este resultado proporciona un contexto neurofisiológico para evaluar representaciones capaces de conservar la forma del espectro.

La línea base escalar alcanzó una exactitud balanceada máxima observada de $0,732 \pm 0,124$, obtenida mediante Transformer. Al utilizar una representación funcional en el dominio de la frecuencia, la estrategia A1 alcanzó una exactitud balanceada de $0,818 \pm 0,109$ mediante regresión logística con transformación de Cholesky. Por tanto, bajo las condiciones evaluadas, esta configuración funcional obtuvo un mayor desempeño observado que la mejor configuración de la línea base escalar, con una diferencia absoluta de $0,086$ en exactitud balanceada. Dado que estos valores corresponden a máximos observados

entre múltiples configuraciones y no se realizó un contraste inferencial formal entre ellas, el resultado debe interpretarse de forma descriptiva y no como evidencia de superioridad estadística de la representación funcional.

La estrategia A2 utilizó representaciones funcionales individuales por época durante el entrenamiento y agregó posteriormente las probabilidades predichas a nivel de sujeto. Bajo esta estrategia, la regresión logística alcanzó el máximo valor medio observado de exactitud balanceada del estudio, de $0,824$, tanto con la transformación de Cholesky ($0,824 \pm 0,092$) como con Cholesky+FPCA ($0,824 \pm 0,115$). Con Cholesky+FPCA, el AUC fue de $0,902 \pm 0,111$. Estos resultados muestran que el entrenamiento con múltiples representaciones por sujeto puede modificar el desempeño respecto a A1; sin embargo, A2 no incrementa el número de sujetos independientes y las diferencias observadas tampoco pueden atribuirse exclusivamente a la multiplicidad de épocas, dado que la dinámica de optimización difiere respecto al entrenamiento con una única representación por sujeto. Las comparaciones se interpretan de forma descriptiva, ya que no se realizó un contraste inferencial formal entre estrategias.

El Enfoque B permitió extender al contexto de clasificación una estrategia de análisis funcional previamente utilizada para conservar la variabilidad época a época de características espectrales del EEG. En este trabajo, las potencias relativas theta y alfa se representaron como trayectorias sobre el orden normalizado de las épocas. La selección mediante GCV favoreció una representación de baja complejidad, con cuatro funciones B-spline por banda, indicando que una mayor flexibilidad no mejoraba suficientemente el compromiso entre ajuste y complejidad dentro del rango evaluado. Las trayectorias obtenidas mostraron principalmente diferencias descriptivas de nivel entre HC y PD_OFF, más que cambios marcados en su forma a lo largo del orden normalizado de las épocas. Aunque el desempeño observado fue inferior al de las mejores configuraciones del Enfoque A, los resultados muestran que esta representación conserva información potencialmente útil para la clasificación experimental. Las mejoras observadas al incorporar las transformaciones funcionales sugieren, además, que el aprovechamiento de dicha información depende no solo de la construcción de las trayectorias, sino también de la representación geométrica y dimensional utilizada antes de la clasificación.

El análisis complementario de ablación permitió precisar la contribución de la representación funcional. Al mantener constante la regresión logística y el esquema de validación, la PSD discretizada entre 4 Hz y 13 Hz alcanzó una exactitud balanceada de $0,818 \pm 0,117$ y un AUC de $0,879 \pm 0,124$, mientras que A1 con transformación de Cholesky obtuvo $0,818 \pm 0,109$ y $0,879 \pm 0,097$, respectivamente. Por tanto, en esta comparación no se observó una ganancia predictiva adicional atribuible exclusivamente al uso del ADF. En cambio, la representación basada únicamente en theta, alfa y PAF alcanzó una exactitud balanceada de $0,758 \pm 0,143$, lo que indica que conservar la forma espectral detallada del intervalo de 4 Hz a 13 Hz proporcionó información relevante frente a su reducción a características escalares.

El aporte del ADF en este estudio debe entenderse, por tanto, no como una mejora predictiva demostrada frente a una PSD discretizada equivalente, sino como una forma estructurada de representar la información espectral, incorporar la geometría funcional y facilitar su interpretación sobre un dominio continuo. En particular, la reconstrucción de las funciones de peso mostró una contribución positiva consistente del intervalo pre-alfa de 5,5 Hz a 8 Hz en los canales parietales y occipitales, observada en las quince particiones externas. Este patrón corresponde a la ponderación condicional del clasificador y no constituye por sí mismo una diferencia univariada entre los grupos ni evidencia de un biomarcador clínico.

5.1.2 Complejidad del modelo y tamaño de la muestra

Se implementaron y evaluaron siete arquitecturas de aprendizaje profundo de distinta naturaleza, desde redes de propósito general hasta redes funcionales y una arquitectura concebida específicamente para EEG. Sin embargo, bajo las condiciones evaluadas, ninguna arquitectura profunda superó el mejor desempeño observado de los modelos clásicos dentro de las estrategias analizadas.

En la estrategia A1, el mayor valor observado de exactitud balanceada entre las arquitecturas profundas correspondió a MLP con transformación de Cholesky, con $0,752 \pm 0,142$. Este valor fue inferior al obtenido por la regresión logística con la misma transformación, que alcanzó $0,818 \pm 0,109$.

En el Enfoque B, el mayor valor observado entre las arquitecturas profundas correspondió a CNN1D con transformación de Cholesky, con una exactitud balanceada de $0,762 \pm 0,141$. En este enfoque, Random Forest con Cholesky+FPCA alcanzó $0,781 \pm 0,094$, correspondiente al mayor valor observado de exactitud balanceada, mientras que la regresión logística con Cholesky+FPCA presentó el mayor AUC, de $0,912 \pm 0,098$.

La estrategia A2 permitió entrenar con múltiples representaciones funcionales por sujeto, preservando la variabilidad entre épocas. En los modelos profundos también incrementó el número de observaciones utilizadas durante la optimización y, por tanto, el número de actualizaciones de los parámetros respecto de A1. En consecuencia, las diferencias de desempeño entre ambas estrategias no pueden atribuirse únicamente a la disponibilidad de múltiples representaciones, sino también a la distinta dinámica de entrenamiento.

Dentro de A2, el mayor desempeño observado entre las arquitecturas profundas correspondió a FDNN con Cholesky+FPCA, con una exactitud balanceada de $0,781 \pm 0,113$ y un AUC de $0,875 \pm 0,090$. Esta configuración se adoptó como realización final del modelo de aprendizaje profundo basado en ADF propuesto en esta investigación. No obstante, la regresión logística alcanzó una exactitud balanceada media de $0,824$ tanto con Cholesky

($0,824 \pm 0,092$) como con Cholesky+FPCA ($0,824 \pm 0,115$). Por tanto, el modelo profundo propuesto no constituyó la configuración con el mayor desempeño observado del estudio.

El aumento de la complejidad del clasificador no se tradujo en una mejora sistemática del desempeño. En esta cohorte, los modelos clásicos, particularmente la regresión logística, aprovecharon de manera competitiva las representaciones funcionales y alcanzaron los mejores resultados observados. Este hallazgo sugiere que la calidad de la representación puede desempeñar un papel tan relevante como la complejidad del modelo de clasificación.

La curva de aprendizaje mostró además que el desempeño permaneció sensible al número de sujetos independientes utilizados durante el entrenamiento, con una variabilidad considerable y una tendencia no estrictamente monótona. Por tanto, los resultados sugieren que el tamaño reducido de la cohorte constituye una limitación relevante para evaluar la capacidad de generalización de arquitecturas de mayor capacidad. La utilidad potencial de los modelos profundos deberá estudiarse en cohortes de mayor tamaño y, preferiblemente, mediante validación externa.

5.1.3 Comparación con el estado del arte

Diversos estudios de clasificación de la enfermedad de Parkinson a partir de EEG han reportado valores de exactitud cercanos al $99\,\%$ [18], [19], [39]. Algunos de estos enfoques utilizan representaciones tiempo-frecuencia combinadas con redes convolucionales [18], [19]. Sin embargo, estas cifras no son directamente comparables con los resultados obtenidos en este estudio debido a diferencias en las cohortes, las representaciones de entrada, las métricas empleadas y, especialmente, los esquemas de validación.

En este trabajo, la evaluación se realizó manteniendo la separación entre sujetos en las particiones externas de entrenamiento y prueba y utilizando al sujeto como unidad final de evaluación. Bajo este esquema, el máximo valor medio observado de exactitud balanceada fue de $0,824$, alcanzado en A2 mediante regresión logística tanto con Cholesky ($0,824 \pm 0,092$) como con Cholesky+FPCA ($0,824 \pm 0,115$). En A1, la regresión logística con transformación de Cholesky alcanzó una exactitud balanceada de $0,818 \pm 0,109$.

La diferencia entre estas cifras y las reportadas en otros trabajos no debe interpretarse de forma directa como una menor capacidad del enfoque propuesto. La magnitud del desempeño reportado puede verse afectada por la unidad utilizada para construir las particiones de entrenamiento y prueba, el tamaño y las características de la cohorte, el balance entre grupos y la métrica seleccionada para resumir el desempeño.

Por tanto, la comparación con el estado del arte debe centrarse principalmente en las condiciones metodológicas bajo las cuales se obtienen los resultados. La contribución de este trabajo reside en evaluar representaciones funcionales del EEG mediante modelos de distinta complejidad bajo un esquema de validación orientado a estimar la generalización a sujetos no observados, evitando interpretar las épocas de un mismo sujeto como observaciones independientes durante la evaluación externa.

5.1.4 Alcance de la contribución

La contribución de este trabajo no reside únicamente en el desempeño predictivo observado, sino en la evaluación del ADF como marco de representación de la información espectral del EEG. La representación funcional permite conservar la forma del espectro mediante una base de funciones, incorporar la geometría L^2 en el espacio de coeficientes mediante la transformación de Cholesky y obtener representaciones de dimensión controlada que pueden emplearse como entrada tanto de modelos clásicos como de arquitecturas de aprendizaje profundo.

Las configuraciones funcionales alcanzaron valores observados superiores a los de la línea base escalar en determinadas condiciones. En particular, la estrategia A2 con regresión logística alcanzó el máximo valor medio observado de exactitud balanceada, de $0,824$, tanto con Cholesky $(0,824 \pm 0,092)$ como con Cholesky+FPCA $(0,824 \pm 0,115)$. Sin embargo, el análisis de ablación mostró que, bajo una comparación controlada en A1 con regresión logística, la PSD discretizada entre 4 Hz y 13 Hz y la representación funcional con transformación de Cholesky alcanzaron la misma exactitud balanceada media de $0,818$. Por lo tanto, el mayor desempeño observado frente a la línea base escalar no puede atribuirse exclusivamente al uso del ADF, sino también a la conservación de información espectral más detallada dentro del intervalo theta-alfa.

La FPCA permitió además reducir la dimensión de las representaciones funcionales. Después del ajuste necesario para mantener una dimensión común entre canales, el Enfoque A presentó una reducción media del $46{,}7\,\%$ respecto a los 110 coeficientes originales, mientras que en el Enfoque B la reducción fue de aproximadamente el $30\,\%$ respecto a los 80 coeficientes iniciales. Esta reducción dimensional no produjo una mejora predictiva uniforme, pero permitió conservar una proporción elevada de la variabilidad funcional mediante un menor número de coordenadas.

En respuesta a la pregunta de investigación, los resultados muestran que el aporte del ADF no se manifestó como una mejora predictiva adicional frente a una representación discretizada que conserva la misma información espectral. En la comparación controlada de A1 con regresión logística, la PSD discretizada entre 4 Hz y 13 Hz y la representación funcional con transformación de Cholesky alcanzaron la misma exactitud balanceada me-

dia de $0,818$. En contraste, la representación resumida mediante theta, alfa y PAF obtuvo un desempeño inferior, lo que indica que la conservación de la estructura espectral detallada fue más relevante para la clasificación que su reducción a unas pocas características escalares.

El aporte específico del ADF se situó principalmente en la forma de representar y analizar esta información. La aproximación mediante B-splines permitió pasar de 190 valores espectrales discretos a 110 coeficientes funcionales, incorporar la geometría del espacio L^2 mediante la transformación de Cholesky y reconstruir funciones de peso continuas sobre el dominio frecuencial. Estas funciones mostraron una ponderación positiva consistente en el intervalo pre-alfa de 5,5 Hz a 8 Hz en las derivaciones parietales y occipitales a través de las quince particiones externas. Por tanto, bajo las condiciones de este estudio, la principal contribución del ADF fue proporcionar una representación funcional compacta y una vía de interpretación continua del clasificador, más que una ventaja predictiva demostrada frente a la PSD discretizada equivalente.

5.2 LIMITACIONES

Los resultados deben interpretarse considerando varias limitaciones metodológicas. La cohorte estuvo conformada por cuarenta y ocho sujetos, un tamaño que restringe la evaluación de modelos de alta capacidad y aumenta la incertidumbre sobre su capacidad de generalización. Esta limitación se refleja en la ventaja observada de los modelos lineales y en la sensibilidad del desempeño al número de sujetos independientes disponibles para el entrenamiento.

A ello se suma que el estudio se realizó sobre una única cohorte y una única condición de registro, con los pacientes en estado OFF de medicación. Por lo tanto, la validez externa de los resultados frente a otras poblaciones, equipos, protocolos o condiciones de medicación permanece por establecer.

Por otra parte, el análisis se centró principalmente en la información espectral del EEG de reposo. No se evaluaron enfoques que utilizaran directamente la señal preprocesada en el dominio temporal como entrada de los modelos, ni características de conectividad entre regiones. Estas alternativas constituyen posibles extensiones para trabajos futuros.

Asimismo, en CNN1D y EEGNet las convoluciones se aplicaron sobre representaciones derivadas del procesamiento funcional cuyas coordenadas, particularmente después de Cholesky o FPCA, no conservan necesariamente una noción directa de localidad temporal o frecuencial. Este aspecto debe considerarse al interpretar el desempeño de estas arquitecturas.

La comparación entre configuraciones se basó principalmente en los valores medios observados y no incluyó un contraste inferencial formal entre clasificadores. Además, al destacar el mejor desempeño entre múltiples combinaciones de representación y modelo existe un posible sesgo de selección asociado al máximo observado. Finalmente, las arquitecturas de aprendizaje profundo se evaluaron con una configuración común y fija, sin una optimización específica para cada arquitectura; por tanto, las diferencias entre modelos deben interpretarse en el contexto de las configuraciones evaluadas.

El estudio se plantea de forma intencionada como una exploración de biomarcadores neurofisiológicos y de la viabilidad de una representación, no como una herramienta de diagnóstico. La clasificación obtenida es experimental y no sustituye la valoración clínica.

5.3 TRABAJO FUTURO

Una primera línea de trabajo futuro consiste en fortalecer la comparación estadística entre los modelos y representaciones evaluados. Estudios posteriores podrían incorporar intervalos de confianza y contrastes estadísticos que tengan en cuenta la dependencia entre las evaluaciones obtenidas mediante validación cruzada repetida. De esta manera, sería posible establecer con mayor precisión si las diferencias observadas entre configuraciones reflejan un comportamiento sistemático o pueden atribuirse a la variabilidad de las particiones y al tamaño limitado de la cohorte.

De manera complementaria, resulta prioritaria la validación en cohortes mayores y multicéntricas. La curva de aprendizaje mostró que el desempeño continuó siendo sensible al número de sujetos independientes utilizados durante el entrenamiento, hasta el máximo evaluado de 38 sujetos. Una muestra más amplia permitiría estimar con mayor precisión la capacidad de generalización de los modelos y evaluar si las arquitecturas de aprendizaje profundo se benefician de una mayor disponibilidad de datos. La evaluación sobre registros de distintos centros permitiría además estudiar la generalización del enfoque, aunque requeriría controlar el efecto de sitio asociado con diferencias entre equipos, protocolos y condiciones de adquisición, mediante estrategias de validación entre centros o armonización de los registros.

El conjunto de datos incluye registros de los pacientes en estado de medicación que no fueron utilizados en este trabajo. Estos datos permitirían estudiar cómo la medicación dopaminérgica modifica la representación funcional del espectro, comparando los estados ON y OFF dentro de un mismo paciente, en lugar de emplearlos únicamente para la clasificación entre grupos.

Otra extensión consiste en evaluar directamente la señal EEG preprocesada en el dominio temporal, sin transformarla previamente en densidad espectral de potencia. La compara-

ción entre modelos entrenados sobre la señal temporal y aquellos basados en PSD y ADF permitiría determinar si existen patrones discriminantes adicionales a los contenidos en la representación espectral funcional.

Finalmente, relacionar las representaciones funcionales con variables clínicas de severidad permitiría estudiar su asociación con el grado de avance de la enfermedad. También resulta de interés evaluar su comportamiento en fases tempranas o prodrómicas, donde la exploración de biomarcadores EEG podría adquirir mayor relevancia como herramienta complementaria de investigación.

REFERENCIAS

[1] World Health Organization, «Parkinson Disease: A Public Health Approach: Technical Brief,» World Health Organization, Geneva, 2022. dirección: https://www.who.int/publications/i/item/9789240050983

[2] K. R. Chaudhuri y A. H. V. Schapira, «Non-motor symptoms of Parkinson's disease: Dopaminergic pathophysiology and treatment,» *The Lancet Neurology*, vol. 8, n.º 5, págs. 464-474, 2009. DOI: 10.1016/S1474-4422(09)70068-7

[3] W. Poewe et al., «Parkinson disease,» *Nature Reviews Disease Primers*, vol. 3, pág. 17 013, 2017. DOI: 10.1038/nrdp.2017.13

[4] G. Rizzo, M. Copetti, S. Arcuti, D. Martino, A. Fontana y G. Logroscino, «Accuracy of clinical diagnosis of Parkinson disease: A systematic review and meta-analysis,» *Neurology*, vol. 86, n.º 6, págs. 566-576, 2016. DOI: 10.1212/WNL.0000000000002350

[5] A. M. Maitín, Á. J. García-Tejedor y J. P. Romero Muñoz, «Machine learning approaches for detecting Parkinson's disease from EEG analysis: A systematic review,» *Applied Sciences*, vol. 10, n.º 23, pág. 8662, 2020. DOI: 10.3390/app10238662

[6] V. J. Geraedts et al., «Clinical correlates of quantitative EEG in Parkinson disease: A systematic review,» *Neurology*, vol. 91, n.º 19, págs. 871-883, 2018. DOI: 10.1212/WNL.0000000000006473

[7] S. Sanei y J. A. Chambers, *EEG Signal Processing*. John Wiley & Sons, 2007, ISBN: 9780470025819. DOI: 10.1002/9780470511923

[8] A. Jaramillo-Jimenez et al., «Spectral features of resting-state EEG in Parkinson's Disease: a multicenter study using functional data analysis,» *Clinical Neurophysiology*, vol. 151, págs. 28-40, 2023. DOI: 10.1016/j.clinph.2023.03.363

[9] J. O. Ramsay y B. W. Silverman, *Functional Data Analysis* (Springer Series in Statistics), 2.ª ed. New York: Springer, 2005. DOI: 10.1007/b98888

[10] Y. LeCun, Y. Bengio y G. Hinton, «Deep learning,» *Nature*, vol. 521, n.º 7553, págs. 436-444, 2015. DOI: 10.1038/nature14539

[11] Z. Ou et al., «Global trends in the incidence, prevalence, and years lived with disability of Parkinson's disease in 204 countries/territories from 1990 to 2019,» *Frontiers in Public Health*, vol. 9, pág. 776 847, 2021. DOI: 10.3389/fpubh.2021.776847

[12] W. Dauer y S. Przedborski, «Parkinson's disease: Mechanisms and models,» *Neuron*, vol. 39, n.º 6, págs. 889-909, 2003. DOI: 10.1016/S0896-6273(03)00568-3

[13] A.-G. P. Dennis y A. P. Strafella, «The role of AI and machine learning in the diagnosis of Parkinson's disease and atypical parkinsonisms,» *Parkinsonism & Related Disorders*, vol. 126, pág. 106 986, 2024. DOI: 10.1016/j.parkreldis.2024.106986

[14] Y. Zhao et al., «Peak alpha frequency and alpha power spectral density as vulnerability markers of cognitive impairment in Parkinson's disease: an exploratory EEG study,» *Frontiers in Neuroscience*, vol. 19, pág. 1 575 815, 2025. DOI: 10.3389/fnins.2025.1575815

[15] J. Gertheiss, D. Rügamer, B. X. W. Liew y S. Greven, «Functional data analysis: An introduction and recent developments,» *Biometrical Journal*, vol. 66, n.º 7, e202300363, 2024. DOI: 10.1002/bimj.202300363

[16] S. Lee, R. Hussein, R. Ward, Z. J. Wang y M. J. McKeown, «A convolutional-recurrent neural network approach to resting-state EEG classification in Parkinson's disease,» *Journal of Neuroscience Methods*, vol. 361, pág. 109 282, 2021. DOI: 10.1016/j.jneumeth.2021.109282

[17] S. A. A. Shah, L. Zhang y A. Bais, «Dynamical system based compact deep hybrid network for classification of Parkinson disease related EEG signals,» *Neural Networks*, vol. 130, págs. 75-84, 2020. DOI: 10.1016/j.neunet.2020.06.018

[18] S. K. Khare, V. Bajaj y U. R. Acharya, «PDCNNet: An automatic framework for the detection of Parkinson's disease using EEG signals,» *IEEE Sensors Journal*, vol. 21, n.º 15, págs. 17 017-17 024, 2021. DOI: 10.1109/JSEN.2021.3080135

[19] H. W. Loh et al., «GaborPDNet: Gabor transformation and deep neural network for Parkinson's disease detection using EEG signals,» *Electronics*, vol. 10, n.º 14, pág. 1740, 2021. DOI: 10.3390/electronics10141740

[20] S. J. Raudys y A. K. Jain, «Small sample size effects in statistical pattern recognition: Recommendations for practitioners,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 13, n.º 3, págs. 252-264, 1991. DOI: 10.1109/34.75512

[21] C. D. Marsden y J. A. Obeso, «The functions of the basal ganglia and the paradox of stereotaxic surgery in Parkinson's disease,» *Brain*, vol. 117, n.º 4, págs. 877-897, 1994. DOI: 10.1093/brain/117.4.877

[22] D. J. Brooks, «Imaging approaches to Parkinson disease,» *Journal of Nuclear Medicine*, vol. 51, n.º 4, págs. 596-609, 2010. DOI: 10.2967/jnumed.108.059998

[23] F. Ba y W. R. W. Martin, «Dopamine transporter imaging as a diagnostic tool for parkinsonism and related disorders in clinical practice,» *Parkinsonism & Related Disorders*, vol. 21, n.º 2, págs. 87-94, 2015. DOI: 10.1016/j.parkreldis.2014.11.007

[24] F. Ferraty y P. Vieu, *Nonparametric Functional Data Analysis: Theory and Practice* (Springer Series in Statistics). New York: Springer, 2006, ISBN: 978-0-387-30369-7. DOI: 10.1007/0-387-36620-2

[25] J. O. Ramsay, G. Hooker y S. Graves, *Functional Data Analysis with R and MATLAB*. New York: Springer, 2009. DOI: 10.1007/978-0-387-98185-7

[26] P. Craven y G. Wahba, «Smoothing noisy data with spline functions: Estimating the correct degree of smoothing by the method of generalized cross-validation,» *Numerische Mathematik*, vol. 31, n.º 4, págs. 377-403, 1979. DOI: 10.1007/BF01404567

[27] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016. dirección: https://www.deeplearningbook.org

[28] A. Vaswani et al., «Attention is all you need,» en *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, 2017, págs. 5998-6008. dirección: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

[29] S. Jain y B. C. Wallace, «Attention is not Explanation,» en *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, Association for Computational Linguistics, 2019, págs. 3543-3556. DOI: 10.18653/v1/N19-1357

[30] F. Rossi, N. Delannay, B. Conan-Guez y M. Verleysen, «Representation of functional data in neural networks,» *Neurocomputing*, vol. 64, págs. 183-210, 2005. DOI: 10.1016/j.neucom.2004.11.012

[31] B. Thind, K. Multani y J. Cao, «Deep learning with functional inputs,» *Journal of Computational and Graphical Statistics*, vol. 32, n.º 1, págs. 171-180, 2023. DOI: 10.1080/10618600.2022.2097914

[32] B. Thind, K. Multani y J. Cao, *Neural networks as functional classifiers*, 2020. arXiv: 2010.04305 [stat.ML].

[33] J. Yao, J. Mueller y J.-L. Wang, «Deep learning for functional data analysis with adaptive basis layers,» en *Proceedings of the 38th International Conference on Machine Learning (ICML)*, ép. Proceedings of Machine Learning Research, vol. 139, PMLR, 2021, págs. 11 898-11 908.

[34] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung y B. J. Lance, «EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces,» *Journal of Neural Engineering*, vol. 15, n.º 5, pág. 056 013, 2018. DOI: 10.1088/1741-2552/aace8c

[35] M. F. Anjum, S. Dasgupta, R. Mudumbai, A. Singh, J. F. Cavanagh y N. S. Narayanan, «Linear predictive coding distinguishes spectral EEG features of Parkinson's disease,» *Parkinsonism & Related Disorders*, vol. 79, págs. 79-85, 2020. DOI: 10.1016/j.parkreldis.2020.08.001

[36] S. K. Khare, V. Bajaj y U. R. Acharya, «Detection of Parkinson's disease using automated tunable Q wavelet transform technique with EEG signals,» *Biocybernetics and Biomedical Engineering*, vol. 41, n.º 2, págs. 679-689, 2021. DOI: 10.1016/j.bbe.2021.04.008

[37] M. Aljalal, S. A. Aldosari, M. Molinas, K. AlSharabi y F. A. Alturki, «Detection of Parkinson's disease from EEG signals using discrete wavelet transform, different entropy measures, and machine learning techniques,» *Scientific Reports*, vol. 12, n.º 1, pág. 22 547, 2022. DOI: 10.1038/s41598-022-26644-7

[38] M. Aljalal, S. A. Aldosari, K. AlSharabi, A. M. Abdurraqeeb y F. A. Alturki, «Parkinson's disease detection from resting-state EEG signals using common spatial pattern, entropy, and machine learning techniques,» *Diagnostics*, vol. 12, n.º 5, pág. 1033, 2022. DOI: 10.3390/diagnostics12051033

[39] M. Belyaev, M. Murugappan, A. Velichko y D. Korzun, «Entropy-based machine learning model for fast diagnosis and monitoring of Parkinson's disease,» *Sensors*, vol. 23, n.º 20, pág. 8609, 2023. DOI: 10.3390/s23208609

[40] C.-Y. Yang e Y.-Z. Huang, «Parkinson's disease classification using machine learning approaches and resting-state EEG,» *Journal of Medical and Biological Engineering*, vol. 42, n.º 2, págs. 263-270, 2022. DOI: 10.1007/s40846-022-00695-7

[41] K. AlSharabi, Y. Bin Salamah, A. M. Abdurraqeeb, M. Aljalal y F. A. Alturki, «EEG signal processing for Alzheimer's disorders using discrete wavelet transform and machine learning approaches,» *IEEE Access*, vol. 10, págs. 89 781-89 797, 2022. DOI: 10.1109/ACCESS.2022.3198988

[42] S. L. Oh et al., «A deep learning approach for Parkinson's disease diagnosis from EEG signals,» *Neural Computing and Applications*, vol. 32, n.º 15, págs. 10 927-10 933, 2020. DOI: 10.1007/s00521-018-3689-5

[43] M. Shaban y A. W. Amara, «Resting-state electroencephalography based deep-learning for the detection of Parkinson's disease,» *PLoS ONE*, vol. 17, n.º 2, e0263159, 2022. DOI: 10.1371/journal.pone.0263159

[44] H. Chang, B. Liu, Y. Zong, C. Lu y X. Wang, «EEG-based Parkinson's disease recognition via attention-based sparse graph convolutional neural network,» *IEEE Journal of Biomedical and Health Informatics*, vol. 27, n.º 11, págs. 5216-5224, 2023. DOI: 10.1109/JBHI.2023.3292452

[45] S. Wang, G. Wang, G. Pei y T. Yan, «An EEG-based approach for Parkinson's disease diagnosis using capsule network,» en *2022 7th International Conference on Intelligent Computing and Signal Processing (ICSP)*, 2022, págs. 1641-1645. DOI: 10.1109/ICSP54964.2022.9778541

[46] L. Qiu, J. Li, L. Zhong, W. Feng, C. Zhou y J. Pan, «A novel EEG-based Parkinson's disease detection model using multiscale convolutional prototype networks,» *IEEE Transactions on Instrumentation and Measurement*, vol. 73, pág. 4 002 814, 2024. DOI: 10.1109/TIM.2024.3351248

[47] V. Mancazzo, E. Sibilano, D. Buongiorno, R. Carli, V. Bevilacqua y A. Brunetti, «Parkinson's disease detection from resting-state EEG using a Transformer model with Multi-Head Attention explanations,» *Biomedical Signal Processing and Control*, vol. 119, pág. 109 811, 2026. DOI: 10.1016/j.bspc.2026.109811

[48] F. Del Pup, A. Zanola, L. F. Tshimanga, A. Bertoldo, L. Finos y M. Atzori, «The role of data partitioning on the performance of EEG-based deep learning models in supervised cross-subject analysis: A preliminary study,» *Computers in Biology and Medicine*, vol. 196, pág. 110 608, 2025. DOI: 10.1016/j.compbiomed.2025.110608

[49] F. Rossi y B. Conan-Guez, «Functional Multi-Layer Perceptron: A Nonlinear Tool for Functional Data Analysis,» *Neural Networks*, vol. 18, n.º 1, págs. 45-60, 2005. DOI: 10.1016/j.neunet.2004.07.001

[50] A. R. Rao y M. Reimherr, «Nonlinear functional modeling using neural networks,» *Journal of Computational and Graphical Statistics*, vol. 32, n.º 4, págs. 1248-1257, 2023. DOI: 10.1080/10618600.2023.2165498

[51] S. Xie y A. T. Lawniczak, «Fourier Spectral Domain Functional Principal Component Analysis of EEG Signals,» en *Pattern Recognition Applications and Methods*, ép. Lecture Notes in Computer Science, vol. 11996, Springer, 2020, págs. 3-22. DOI: 10.1007/978-3-030-40014-9_1

[52] K. Hasenstab et al., «A multi-dimensional functional principal components analysis of EEG data,» *Biometrics*, vol. 73, n.º 3, págs. 999-1009, 2017. DOI: 10.1111/biom.12635

[53] Y. Zhang, C. Wang, F. Wu, K. Huang, L. Yang y L. Ji, «Prediction of working memory ability based on EEG by functional data analysis,» *Journal of Neuroscience Methods*, vol. 333, pág. 108 552, 2020. DOI: 10.1016/j.jneumeth.2019.108552

[54] F. Heinrichs, M. Heim y C. Weber, «Functional Neural Networks: Shift Invariant Models for Functional Data with Applications to EEG Classification,» en *Proceedings of the 40th International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 202, PMLR, 2023, págs. 12 866-12 881.

[55] M. Heim et al., «Real-time EEG-based BCI for self-paced motor imagery and motor execution using functional neural networks,» *IEEE Access*, vol. 13, págs. 91 232-91 247, 2025. DOI: 10.1109/ACCESS.2025.3569932

[56] Y. Yi, N. Billor, M. Liang, X. Cao, A. Ekstrom y J. Zheng, «Classification of EEG signals: An interpretable approach using functional data analysis,» *Journal of Neuroscience Methods*, vol. 376, pág. 109 609, 2022. DOI: 10.1016/j.jneumeth.2022.109609

[57] M. P. Bohorquez Castañeda, M. A. Muñoz Layton, L. C. Sarmiento Vela, J. Mateu Mahiques y P. Moraga, «A Quadratic Discriminant Analysis Rule for Spatial Functional Data: Application to EEG Data for Silent Speech Recognition,» *Journal of Classification*, vol. 43, n.º 2, págs. 352-381, 2026. DOI: 10.1007/s00357-025-09533-2

[58] F. Maturo y R. Verde, «Pooling random forest and functional data analysis for biomedical signals supervised classification: Theory and application to electrocardiogram data,» *Statistics in Medicine*, vol. 41, n.º 12, págs. 2247-2275, 2022. DOI: 10.1002/sim.9353

[59] J. F. Cavanagh, *EEG: 3-Stim Auditory Oddball and Rest in Parkinson's*, OpenNeuro, Dataset ds003490, version 1.1.0, 2021. DOI: 10.18112/openneuro.ds003490.v1.1.0

[60] J. F. Cavanagh, P. Kumar, A. A. Mueller, S. Pirio Richardson y A. Mueen, «Diminished EEG habituation to novel events effectively classifies Parkinson's patients,» *Clinical Neurophysiology*, vol. 129, n.º 2, págs. 409-418, 2018. DOI: 10.1016/j.clinph.2017.11.023

[61] J.-M. Melgari et al., «Alpha and beta EEG power reflects L-dopa acute administration in parkinsonian patients,» *Frontiers in Aging Neuroscience*, vol. 6, pág. 302, 2014. DOI: 10.3389/fnagi.2014.00302

[62] A. Gramfort et al., «MEG and EEG data analysis with MNE-Python,» *Frontiers in Neuroscience*, vol. 7, pág. 267, 2013. DOI: 10.3389/fnins.2013.00267

[63] I. Suuronen, A. Airola, T. Pahikkala, M. Murtojärvi, V. Kaasinen y H. Railo, «Budget-Based Classification of Parkinson's Disease From Resting State EEG,» *IEEE Journal of Biomedical and Health Informatics*, vol. 27, n.º 8, págs. 3740-3747, 2023. DOI: 10.1109/JBHI.2023.3235040

[64] P. D. Welch, «The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms,» *IEEE Transactions on Audio and Electroacoustics*, vol. 15, n.º 2, págs. 70-73, 1967. DOI: 10.1109/TAU.1967.1161901

[65] G. Rodriguez, F. Copello, P. Vitali, G. Perego y F. Nobili, «EEG spectral profile to stage Alzheimer's disease,» *Clinical Neurophysiology*, vol. 110, n.º 10, págs. 1831-1837, 1999. DOI: 10.1016/S1388-2457(99)00123-6

[66] J. Schumacher et al., «Quantitative EEG as a biomarker in mild cognitive impairment with Lewy bodies,» *Alzheimer's Research & Therapy*, vol. 12, pág. 82, 2020. DOI: 10.1186/s13195-020-00650-1

[67] F. T. Y. Smulders, S. ten Oever, F. C. L. Donkers, C. W. E. M. Quaedflieg y V. van de Ven, «Single-trial log transformation is optimal in frequency analysis of resting EEG alpha,» *European Journal of Neuroscience*, vol. 48, n.º 7, págs. 2585-2598, 2018. DOI: 10.1111/ejn.13854

[68] F. Pedregosa et al., «Scikit-learn: Machine learning in Python,» *Journal of Machine Learning Research*, vol. 12, págs. 2825-2830, 2011.

[69] M. Chaturvedi et al., «Quantitative EEG (QEEG) Measures Differentiate Parkinson's Disease (PD) Patients from Healthy Controls (HC),» *Frontiers in Aging Neuroscience*, vol. 9, pág. 3, 2017. DOI: 10.3389/fnagi.2017.00003

A. RESULTADOS COMPLETOS POR MODELO

Las tablas de este anexo presentan los resultados completos de los modelos evaluados. Todos los valores corresponden a la media $\pm$ desviación estándar sobre las quince evaluaciones obtenidas con cinco particiones y tres semillas. La evaluación final se realiza a nivel de sujeto. En negrita se indica el valor más alto de cada métrica dentro de cada representación; cuando dos valores coinciden al nivel de precisión reportado, ambos se resaltan.

Tabla A.1: Resultados de la línea base sin ADF basada en características escalares.

Modelo	Exactitud bal.	Sens.	Espec.	F1	AUC
LogReg	$0{,}684 \pm 0{,}146$	$0{,}713 \pm 0{,}235$	$0{,}656 \pm 0{,}228$	$0{,}673 \pm 0{,}211$	$0{,}792 \pm 0{,}145$
Random Forest	$0{,}715 \pm 0{,}130$	$\mathbf{0{,}797 \pm 0{,}152}$	$0{,}633 \pm 0{,}226$	$0{,}732 \pm 0{,}117$	$\mathbf{0{,}837 \pm 0{,}115}$
MLP	$0{,}672 \pm 0{,}124$	$0{,}677 \pm 0{,}290$	$\mathbf{0{,}667 \pm 0{,}219}$	$0{,}632 \pm 0{,}223$	$0{,}714 \pm 0{,}218$
Transformer	$\mathbf{0{,}732 \pm 0{,}124}$	$\mathbf{0{,}797 \pm 0{,}152}$	$\mathbf{0{,}667 \pm 0{,}215}$	$\mathbf{0{,}746 \pm 0{,}115}$	$0{,}814 \pm 0{,}106$

Tabla A.2: Enfoque A, estrategia A1: desempeño a nivel de sujeto sobre las tres representaciones funcionales.

Modelo	Exactitud bal.	Sens.	Espec.	F1	AUC
B-spline (X_{raw})					
LogReg	$\mathbf{0{,}792 \pm 0{,}114}$	$\mathbf{0{,}840 \pm 0{,}155}$	$\mathbf{0{,}744 \pm 0{,}145}$	$\mathbf{0{,}795 \pm 0{,}109}$	$\mathbf{0{,}806 \pm 0{,}153}$
Random Forest	$0{,}724 \pm 0{,}156$	$0{,}733 \pm 0{,}148$	$0{,}714 \pm 0{,}208$	$0{,}723 \pm 0{,}161$	$0{,}770 \pm 0{,}117$
MLP	$0{,}715 \pm 0{,}120$	$0{,}713 \pm 0{,}247$	$0{,}717 \pm 0{,}223$	$0{,}679 \pm 0{,}219$	$0{,}687 \pm 0{,}181$
Transformer	$0{,}667 \pm 0{,}168$	$0{,}700 \pm 0{,}180$	$0{,}633 \pm 0{,}276$	$0{,}670 \pm 0{,}155$	$0{,}753 \pm 0{,}143$
FDNN	$0{,}650 \pm 0{,}140$	$0{,}703 \pm 0{,}235$	$0{,}597 \pm 0{,}292$	$0{,}653 \pm 0{,}156$	$0{,}735 \pm 0{,}169$
FNN	$0{,}598 \pm 0{,}175$	$0{,}667 \pm 0{,}260$	$0{,}530 \pm 0{,}241$	$0{,}605 \pm 0{,}198$	$0{,}604 \pm 0{,}194$
AdaFNN	$0{,}591 \pm 0{,}143$	$0{,}597 \pm 0{,}270$	$0{,}586 \pm 0{,}338$	$0{,}562 \pm 0{,}208$	$0{,}626 \pm 0{,}207$
EEGNet	$0{,}641 \pm 0{,}156$	$0{,}547 \pm 0{,}396$	$0{,}734 \pm 0{,}327$	$0{,}509 \pm 0{,}341$	$0{,}679 \pm 0{,}235$
CNN1D	$0{,}601 \pm 0{,}146$	$0{,}793 \pm 0{,}186$	$0{,}409 \pm 0{,}268$	$0{,}660 \pm 0{,}128$	$0{,}690 \pm 0{,}164$
Cholesky (X_{chol})					
LogReg	$\mathbf{0{,}818 \pm 0{,}109}$	$\mathbf{0{,}840 \pm 0{,}155}$	$\mathbf{0{,}796 \pm 0{,}149}$	$\mathbf{0{,}816 \pm 0{,}103}$	$\mathbf{0{,}879 \pm 0{,}097}$
Random Forest	$0{,}728 \pm 0{,}125$	$0{,}747 \pm 0{,}177$	$0{,}709 \pm 0{,}222$	$0{,}723 \pm 0{,}115$	$0{,}787 \pm 0{,}126$
MLP	$0{,}752 \pm 0{,}142$	$0{,}770 \pm 0{,}183$	$0{,}733 \pm 0{,}195$	$0{,}748 \pm 0{,}139$	$0{,}780 \pm 0{,}139$
Transformer	$0{,}687 \pm 0{,}127$	$0{,}687 \pm 0{,}188$	$0{,}688 \pm 0{,}222$	$0{,}674 \pm 0{,}135$	$0{,}765 \pm 0{,}141$
FDNN	$0{,}633 \pm 0{,}157$	$0{,}663 \pm 0{,}297$	$0{,}603 \pm 0{,}284$	$0{,}611 \pm 0{,}244$	$0{,}674 \pm 0{,}185$
FNN	$0{,}596 \pm 0{,}151$	$0{,}633 \pm 0{,}287$	$0{,}559 \pm 0{,}312$	$0{,}578 \pm 0{,}181$	$0{,}602 \pm 0{,}212$
AdaFNN	$0{,}594 \pm 0{,}178$	$0{,}660 \pm 0{,}302$	$0{,}528 \pm 0{,}309$	$0{,}598 \pm 0{,}238$	$0{,}591 \pm 0{,}255$
EEGNet	$0{,}570 \pm 0{,}140$	$0{,}443 \pm 0{,}369$	$0{,}697 \pm 0{,}311$	$0{,}421 \pm 0{,}323$	$0{,}679 \pm 0{,}239$
CNN1D	$0{,}584 \pm 0{,}139$	$0{,}740 \pm 0{,}219$	$0{,}428 \pm 0{,}336$	$0{,}626 \pm 0{,}133$	$0{,}714 \pm 0{,}166$
Cholesky + FPCA					
LogReg	$\mathbf{0{,}803 \pm 0{,}138}$	$\mathbf{0{,}827 \pm 0{,}167}$	$\mathbf{0{,}779 \pm 0{,}167}$	$\mathbf{0{,}803 \pm 0{,}129}$	$\mathbf{0{,}855 \pm 0{,}116}$
Random Forest	$0{,}719 \pm 0{,}154$	$0{,}733 \pm 0{,}209$	$0{,}706 \pm 0{,}228$	$0{,}712 \pm 0{,}164$	$0{,}797 \pm 0{,}140$
MLP	$0{,}694 \pm 0{,}159$	$0{,}697 \pm 0{,}202$	$0{,}692 \pm 0{,}193$	$0{,}685 \pm 0{,}181$	$0{,}769 \pm 0{,}165$
Transformer	$0{,}718 \pm 0{,}152$	$0{,}730 \pm 0{,}194$	$0{,}707 \pm 0{,}196$	$0{,}715 \pm 0{,}146$	$0{,}805 \pm 0{,}194$
FDNN	$0{,}642 \pm 0{,}147$	$0{,}577 \pm 0{,}314$	$0{,}708 \pm 0{,}281$	$0{,}566 \pm 0{,}269$	$0{,}733 \pm 0{,}156$
FNN	$0{,}672 \pm 0{,}182$	$0{,}647 \pm 0{,}274$	$0{,}698 \pm 0{,}247$	$0{,}631 \pm 0{,}248$	$0{,}733 \pm 0{,}190$
AdaFNN	$0{,}609 \pm 0{,}142$	$0{,}617 \pm 0{,}302$	$0{,}601 \pm 0{,}236$	$0{,}577 \pm 0{,}223$	$0{,}687 \pm 0{,}232$
EEGNet	$0{,}643 \pm 0{,}137$	$0{,}730 \pm 0{,}326$	$0{,}556 \pm 0{,}389$	$0{,}628 \pm 0{,}262$	$0{,}776 \pm 0{,}184$
CNN1D	$0{,}710 \pm 0{,}145$	$0{,}740 \pm 0{,}261$	$0{,}680 \pm 0{,}240$	$0{,}690 \pm 0{,}223$	$0{,}808 \pm 0{,}138$

Tabla A.3: Enfoque B: desempeño a nivel de sujeto.

Modelo	Exactitud bal.	Sens.	Espec.	F1	AUC
B-spline (X_{raw})					
LogReg	$0{,}639 \pm 0{,}152$	$0{,}700 \pm 0{,}145$	$0{,}579 \pm 0{,}290$	$0{,}664 \pm 0{,}111$	$0{,}669 \pm 0{,}168$
Random Forest	$0{,}592 \pm 0{,}205$	$0{,}623 \pm 0{,}234$	$0{,}560 \pm 0{,}279$	$0{,}599 \pm 0{,}206$	$0{,}618 \pm 0{,}221$
MLP	$0{,}598 \pm 0{,}194$	$0{,}693 \pm 0{,}162$	$0{,}502 \pm 0{,}316$	$0{,}641 \pm 0{,}163$	$0{,}619 \pm 0{,}251$
Transformer	$\mathbf{0{,}672 \pm 0{,}127}$	$0{,}717 \pm 0{,}181$	$0{,}627 \pm 0{,}276$	$0{,}676 \pm 0{,}119$	$\mathbf{0{,}737 \pm 0{,}182}$
FDNN	$0{,}558 \pm 0{,}129$	$0{,}643 \pm 0{,}309$	$0{,}473 \pm 0{,}269$	$0{,}549 \pm 0{,}227$	$0{,}599 \pm 0{,}150$
FNN	$0{,}502 \pm 0{,}119$	$0{,}533 \pm 0{,}291$	$0{,}470 \pm 0{,}320$	$0{,}478 \pm 0{,}199$	$0{,}545 \pm 0{,}191$
AdaFNN	$0{,}573 \pm 0{,}159$	$0{,}587 \pm 0{,}258$	$0{,}559 \pm 0{,}271$	$0{,}552 \pm 0{,}200$	$0{,}591 \pm 0{,}224$
EEGNet	$0{,}660 \pm 0{,}180$	$\mathbf{0{,}810 \pm 0{,}177}$	$0{,}510 \pm 0{,}392$	$\mathbf{0{,}715 \pm 0{,}136}$	$0{,}611 \pm 0{,}299$
CNN1D	$0{,}636 \pm 0{,}130$	$0{,}517 \pm 0{,}350$	$\mathbf{0{,}756 \pm 0{,}285}$	$0{,}511 \pm 0{,}299$	$0{,}733 \pm 0{,}157$
Cholesky (X_{chol})					
LogReg	$0{,}701 \pm 0{,}172$	$0{,}757 \pm 0{,}155$	$0{,}644 \pm 0{,}253$	$0{,}721 \pm 0{,}132$	$0{,}781 \pm 0{,}153$
Random Forest	$0{,}695 \pm 0{,}161$	$\mathbf{0{,}770 \pm 0{,}149}$	$0{,}620 \pm 0{,}268$	$0{,}720 \pm 0{,}125$	$0{,}823 \pm 0{,}129$
MLP	$0{,}701 \pm 0{,}127$	$0{,}743 \pm 0{,}159$	$0{,}658 \pm 0{,}224$	$0{,}713 \pm 0{,}111$	$0{,}795 \pm 0{,}159$
Transformer	$0{,}668 \pm 0{,}169$	$0{,}717 \pm 0{,}236$	$0{,}620 \pm 0{,}234$	$0{,}668 \pm 0{,}189$	$0{,}754 \pm 0{,}159$
FDNN	$0{,}647 \pm 0{,}145$	$0{,}690 \pm 0{,}344$	$0{,}604 \pm 0{,}350$	$0{,}606 \pm 0{,}269$	$0{,}736 \pm 0{,}196$
FNN	$0{,}624 \pm 0{,}177$	$0{,}680 \pm 0{,}260$	$0{,}568 \pm 0{,}330$	$0{,}632 \pm 0{,}182$	$0{,}647 \pm 0{,}214$
AdaFNN	$0{,}694 \pm 0{,}212$	$0{,}710 \pm 0{,}254$	$0{,}679 \pm 0{,}334$	$0{,}693 \pm 0{,}221$	$0{,}689 \pm 0{,}270$
EEGNet	$0{,}711 \pm 0{,}141$	$0{,}757 \pm 0{,}188$	$0{,}666 \pm 0{,}247$	$0{,}722 \pm 0{,}132$	$0{,}834 \pm 0{,}131$
CNN1D	$\mathbf{0{,}762 \pm 0{,}141}$	$0{,}730 \pm 0{,}194$	$\mathbf{0{,}793 \pm 0{,}176}$	$\mathbf{0{,}747 \pm 0{,}156}$	$\mathbf{0{,}861 \pm 0{,}123}$
Cholesky + FPCA					
LogReg	$0{,}778 \pm 0{,}126$	$0{,}823 \pm 0{,}168$	$\mathbf{0{,}733 \pm 0{,}221}$	$0{,}791 \pm 0{,}115$	$\mathbf{0{,}912 \pm 0{,}098}$
Random Forest	$\mathbf{0{,}781 \pm 0{,}094}$	$\mathbf{0{,}877 \pm 0{,}150}$	$0{,}686 \pm 0{,}141$	$\mathbf{0{,}794 \pm 0{,}097}$	$0{,}849 \pm 0{,}128$
MLP	$0{,}704 \pm 0{,}132$	$0{,}797 \pm 0{,}170$	$0{,}611 \pm 0{,}239$	$0{,}724 \pm 0{,}113$	$0{,}830 \pm 0{,}137$
Transformer	$0{,}752 \pm 0{,}148$	$0{,}793 \pm 0{,}251$	$0{,}711 \pm 0{,}214$	$0{,}740 \pm 0{,}226$	$0{,}862 \pm 0{,}103$
FDNN	$0{,}684 \pm 0{,}117$	$0{,}767 \pm 0{,}301$	$0{,}602 \pm 0{,}242$	$0{,}666 \pm 0{,}233$	$0{,}807 \pm 0{,}119$
FNN	$0{,}615 \pm 0{,}192$	$0{,}663 \pm 0{,}219$	$0{,}567 \pm 0{,}266$	$0{,}630 \pm 0{,}184$	$0{,}671 \pm 0{,}218$
AdaFNN	$0{,}664 \pm 0{,}139$	$0{,}683 \pm 0{,}234$	$0{,}644 \pm 0{,}305$	$0{,}651 \pm 0{,}207$	$0{,}737 \pm 0{,}199$
EEGNet	$0{,}654 \pm 0{,}131$	$0{,}797 \pm 0{,}262$	$0{,}512 \pm 0{,}356$	$0{,}670 \pm 0{,}201$	$0{,}726 \pm 0{,}248$
CNN1D	$0{,}737 \pm 0{,}114$	$0{,}797 \pm 0{,}152$	$0{,}678 \pm 0{,}245$	$0{,}746 \pm 0{,}110$	$0{,}850 \pm 0{,}123$

Tabla A.4: Enfoque A, estrategia A2: desempeño a nivel de sujeto.

Modelo	Exactitud bal.	Sens.	Espec.	F1	AUC
B-spline (X_{raw})					
LogReg	$\mathbf{0{,}806 \pm 0{,}114}$	$0{,}791 \pm 0{,}138$	$\mathbf{0{,}820 \pm 0{,}209}$	$\mathbf{0{,}803 \pm 0{,}092}$	$\mathbf{0{,}900 \pm 0{,}098}$
Random Forest	$0{,}692 \pm 0{,}121$	$0{,}653 \pm 0{,}215$	$0{,}730 \pm 0{,}247$	$0{,}659 \pm 0{,}137$	$0{,}809 \pm 0{,}170$
MLP	$0{,}764 \pm 0{,}125$	$\mathbf{0{,}830 \pm 0{,}153}$	$0{,}699 \pm 0{,}264$	$0{,}770 \pm 0{,}085$	$0{,}823 \pm 0{,}175$
Transformer	$0{,}724 \pm 0{,}094$	$0{,}741 \pm 0{,}207$	$0{,}708 \pm 0{,}226$	$0{,}709 \pm 0{,}109$	$0{,}865 \pm 0{,}094$
FDNN	$0{,}666 \pm 0{,}155$	$0{,}766 \pm 0{,}228$	$0{,}567 \pm 0{,}346$	$0{,}684 \pm 0{,}127$	$0{,}802 \pm 0{,}119$
FNN	$0{,}764 \pm 0{,}148$	$0{,}800 \pm 0{,}198$	$0{,}729 \pm 0{,}300$	$0{,}764 \pm 0{,}105$	$0{,}844 \pm 0{,}111$
AdaFNN	$0{,}734 \pm 0{,}140$	$0{,}713 \pm 0{,}263$	$0{,}755 \pm 0{,}218$	$0{,}699 \pm 0{,}222$	$0{,}841 \pm 0{,}131$
EEGNet	$0{,}752 \pm 0{,}128$	$0{,}802 \pm 0{,}151$	$0{,}703 \pm 0{,}249$	$0{,}764 \pm 0{,}099$	$0{,}876 \pm 0{,}129$
CNN1D	$0{,}655 \pm 0{,}150$	$0{,}811 \pm 0{,}195$	$0{,}499 \pm 0{,}341$	$0{,}690 \pm 0{,}104$	$0{,}834 \pm 0{,}131$
Cholesky (X_{chol})					
LogReg	$\mathbf{0{,}824 \pm 0{,}092}$	$0{,}791 \pm 0{,}138$	$\mathbf{0{,}856 \pm 0{,}154}$	$\mathbf{0{,}812 \pm 0{,}089}$	$\mathbf{0{,}896 \pm 0{,}116}$
Random Forest	$0{,}734 \pm 0{,}127$	$0{,}714 \pm 0{,}189$	$0{,}753 \pm 0{,}245$	$0{,}715 \pm 0{,}136$	$0{,}801 \pm 0{,}158$
MLP	$0{,}778 \pm 0{,}133$	$\mathbf{0{,}830 \pm 0{,}153}$	$0{,}727 \pm 0{,}266$	$0{,}794 \pm 0{,}104$	$0{,}845 \pm 0{,}111$
Transformer	$0{,}740 \pm 0{,}127$	$0{,}698 \pm 0{,}221$	$0{,}781 \pm 0{,}216$	$0{,}714 \pm 0{,}156$	$0{,}862 \pm 0{,}092$
FDNN	$0{,}767 \pm 0{,}113$	$0{,}770 \pm 0{,}196$	$0{,}763 \pm 0{,}224$	$0{,}759 \pm 0{,}095$	$0{,}800 \pm 0{,}161$
FNN	$0{,}772 \pm 0{,}121$	$0{,}797 \pm 0{,}192$	$0{,}748 \pm 0{,}241$	$0{,}761 \pm 0{,}105$	$0{,}866 \pm 0{,}103$
AdaFNN	$0{,}708 \pm 0{,}096$	$0{,}717 \pm 0{,}199$	$0{,}699 \pm 0{,}218$	$0{,}692 \pm 0{,}123$	$0{,}810 \pm 0{,}148$
EEGNet	$0{,}709 \pm 0{,}150$	$0{,}706 \pm 0{,}210$	$0{,}712 \pm 0{,}263$	$0{,}703 \pm 0{,}162$	$0{,}820 \pm 0{,}143$
CNN1D	$0{,}688 \pm 0{,}127$	$0{,}821 \pm 0{,}192$	$0{,}554 \pm 0{,}324$	$0{,}713 \pm 0{,}097$	$0{,}781 \pm 0{,}168$
Cholesky + FPCA					
LogReg	$\mathbf{0{,}824 \pm 0{,}115}$	$0{,}791 \pm 0{,}167$	$\mathbf{0{,}856 \pm 0{,}134}$	$\mathbf{0{,}810 \pm 0{,}114}$	$\mathbf{0{,}902 \pm 0{,}111}$
Random Forest	$0{,}727 \pm 0{,}098$	$0{,}703 \pm 0{,}173$	$0{,}751 \pm 0{,}204$	$0{,}706 \pm 0{,}094$	$0{,}830 \pm 0{,}138$
MLP	$0{,}756 \pm 0{,}108$	$0{,}808 \pm 0{,}175$	$0{,}704 \pm 0{,}230$	$0{,}761 \pm 0{,}080$	$0{,}868 \pm 0{,}113$
Transformer	$0{,}680 \pm 0{,}118$	$0{,}654 \pm 0{,}244$	$0{,}707 \pm 0{,}250$	$0{,}647 \pm 0{,}154$	$0{,}832 \pm 0{,}114$
FDNN	$0{,}781 \pm 0{,}113$	$\mathbf{0{,}818 \pm 0{,}187}$	$0{,}744 \pm 0{,}276$	$0{,}778 \pm 0{,}087$	$0{,}875 \pm 0{,}090$
FNN	$0{,}739 \pm 0{,}108$	$0{,}758 \pm 0{,}196$	$0{,}720 \pm 0{,}257$	$0{,}733 \pm 0{,}119$	$0{,}854 \pm 0{,}073$
AdaFNN	$0{,}738 \pm 0{,}103$	$0{,}733 \pm 0{,}164$	$0{,}743 \pm 0{,}244$	$0{,}732 \pm 0{,}076$	$0{,}839 \pm 0{,}104$
EEGNet	$0{,}741 \pm 0{,}133$	$0{,}768 \pm 0{,}199$	$0{,}714 \pm 0{,}279$	$0{,}744 \pm 0{,}142$	$0{,}838 \pm 0{,}115$
CNN1D	$0{,}707 \pm 0{,}111$	$0{,}768 \pm 0{,}198$	$0{,}646 \pm 0{,}317$	$0{,}720 \pm 0{,}081$	$0{,}852 \pm 0{,}115$

B. CONFIGURACIÓN DE LOS MODELOS DE CLASIFICACIÓN

En este anexo se presentan los principales hiperparámetros utilizados en los modelos de clasificación. Las arquitecturas de aprendizaje profundo compartieron una configuración común de entrenamiento, mientras que los parámetros estructurales se definieron de acuerdo con cada arquitectura. Estas configuraciones se mantuvieron fijas durante la evaluación.

Tabla B.1: Configuración de entrenamiento utilizada en las arquitecturas de aprendizaje profundo.

Parámetro	**Configuración**
Optimizador	AdamW
Tasa de aprendizaje inicial	1×10^{-3}
Decaimiento de pesos	1×10^{-4}
Tamaño de lote	32
Número máximo de épocas	80
Dropout	$0{,}30$
Planificador de tasa de aprendizaje	*CosineAnnealingLR*, $T_{\text{máx}} = 80$
Función de pérdida	*BCEWithLogitsLoss* con ponderación de la clase positiva
Ponderación de la clase positiva	$\text{máx}(N_{\text{neg}}/N_{\text{pos}},\, 0{,}5)$, calculada únicamente sobre el entrenamiento
Validación interna	Aproximadamente 20 % del conjunto de entrenamiento externo, manteniendo la separación por sujeto
Criterio de parada temprana	Pérdida del conjunto de validación interna
Paciencia	15 épocas
Mejora mínima	1×10^{-5}
Selección final de parámetros	Estado del modelo correspondiente a la menor pérdida de validación

Tabla B.2: Principales parámetros estructurales de los modelos de clasificación evaluados.

Modelo	Configuración principal
LogReg	Regresión logística con $C = 1{,}0$, ponderación de clases mediante `class_weight=balanced`, un máximo de 2000 iteraciones y semilla aleatoria igual a 42.
Random Forest	Bosque aleatorio compuesto por 200 árboles de decisión, con profundidad máxima de 10, ponderación de clases mediante `class_weight=balanced` y semilla aleatoria igual a 42.
MLP	Entrada aplanada de dimensión $n_{\text{canales}} \times n_{\text{coeficientes}}$, seguida de dos capas ocultas de 128 y 64 unidades. Cada capa oculta empleó normalización por lotes, activación ReLU y *dropout*. La capa de salida estuvo compuesta por una unidad.
Transformer	Proyección de los coeficientes de cada canal a un espacio latente de dimensión $d_{\text{model}} = 64$, con embeddings posicionales aprendibles. Se utilizaron dos bloques Transformer con cuatro cabezas de atención por bloque y una dimensión *feedforward* de 128 unidades. La activación utilizada fue GELU. Después de los bloques se aplicó normalización y promedio sobre los canales antes de la capa de salida.
CNN1D	Dos capas convolucionales unidimensionales sobre el eje funcional, con 32 y 64 filtros, respectivamente. El tamaño del núcleo fue 3 cuando la dimensión funcional fue igual o superior a 3, y 1 en caso contrario. Cada convolución fue seguida de normalización por lotes y activación ReLU. Se utilizó agrupamiento promedio adaptativo antes de la capa de salida.
FNN	16 unidades funcionales con pesos aprendibles sobre los canales y los coeficientes de entrada. La representación obtenida se procesó mediante normalización por lotes, activación GELU y una capa densa de 64 unidades antes de la salida binaria.
FDNN	Proyección inicial independiente por canal mediante una convolución agrupada, seguida de una combinación entre canales con 32 componentes. La dimensión funcional se proyectó posteriormente a 16 componentes. La representación resultante se procesó mediante activación GELU y una capa densa de 64 unidades antes de la salida.
AdaFNN	16 bases adaptativas aprendidas conjuntamente con el clasificador. Las proyecciones funcionales obtenidas para cada canal se combinaron mediante pesos específicos por canal y se procesaron con normalización por lotes, activación GELU y una capa densa de 64 unidades antes de la salida.

Tabla B.2 – continuación

Modelo	Configuración principal
EEGNet	Configuración con $F_1 = 8$, multiplicador de profundidad $D = 2$ y $F_2 = 16$. El tamaño del núcleo de la primera convolución sobre el eje funcional se definió como $\max(3, \lfloor n_{\text{coeficientes}}/2 \rfloor)$. Posteriormente se aplicó una convolución *depthwise* que integró la información entre todos los canales, seguida de una convolución separable, activación ELU y agrupamiento adaptativo antes de la capa de salida.

Tabla B.3: Número de parámetros entrenables de las arquitecturas de aprendizaje profundo según el enfoque y la representación funcional.

	Enfoque A		Enfoque B	
Modelo	**B-spline/Chol.**	**Chol.+FPCA**	**B-spline/Chol.**	**Chol.+FPCA**
MLP	$22\,913$	$16\,342 \pm 517$	$19\,073$	$16\,001 \pm 649$
Transformer	$68\,545$	$68\,217 \pm 26$	$68\,353$	$68\,199 \pm 32$
FDNN	$33\,865$	$33\,783 \pm 7$	$33\,817$	$33\,779 \pm 8$
FNN	2945	2124 ± 65	2465	2081 ± 81
AdaFNN	1521	1439 ± 7	1473	1435 ± 8
EEGNet	601	585	593	585
CNN1D	7457	7457	7457	7457

Nota: En las representaciones Cholesky+FPCA se presenta la media $\pm$ desviación estándar del número de parámetros entrenables en las 15 particiones cuando dicho número varió entre ellas. Esta variación se debe a que la cantidad de componentes retenidos por FPCA se determinó dentro de cada partición mediante el criterio del 95 % de varianza explicada. Cuando el número de parámetros fue constante entre particiones se reporta un único valor.

C. MATERIAL COMPLEMENTARIO PARA REPRODUCIBILIDAD

El código desarrollado para el preprocesamiento de las señales EEG, la construcción de las representaciones funcionales, el entrenamiento y evaluación de los modelos, el estudio de ablación y el análisis de interpretabilidad se encuentra disponible en: https://github.com/lespana/analisisDatosFuncionalesEEG.git

El repositorio contiene los cuadernos utilizados en las diferentes etapas del estudio y los archivos complementarios necesarios para documentar la trazabilidad de los experimentos.

Los datos EEG originales no se redistribuyen y pueden obtenerse directamente del conjunto público `ds003490` de OpenNeuro.